


# Laboratório #1

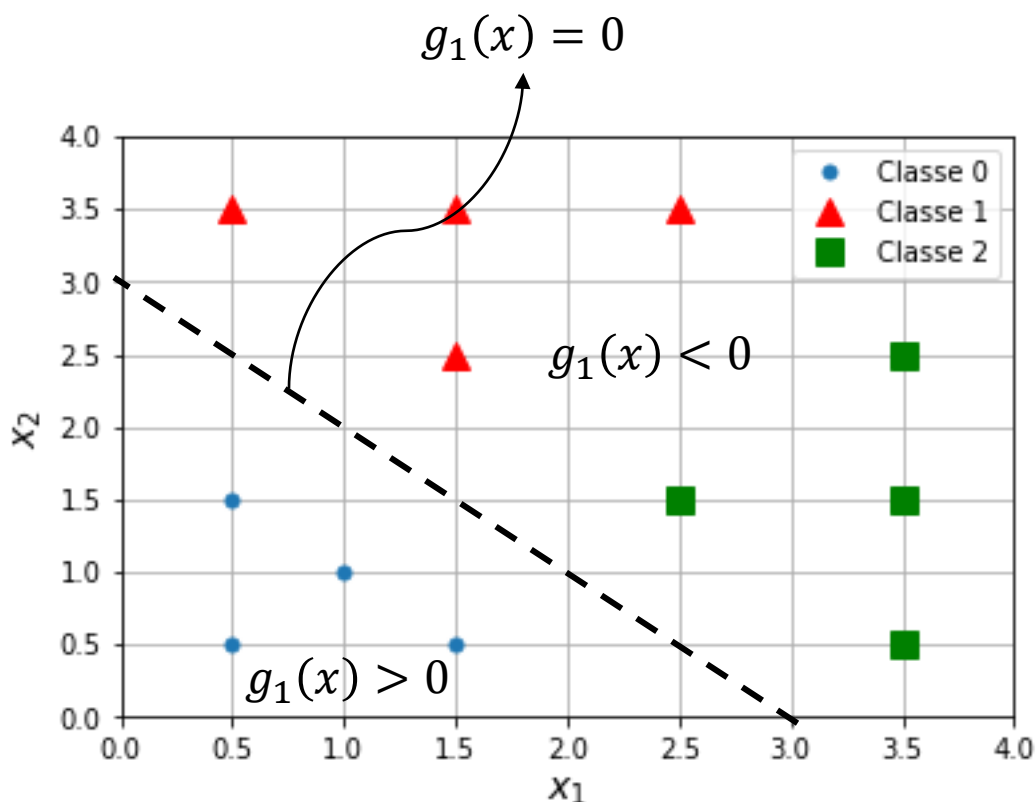
## Exercício #2

# Quantas funções discriminantes?




- Este é um problema com **múltiplas classes**, onde  $Q = 3$ .
- Como temos três classes, não faz sentido falarmos em classes positiva e negativa, apenas em seus índices: 0, 1, e 2.
- Quantas funções discriminantes são necessárias para separar as classes?
  - No mínimo duas funções,  $g_1(\mathbf{x})$  e  $g_2(\mathbf{x})$ .
- Qual o formato mais simples?
  - Retas da forma  $g(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2$ .
- Agora vamos encontrar os pesos de cada uma das funções.

# Encontrando os pesos $g_1(\mathbf{x})$



- Encontramos os pesos de  $g_1(\mathbf{x})$  primeiro, pois ela separa a classe 0 perfeitamente das outras duas (1 e 2).
- A **função discriminante** que representa esta reta é definida como
$$g_1(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2$$
- Temos 3 incógnitas e 3 equações:
  - $(x_1 = 0, x_2 = 3) \rightarrow 0 = a_0 + 3a_2 \therefore a_0 = -3a_2$
  - $(x_1 = 1, x_2 = 2) \rightarrow 0 = a_0 + a_1 + 2a_2 \therefore a_1 = -(a_0 + 2a_2)$
  - $(x_1 = 2, x_2 = 1) \rightarrow 0 = a_0 + 2a_1 + a_2 \therefore a_1 = -(a_0 + a_2)/2$
- Resolvendo o sistema, encontramos  $a_0 = 3$ ,  $a_1 = -1$ ,  $a_2 = -1$ , então
$$g_1(\mathbf{x}) = 3 - x_1 - x_2$$
- Substituindo alguns valores em  $g_1(\mathbf{x})$ , encontramos as regiões das duas classes que ela separa.

# Encontrando os pesos $g_2(\mathbf{x})$



- Na sequência, encontramos os pesos de  $g_2(\mathbf{x})$ , que irá discriminar entre as classes 1 e 2, concluindo a classificação.
- A **função discriminante** que representa esta reta é definida como
$$g_2(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2$$
- Novamente temos 3 incógnitas e 3 equações:
  - $(x_1 = 0, x_2 = 0) \rightarrow 0 = a_0$
  - $(x_1 = 1, x_2 = 1) \rightarrow 0 = a_0 + a_1 + a_2 \therefore a_1 = -a_2$
  - $(x_1 = 2, x_2 = 2) \rightarrow 0 = a_0 + 2a_1 + 2a_2 \therefore a_1 = -a_2$
- Resolvendo o sistema, encontramos  $a_0 = 0$ ,  $a_1 = 1$ ,  $a_2 = -1$ , então
$$g_2(\mathbf{x}) = x_1 - x_2$$

# Trecho da função *predict*

# Usamos  $g_1(\mathbf{x})$  primeiro, pois ela separa exatamente a classe 0 das demais.

if( $g_1(\mathbf{x}) \geq 0$ ):

    y\_pred[i] = 0

# Caso quando  $g_1(\mathbf{x}) < 0$

else:

    if( $g_2(\mathbf{x}) < 0$ ):

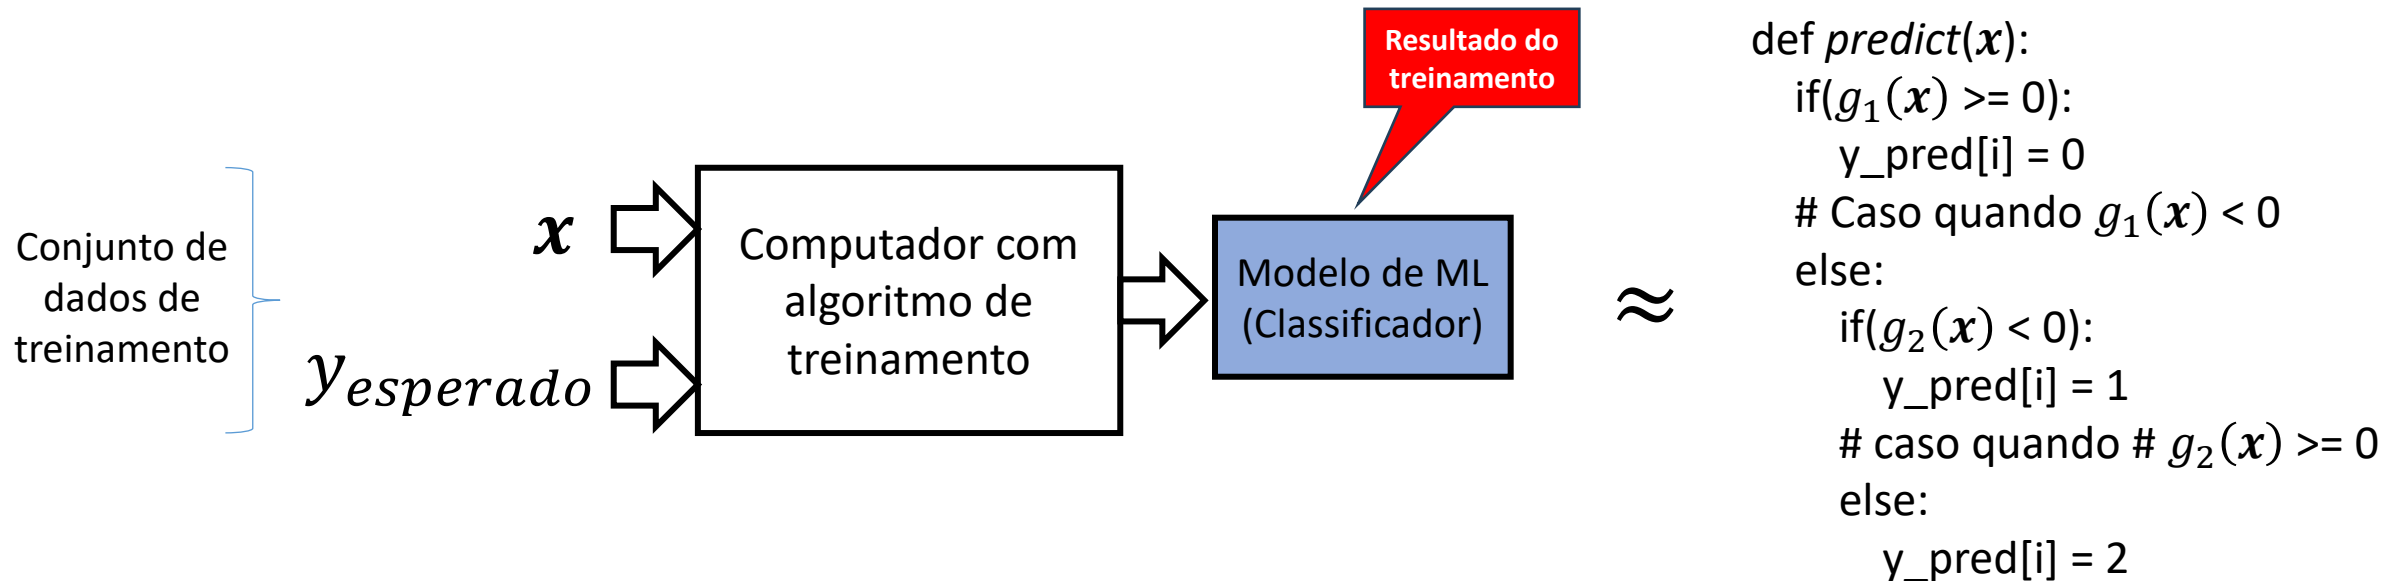
        y\_pred[i] = 1

    # caso quando  $g_2(\mathbf{x}) \geq 0$

    else:


        y\_pred[i] = 2

# Paradigma do ML



- Fornecemos as **entradas** e as **respostas esperadas** ao computador e deixamos que ele **aprenda, através de treinamento**, um **modelo** que **mapeie as entradas nas respostas esperadas**.


# Objetivo do curso



```
def predict(x):  
    if( $g_1(x) \geq 0$ ):  
        y_pred[i] = 0  
    # Caso quando  $g_1(x) < 0$   
    else:  
        if( $g_2(x) < 0$ ):  
            y_pred[i] = 1  
        # caso quando #  $g_2(x) \geq 0$   
        else:  
            y_pred[i] = 2
```

Treinar modelos de ML que aprendam, ***sem serem explicitamente programados***, a classificar as entradas,  $x$ , em suas respectivas classes.

# Objetivo do curso



```
def predict(x):  
    if( $g_1(x) \geq 0$ ):  
        y_pred[i] = 0  
    # Caso quando  $g_1(x) < 0$   
    else:  
        if( $g_2(x) < 0$ ):  
            y_pred[i] = 1  
        # caso quando #  $g_2(x) \geq 0$   
        else:  
            y_pred[i] = 2
```

Ou seja, o objetivo é encontrar os ***pesos das funções discriminantes*** que ***minimizem o erro de classificação.***