T320 - Introdução ao Aprendizado de Máquina II: *Classificação (Parte I)*

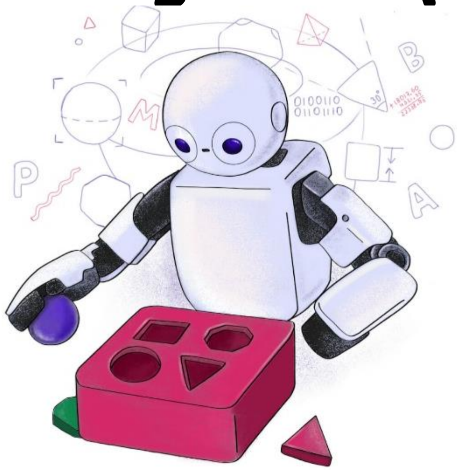

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

A disciplina

- Continuação de ***T319 - Introdução ao Aprendizado de Máquina I***.
- Curso introdutório onde veremos os conceitos básicos de funcionamento dos seguintes algoritmos de ***machine learning*** (ML):
    - Classificadores
        - Regressão Logística
        - Regressão Softmax
    - Redes Neurais
    - Clustering
- O curso será o mais prático possível, com vários exercícios envolvendo o uso dos algoritmos discutidos.

Objetivo do curso

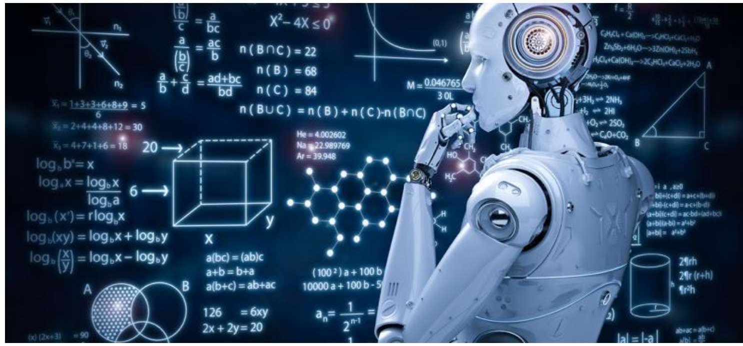

- O objetivo principal do curso é apresentar à vocês
  - os conceitos fundamentais da teoria do aprendizado de máquina.
  - um conjunto de ferramentas (ou seja, algoritmos) de aprendizado de máquina.
- Ao final do curso vocês devem ser capazes de
  - Entender e discutir sobre os principais algoritmos de ML.
  - Compreender a terminologia utilizada na área.
  - Aplicar algoritmos de ML para a resolução de problemas.
  - Analisar e entender novos algoritmos de ML.
  - Criar seus próprios projetos.

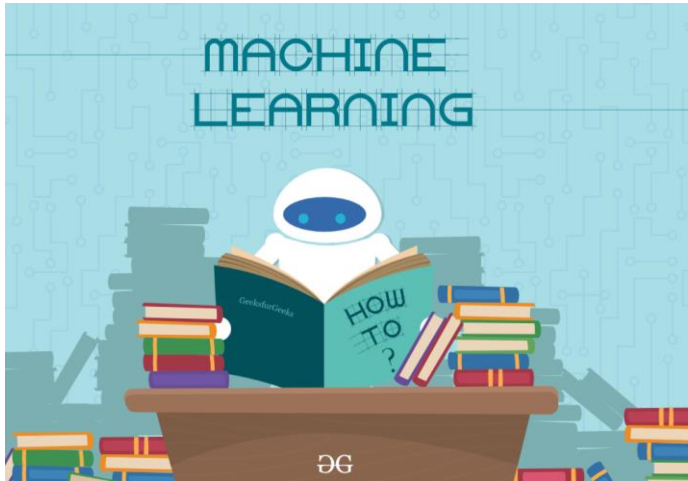

Avaliação do curso

- Avaliações
  - Dois (2) trabalhos valendo 85% da nota.
  - Envolvendo questões teóricas e/ou práticas.
- Atividades
  - Exercícios e quizzes valendo 15% da nota.
  - Ao longo das aulas e para casa.
  - Entregues no MS Teams.

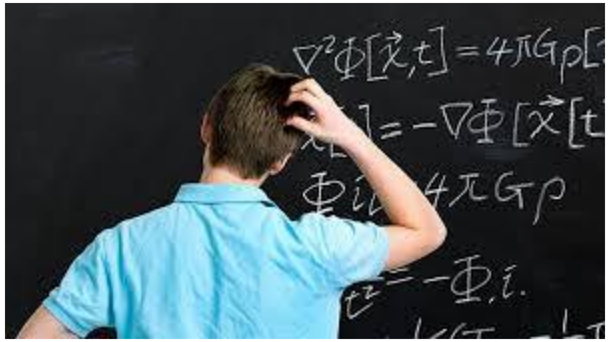

Referências

[1] Stuart Russell and Peter Norvig, “*Artificial Intelligence: A Modern Approach*,” Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.

[2] Aurélien Géron, “*Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*”, 1st ed., O'Reilly Media, 2017.

[3] Joseph Misiti, “*Awesome Machine-Learning*,” on-line data base with several free and/or open-source books (https://github.com/josephmisiti/awesome-machine-learning).

[4] Andriy Burkov, “*The Hundred-Page Machine-Learning Book*,” Andriy Burkov 2019.

[5] C. M. Bishop, “*Pattern Recognition and Machine Learning*,” Springer, 1st ed., 2006.

[6] S. Haykin, “*Neural Networks and Learning Machines*,” Prentice Hall, 3ª ed., 2008.

[7] Coleção de livros, https://drive.google.com/drive/folders/1IylIMu1w6POBhrVnw11yqXXy6BjC439j?usp=sharing

Avisos

- Entregas de exercícios (laboratórios e quizzes) devem ser feitas no MS Teams.
  - Se atentem às datas/horários de entrega no MS Teams.
- Todo material do curso será disponibilizado no MS Teams e no GitHub:
  - https://github.com/zz4fap/t320_aprendizado_de_maquina
- Horários de Atendimento
  - Professor: Segundas-feiras das 18:30 às 19:30 e Quartas-feiras das 15:30 às 16:30 via MS Teams.
  - Monitora (Bruna de Souza: ***bruna.br@gea.inatel.br***): Todas as Segundas-feiras das 17:30 às 18:30.

Motivação

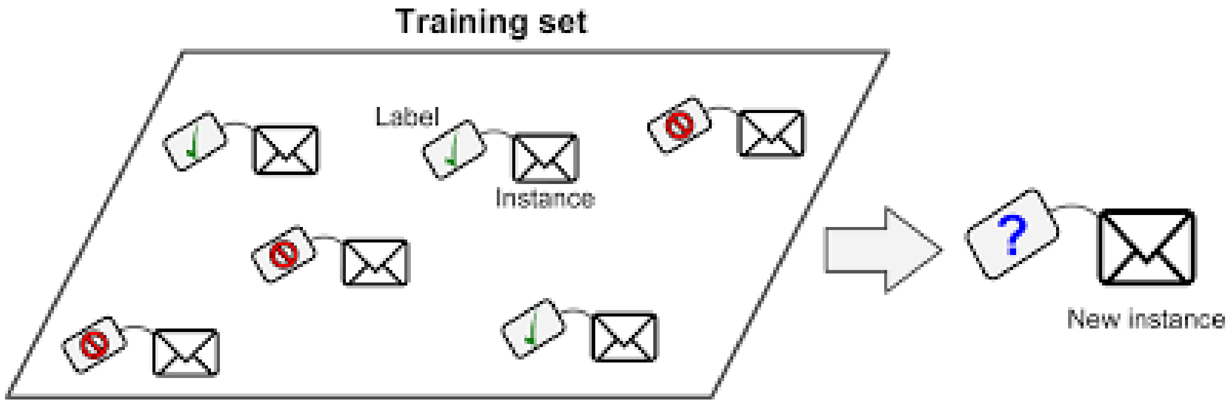

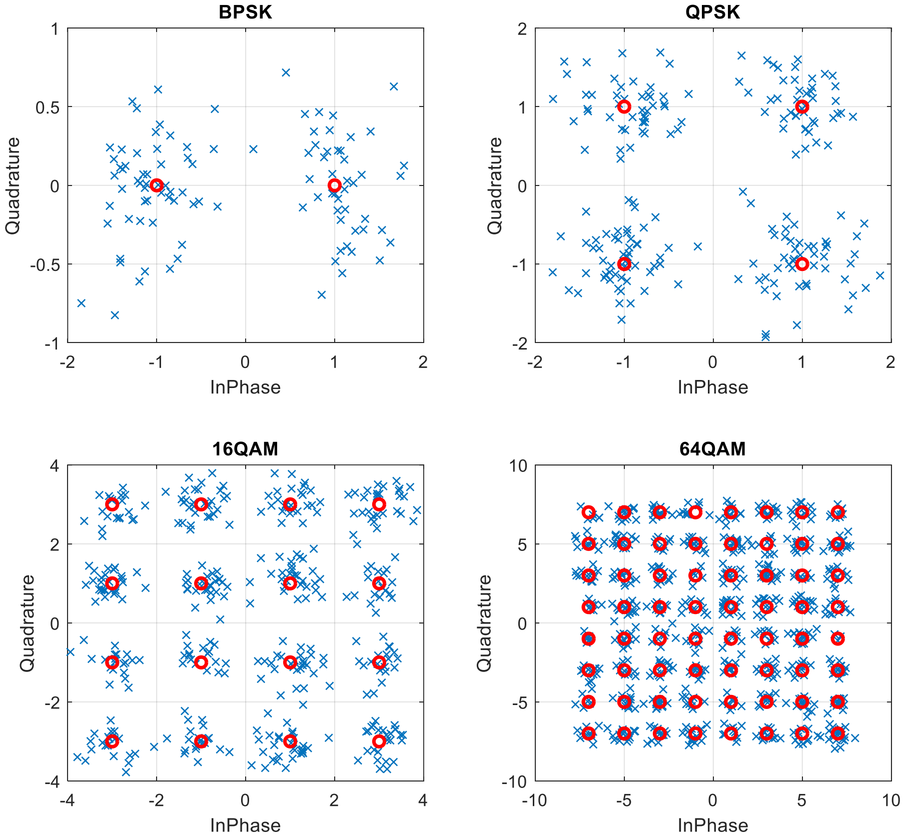

- Classificação de emails entre SPAM e pessoal (HAM).
- Detecção de símbolos (classificação de símbolos).
- Classificação de modulações (QPSK, AM, FM, etc.)

Motivação

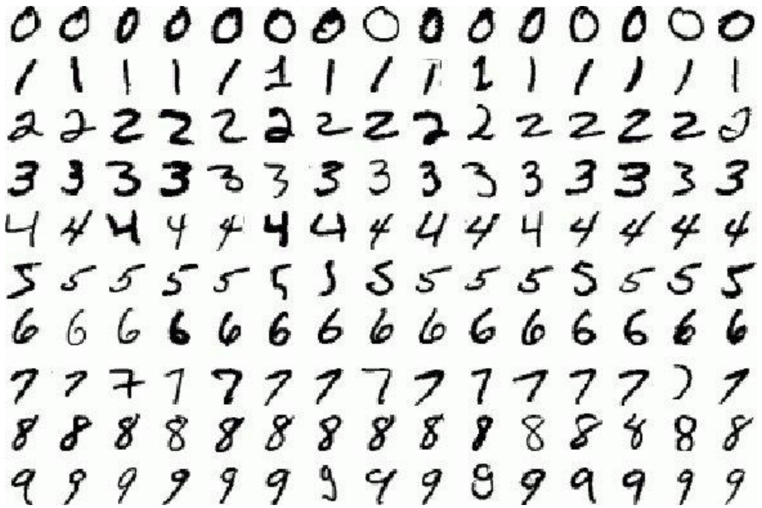

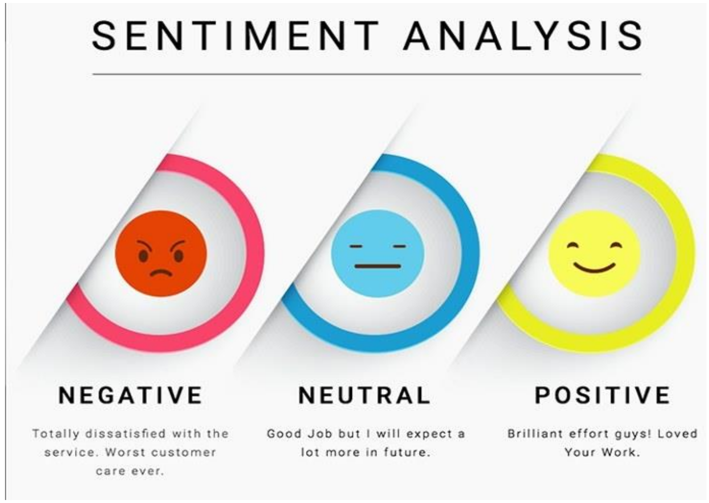

- Reconhecimento de dígitos escritos à mão.
- Classificação de texto.
- Classificação de sentimentos.

Definição do problema de classificação

- **Problema**: atribuir a cada ***exemplo de entrada*** o ***rótulo*** correspondente a uma das Q classes existentes, $C_q, q = 1, \dots, Q$, à qual o exemplo pertence.
  - As classes podem ser
    - Spam e not spam (ham).
    - Dígitos de 0 a 9.
    - Símbolos de uma modulção específica.
    - Objetos (carros, cachorro, gato, etc.)
- Semelhante ao problema da regressão linear, existe um conjunto de treinamento com exemplos e rótulos $\{\boldsymbol{x}(i); y(i)\}_{i=0}^{N-1}$ que é utilizado para treinar um ***classificador***, onde
  - $\boldsymbol{x}(i) = [x_1(i) \quad \cdots \quad x_K(i)]^T \in \mathbb{R}^{K \times 1}$ representa o *i*-ésimo vetor exemplo de entrada, o qual é caraterizado por K atributos, $x_1, \dots, x_K$
  - e $y(i) \in \mathbb{R}$ representa o *i*-ésimo ***rótulo***. Como veremos a seguir, y pode ser um escalar $\mathbb{R}^1$ ou um vetor $\mathbb{R}^{Q \times 1}$.

Representação da saída desejada

- Como vocês devem ter percebido, classificadores são algoritmos com ***treinamento supervisionado***.
- A saída desejada para um dado ***exemplo de entrada***, $\boldsymbol{x}$, deve ser o ***rótulo***, y, da classe à qual ele pertence.
- Sendo assim, a saída y de um ***classificador***, é uma variável ***categórica*** (ou seja, ***discreta***).
- Portanto, para realizarmos o treinamento do modelo, é necessário escolher uma ***representação numérica*** para a saída desejada, ou seja, y.
- Assim, como veremos a seguir, duas opções podem ser adotadas, dependendo do tipo de classificação a ser feita.

Representação da saída desejada

- **Classificação binária**: existem apenas duas classes possíveis, C_1 e C_2. Portanto, neste caso, podemos utilizar ***uma única saída escalar binária*** para indicar a classe correspondente ao exemplo de entrada:

$$y(i) = \begin{cases} 0, & \boldsymbol{x}(i) \in C_1 \\ 1, & \boldsymbol{x}(i) \in C_2 \end{cases}$$

- Assim, $y(i) \in \mathbb{R}^1$, de maneira que o classificador realiza um mapeamento $\mathbb{R}^K \to \mathbb{R}^1$

- Também é possível utilizar $y(i) = -1$ para $\boldsymbol{x}(i) \in C_1$, ou seja

$$y(i) = \begin{cases} -1, & \boldsymbol{x}(i) \in C_1 \\ 1, & \boldsymbol{x}(i) \in C_2 \end{cases}$$

Representação da saída desejada

- **Classificação multi-classes**: existem mais de 2 classes possíveis $(Q > 2)$.
  - Uma estratégia bastante utilizada para representar estas classes é conhecida como ***one-hot encoding***.
- ***One-hot encoding***: utiliza uma representação binária para cada uma das variáveis categóricas.
  - Neste caso, o ***classificador*** produz múltiplas saídas, cada uma representando a ***possibilidade*** como veremos mais tarde, a probabilidade) do exemplo de entrada pertencer a uma classe específica.
  - **Exemplo**: imaginemos um classificador de notícias com quatro classes possíveis: *esportes*, *política*, *ciências* e *variedades*. Como vocês as representariam com o ***one-hot encoding***?

$$\left.\begin{array}{ll} \textit{esportes:} & [1 \quad 0 \quad 0 \quad 0]^T \\ \textit{política:} & [0 \quad 1 \quad 0 \quad 0]^T \\ \textit{ciências:} & [0 \quad 0 \quad 1 \quad 0]^T \\ \textit{variedades:} & [0 \quad 0 \quad 0 \quad 1]^T \end{array}\right\}$$

Assim, $\boldsymbol{y}(i) \in \mathbb{R}^{Q \times 1}$, de maneira que o classificador realiza um mapeamento $\mathbb{R}^K \rightarrow \mathbb{R}^Q$.

Fronteiras de decisão de um classificador

- Antes, usávamos funções para aproximar um modelo gerador, agora, as usaremos para separar classes.
- O espaço K dimensional (i.e., $\mathbb{R}^K$) criado pelos ***atributos*** é dividido em ***regiões de decisão***, $R_i, i = 1, \ldots, \text{Q}$, as quais são separadas pelas ***fonteiras de decisão***.
- ***Fonteiras de decisão*** correspondem a ***superfícies de decisão*** no ***espaço de atributos*** onde ocorre uma indeterminação, ou seja, um empate entre diferentes classes possíveis.
- As ***fronteiras de decisão*** podem ser ***lineares*** (e.g., retas e planos) ou ***não-lineares*** (e.g., círculos).
- As ***fronteiras de decisão*** são definidas por ***funções*** (lineares ou não) que separam as classes.
- Essas funções são normalmente chamadas de ***funções discriminates***, pois separam as classes.
- Figuras mostram ***regiões de decisão*** em problemas de classificação ***binária*** e ***multi-classes***.

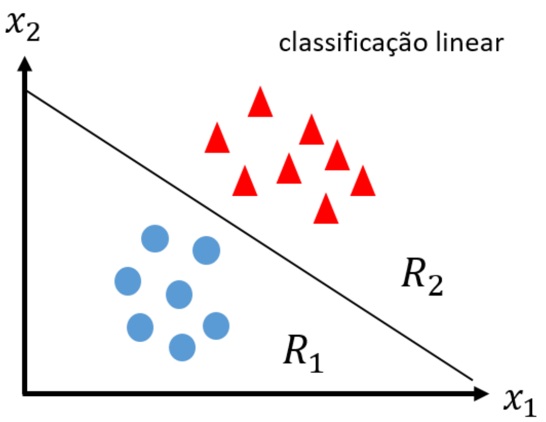

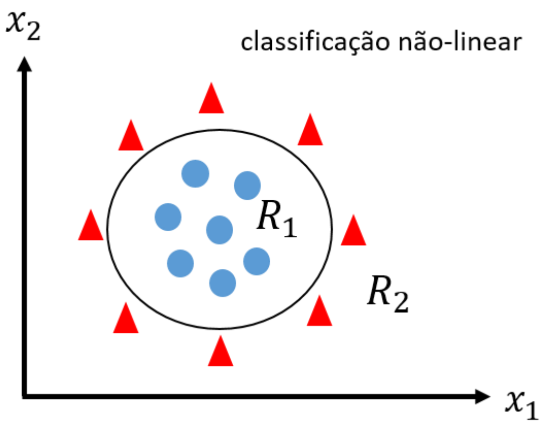

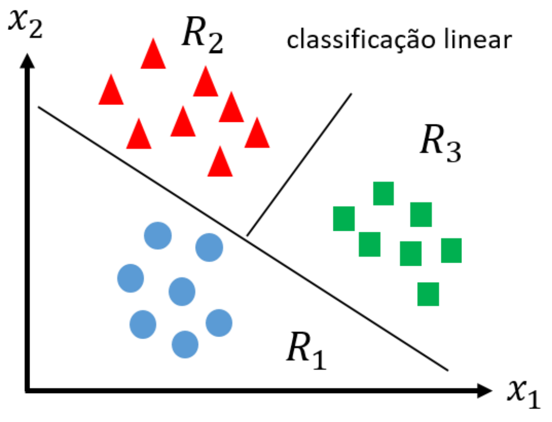

Funções discriminates lineares

- Em geral, uma ***função discriminante linear*** pode ser escrita da seguinte forma

$$g(\boldsymbol{x}) = a_0 + a_1x_1 + a_2x_2 + \ \ldots + a_Kx_K = \boldsymbol{a}^T\boldsymbol{x},$$

que nada mais é do uma combinação linear dos pesos, assim como nós vimos na regressão linear.

- $g(\boldsymbol{x})$ também pode ser visto como um ***hiperplano*** que separa as classes. Um ***hiperplano*** pode ser 1 ponto em 1D, uma reta em 2D e um plano em 3D.
  - O bias, a_0, dá o deslocamento com relação à origem.
  - E o restante dos pesos determinam a orientação do ***hiperplano***.

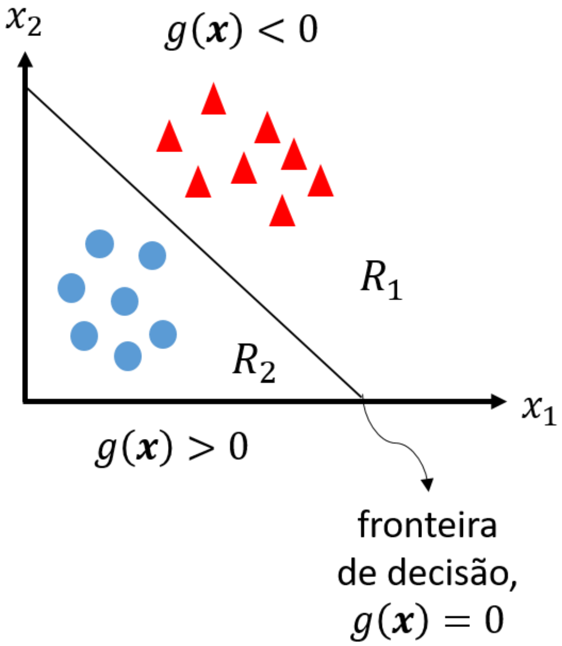

- A ideia aqui é encontrar os pesos da ***função discriminate*** de tal forma que

$$C_q = \begin{cases} 1, & g(\boldsymbol{x}) < 0 \\ 2, & g(\boldsymbol{x}) > 0 \\ \text{uma ou outra}, & g(\boldsymbol{x}) = 0 \end{cases}$$

- OBS.: Como vimos anteriormente, podemos ter também ***funções discriminates não-lineares***, e.g., $g(\boldsymbol{x}) = a_0 + x_1^2 + x_2^2$ (eq. de um círculo).

Exemplo: Encontrar a função discriminante, $g(\boldsymbol{x})$

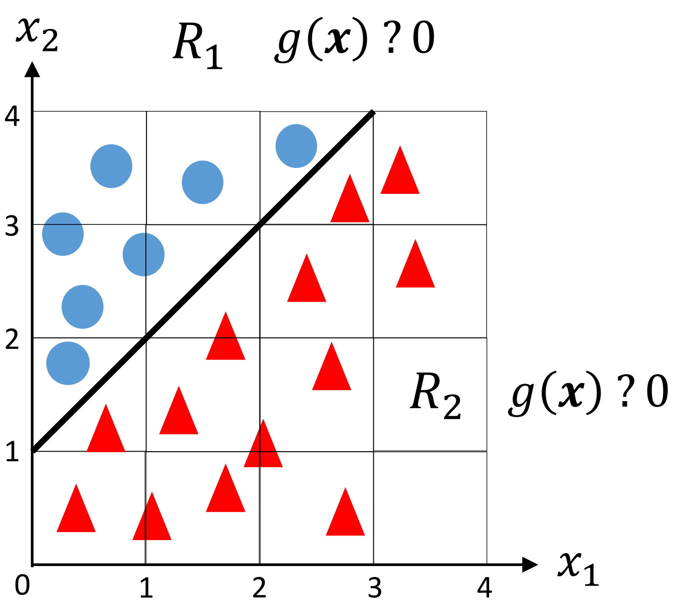

- Dada a seguinte função discriminante: $g(x) = a_0 + a_1 x_1 + a_2 x_2$
- Encontre os pesos e as regiões de decisão.

Exemplo: Encontrar a função discriminante, $g(\boldsymbol{x})$

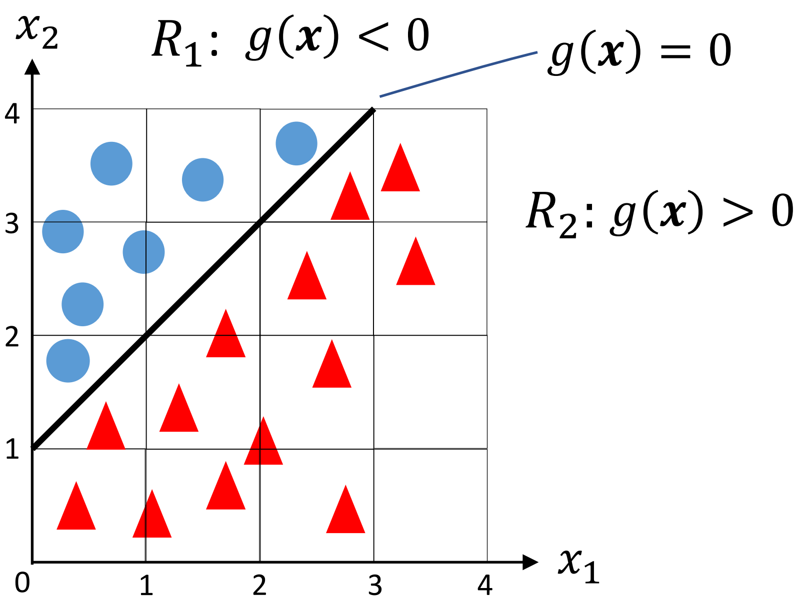

- Temos 3 incógnitas e 3 equações:
  - $(x_1 = 0, x_2 = 1) \rightarrow 0 = a_0 + a_2 \therefore a_0 = -a_2$
  - $(x_1 = 1, x_2 = 2) \rightarrow 0 = a_0 + a_1 + 2a_2 \therefore a_1 = -(a_0 + 2a_2)$
  - $(x_1 = 2, x_2 = 3) \rightarrow 0 = a_0 + 2a_1 + 3a_2 \therefore a_1 = -(a_0 + 3a_2)/2$
- Resolvendo o sistema, encontramos $a_0 = 1, a_1 = 1, a_2 = -1$, então
  - $g(x) = 1 + x_1 - x_2$

[Exemplo: encontrando_pesos_da_função_discriminante.ipynb]

Tarefas

- **Quiz**: *“T320 - Quiz - Classificação (Parte I)”* que se encontra no MS Teams.
- **Exercício Prático**: **Laboratório #1**.
  - Pode ser baixado do MS Teams ou do GitHub.
  - Pode ser respondido através do link acima (na nuvem) ou localmente.
  - Instruções para resolução e entrega dos laboratórios.
  - **Atividades podem ser feitas em grupo, mas as entregas devem ser individuais.**

Obrigado!

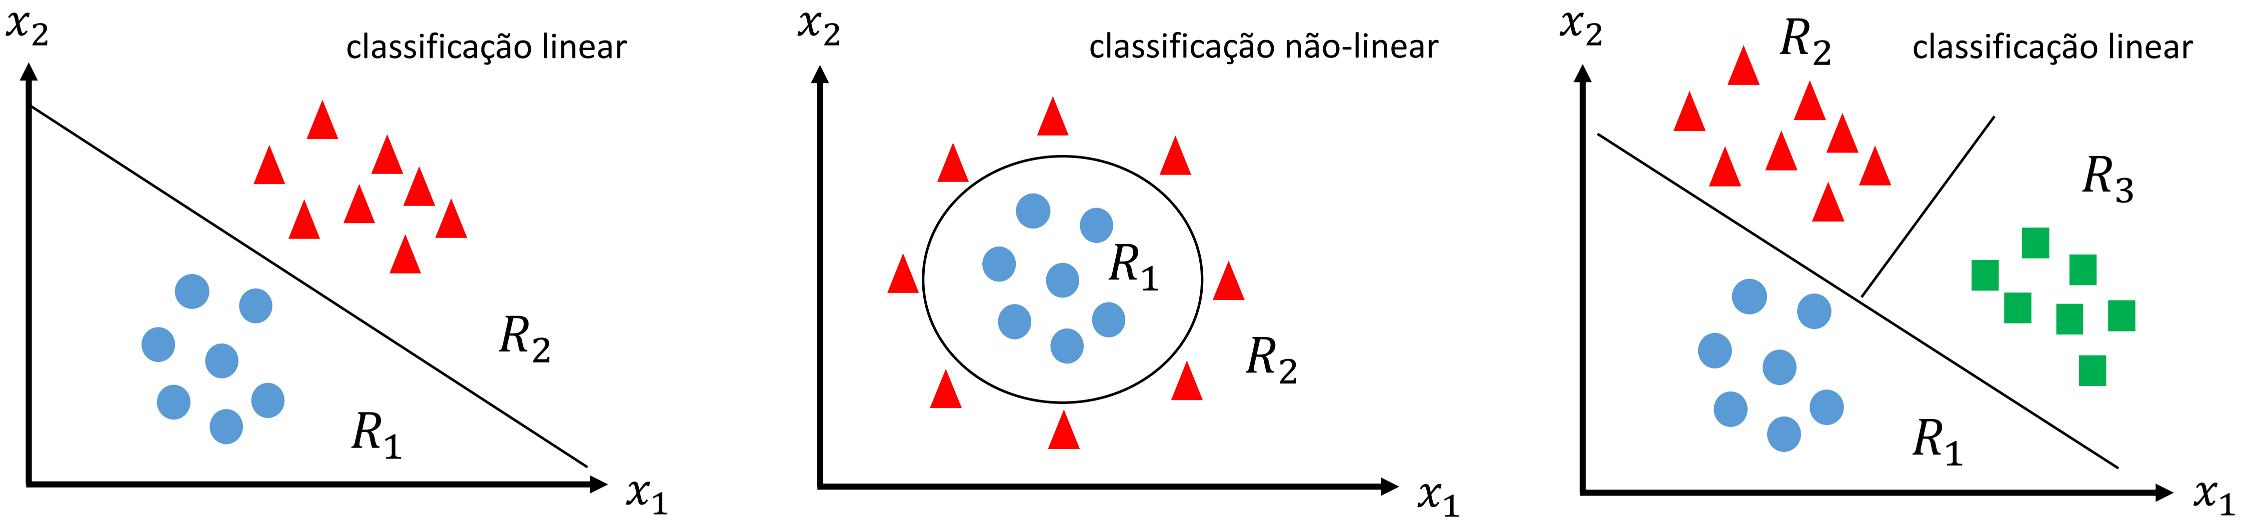
x_2
classificação linear
R_2
R_1
x_1
x_2
classificação não-linear
R_1
R_2
x_1
x_2
R_2
classificação linear
R_3
R_1
x_1

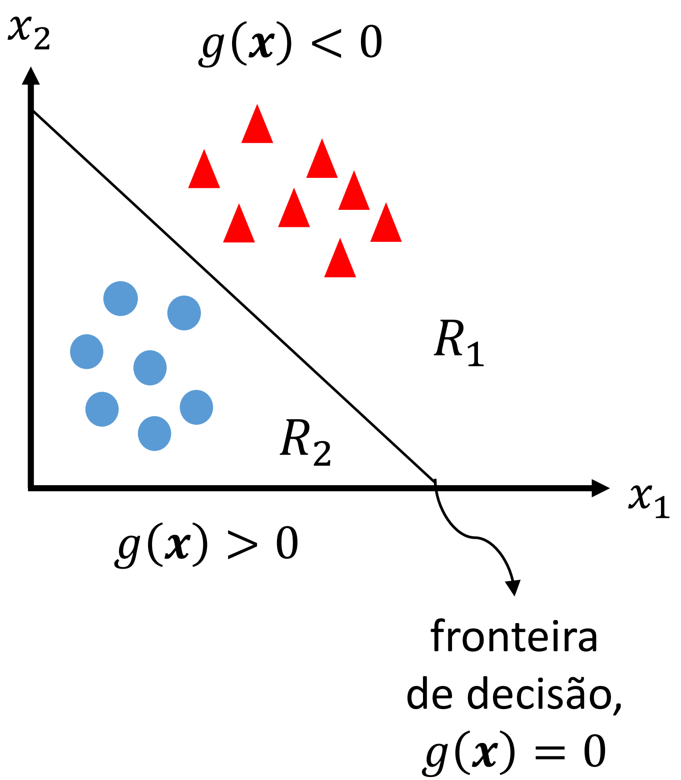
x_2
$g(\boldsymbol{x}) < 0$
R_1
R_2
x_1
$g(\boldsymbol{x}) > 0$
fronteira
de decisão,
$g(\boldsymbol{x}) = 0$