


T320 - Introdução ao Aprendizado de Máquina II: *Classificação (Parte I)*



Inatel



Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

A disciplina

- Continuação de ***T319 - Introdução ao Aprendizado de Máquina I.***
- ***Curso introdutório*** onde veremos os conceitos básicos de funcionamento dos seguintes algoritmos de ***machine learning*** (ML):
 - Classificadores
 - Regressão Logística
 - Regressão Softmax
 - k-Vizinhos mais Próximos
 - Redes Neurais
 - Clustering
 - k-Means
- O curso terá sempre uma parte ***expositiva*** e outra ***prática*** para fixação dos conceitos introduzidos.
 - Quizzes e exercícios envolvendo o uso dos algoritmos discutidos.


Objetivo do curso

- O objetivo principal do curso é apresentar
 - os conceitos fundamentais da teoria do aprendizado de máquina.
 - um conjunto de ferramentas (ou seja, algoritmos) de aprendizado de máquina para solução de problemas.
- Ao final do curso vocês devem ser capazes de
 - Entender e discutir sobre os principais algoritmos de ML.
 - Compreender a terminologia utilizada na área.
 - Aplicar algoritmos de ML para a resolução de problemas.
 - Analisar e entender novos algoritmos de ML.
 - Criar seus próprios projetos.



Critérios de Avaliação

- 2 trabalhos com peso de 85% cada.
 - Envolvendo questões teóricas e/ou práticas.
- 2 conjuntos de exercícios (quizzes e laboratórios) com peso de 15% cada.
 - Podem sempre ser entregues até a próxima aula.
 - Podem ser resolvidos em grupo, mas entregas devem ser individuais.
 - Exercícios serão atribuídos através de tarefas do MS Teams.
- **Frequência**
 - Gerada automaticamente pelo Teams.
 - Por favor, acompanhem suas presenças no portal.



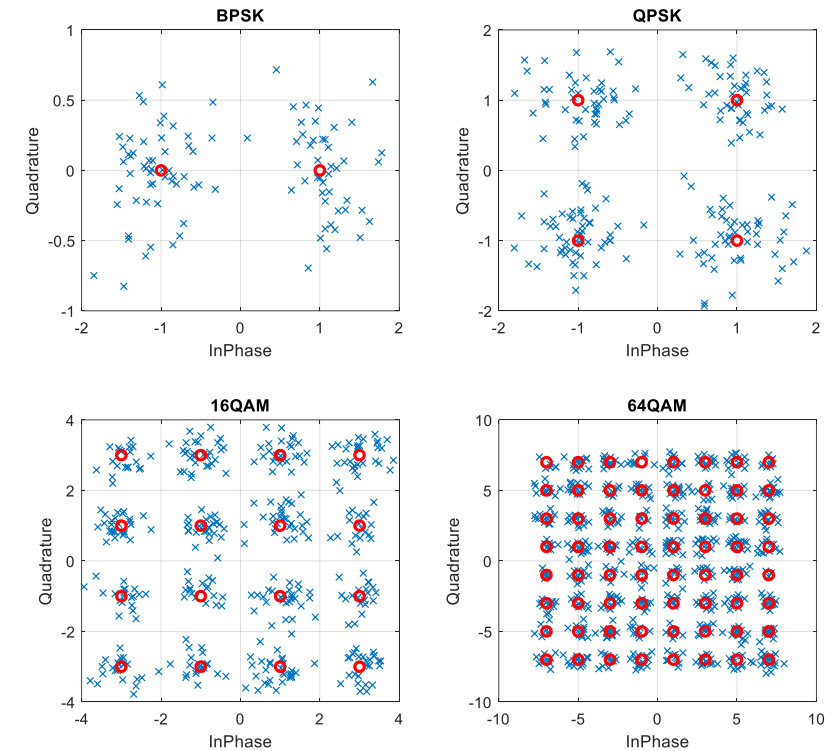

Referências

- [1] Stuart Russell and Peter Norvig, *“Artificial Intelligence: A Modern Approach,”* Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [2] Aurélien Géron, *“Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems”*, 1st ed., O'Reilly Media, 2017.
- [3] Joseph Misiti, *“Awesome Machine-Learning,”* on-line data base with several free and/or open-source books (<https://github.com/josephmisiti/awesome-machine-learning>).
- [4] Andriy Burkov, *“The Hundred-Page Machine-Learning Book,”* Andriy Burkov 2019.
- [5] C. M. Bishop, *“Pattern Recognition and Machine Learning,”* Springer, 1st ed., 2006.
- [6] S. Haykin, *“Neural Networks and Learning Machines,”* Prentice Hall, 3ª ed., 2008.
- [7] Coleção de livros:
<https://drive.google.com/drive/folders/1lylIMu1w6POBhrVnw11yqXXy6BjC439j?usp=sharing>

Avisos


- Entregas de exercícios (laboratórios e quizzes) devem ser feitas no MS Teams.
 - Se atentem às datas/horários de entrega.
- Todo material do curso será disponibilizado no MS Teams e no GitHub:
 - https://github.com/zz4fap/t320_aprendizado_de_maquina
- Horários de Atendimento
 - Professor: quintas-feiras das 18:30 às 19:30 e sextas-feiras das 15:30 às 16:30.
 - Monitor (Pedro Rezende: ***pedro_rafael@get.inatel.br***): Todas as sextas-feiras das 17:30 às 18:30.
 - Atendimento via MS Teams.

Motivação para tarefas de classificação



- Em alguns casos, nós precisamos encontrar funções, $f(x)$, que mapeiem os atributos de entrada em determinados valores discretos, ou seja, em classes.
Por exemplo
 - Classificação de emails entre SPAM e HAM (legítimo).
 - Classificação de objetos.
 - Detecção ou classificação de símbolos.
 - Classificação de modulações (QPSK, AM, FM, etc.)

Motivação para tarefas de classificação



- Reconhecimento de dígitos escritos à mão.
- Classificação de texto.
- Classificação de sentimentos.

Definição do problema de classificação

- **Problema:** encontrar uma função $f(\mathbf{x})$ que atribua a cada **exemplo de entrada**, \mathbf{x} , uma das Q classes possíveis, C_q , $q = 1, \dots, Q$ e a qual o exemplo pertence.
 - As classes podem ser
 - Spam e not spam (ham).
 - Dígitos de 0 a 9.
 - Símbolos de uma modulação específica.
 - Objetos (carros, cães, gatos, etc.)
- Semelhante ao problema da **regressão linear**, existe um conjunto de treinamento com N **exemplos** e **rótulos** $\{\mathbf{x}(i); y(i)\}_{i=0}^{N-1}$ que é utilizado para treinar um **classificador**, onde
 - $\mathbf{x}(i) = [x_1(i) \ \dots \ x_K(i)]^T \in \mathbb{R}^{K \times 1}$ representa o i -ésimo vetor exemplo de entrada, o qual é caracterizado por K atributos, $x_1(i), \dots, x_K(i)$
 - e $y(i)$ representa o i -ésimo **rótulo**.
- Portanto, como vocês já devem ter percebido, **classificadores** são algoritmos de **treinamento supervisionado**.

Representação da saída desejada

- A **saída desejada** de um classificador para um **exemplo de entrada**, $x(i)$ deve ser um valor que identifique a **classe** à qual $x(i)$ pertence.
- Sendo assim, a saída $\hat{y}(i)$ de um **classificador**, é uma variável **categórica** (ou seja, **discreta**).
- Portanto, para realizarmos o treinamento do **modelo de classificação**, devemos escolher uma **representação numérica** para a **saída desejada**, y .
- Assim, como veremos a seguir, duas opções podem ser adotadas, dependendo se a classificação é **binária** ou **multi-classes**.



Representação da saída desejada

- **Classificação binária:** existem apenas duas classes possíveis, C_1 e C_2 , onde C_1 é chamada de ***classe negativa*** e C_2 a ***classe positiva***.
- Portanto, nesse caso, podemos utilizar ***uma única saída escalar binária*** para indicar a ***classe*** correspondente ao ***exemplo de entrada***:

$$y(i) = \begin{cases} 0, & \mathbf{x}(i) \in C_1 \\ 1, & \mathbf{x}(i) \in C_2 \end{cases}.$$

- Assim, $y(i) \in \mathbb{R}^1$, de maneira que o classificador realiza um mapeamento $\mathbb{R}^K \rightarrow \mathbb{R}^1$, ou seja, $y = f(\mathbf{x})$, onde $\mathbf{x} \in \mathbb{R}^K$ e $y \in \mathbb{R}^1$.
- Também é possível utilizar $y(i) = -1$ para $\mathbf{x}(i) \in C_1$, ou seja

$$y(i) = \begin{cases} -1, & \mathbf{x}(i) \in C_1 \\ 1, & \mathbf{x}(i) \in C_2 \end{cases}.$$


Representação da saída desejada

- **Classificação multi-classes:** existem mais de 2 classes possíveis ($Q > 2$).
 - Geralmente, nesse caso, o classificador terá Q saídas.
 - Uma estratégia bastante utilizada para representar estas classes é conhecida como codificação **one-hot**.
- **Codificação one-hot:** utiliza uma representação **vetorial binária** para as saídas.
 - Ou seja, as saídas são vetores com o valor 1 no elemento representando a classe do exemplo de entrada e 0 nos demais elementos.
 - Nesse caso, o **classificador** possui **múltiplas saídas**, cada uma representando uma classe específica.
 - **Exemplo:** imaginemos um classificador de notícias com quatro classes possíveis: *esportes*, *política*, *ciências* e *variedades*. Como seria a representação com codificação **one-hot**?

$$\left. \begin{array}{lcl} \text{esportes:} & [1 & 0 & 0 & 0]^T \\ \text{política:} & [0 & 1 & 0 & 0]^T \\ \text{ciências:} & [0 & 0 & 1 & 0]^T \\ \text{variedades:} & [0 & 0 & 0 & 1]^T \end{array} \right\} \text{ Assim, } \mathbf{y}(i) \in \mathbb{R}^{Q \times 1}, \text{ de maneira} \\ \text{que o classificador realiza um} \\ \text{mapeamento } \mathbb{R}^K \rightarrow \mathbb{R}^Q.$$




Fronteiras de decisão de um classificador

- Antes, usávamos **funções hipótese** para aproximar um **modelo gerador**, agora, as usaremos para separar classes.
- Para facilitar o entendimento, vamos imaginar o **espaço bi-dimensional**, \mathbb{R}^2 , criado pelos **atributos** x_1 e x_2 .
- Esse espaço pode ser dividido em **regiões de decisão**, $R_i, i = 1, \dots, Q$, onde cada **região** corresponde a uma classe.
- As regiões de decisão são separadas por **fronteiras de decisão**.
- Uma **fronteira de decisão** corresponde a uma **superfície** (também chamada de **superfície de separação**) no **espaço de atributos** que separe as classes de forma ótima.



Fronteiras de decisão de um classificador

- As **superfícies de decisão** podem ser **lineares** (e.g., retas e planos) ou **não-lineares** (e.g., círculos).
- As **superfícies de decisão** são definidas por **funções** (lineares ou não) que separam as classes.
- Essas funções são normalmente chamadas de **funções discriminantes**, pois separam as classes.
- As figuras mostram **regiões de decisão** em problemas de classificação **binária** e **multi-classes**.



Funções discriminantes lineares

- Em geral, uma **função discriminante linear** pode ser escrita da seguinte forma

$$g(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2 + \dots + a_Kx_K = \mathbf{a}^T \mathbf{x},$$

que nada mais é do que uma **combinação linear dos pesos**, assim como nós vimos na regressão linear.


- $g(\mathbf{x})$ também pode ser vista como um **hiperplano** que separa as classes. Um **hiperplano** pode ser 1 ponto em 1D, uma reta em 2D, um plano em 3D, etc.

- O coeficiente a_0 (**bias**) dá o deslocamento com relação à origem.
- E o restante dos pesos determina a orientação do **hiperplano**.


- A ideia aqui é encontrar os pesos da **função discriminante** de tal forma que

$$C_q = \begin{cases} 1, & g(\mathbf{x}) < 0 \\ 2, & g(\mathbf{x}) > 0 \\ \text{uma ou outra,} & g(\mathbf{x}) = 0 \end{cases} \longrightarrow \text{Indeterminação: empate entre as classes.}$$

- OBS.: Como vimos anteriormente, podemos ter também **funções discriminantes não-lineares em relação aos atributos**, e.g., $g(\mathbf{x}) = a_0 + x_1^2 + x_2^2$ (eq. de um círculo centrado na origem).




Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$




- Analisem a figura.
- Temos 2 classes, 2 atributos, x_1 e x_2 , e queremos encontrar uma **função discriminante**, $g(\mathbf{x})$, que as separe.
- Qual formato deve ter esta **função discriminante**?
 - O formato mais simples (navalha de Occam) é o de uma reta.

Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$



- Visualmente, traçamos uma reta em uma posição que separe as classes da melhor forma possível.
- A **função discriminante** que representa esta reta é definida como
$$g(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2$$
- Agora que definimos uma função e sua posição no gráfico, precisamos encontrar os **pesos** e as **regiões de decisão**.

Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$



- Temos 3 incógnitas e 3 equações:
 - $(x_1 = 0, x_2 = 1) \rightarrow 0 = a_0 + a_2 \therefore a_0 = -a_2$
 - $(x_1 = 1, x_2 = 2) \rightarrow 0 = a_0 + a_1 + 2a_2 \therefore a_1 = -(a_0 + 2a_2)$
 - $(x_1 = 2, x_2 = 3) \rightarrow 0 = a_0 + 2a_1 + 3a_2 \therefore a_1 = -(a_0 + 3a_2)/2$
- Resolvendo o sistema, encontramos $a_0 = 1, a_1 = 1, a_2 = -1$, então
 - $g(\mathbf{x}) = 1 + x_1 - x_2$

Tarefas

- **Quiz:** “*T320 - Quiz - Classificação (Parte I)*” que se encontra no MS Teams.
- **Exercício Prático:** [Laboratório #1](#).
 - Pode ser baixado do MS Teams ou do GitHub.
 - Pode ser respondido através do link acima (na nuvem) ou localmente.
 - [Instruções para resolução e entrega dos laboratórios](#).
 - **Atividades podem ser feitas em grupo, mas as entregas devem ser individuais.**

Obrigado!

