


# T320 - Introdução ao Aprendizado de Máquina II: *Classificação (Parte I)*



***Inatel***



Felipe Augusto Pereira de Figueiredo  
felipe.figueiredo@inatel.br

# A disciplina

- Continuação de ***T319 - Introdução ao Aprendizado de Máquina I.***
- ***Curso introdutório*** onde veremos os conceitos básicos de funcionamento dos seguintes algoritmos de ***machine learning*** (ML):
  - Classificadores
    - Regressão Logística
    - Regressão Softmax
  - Redes Neurais
  - Clustering
    - k-Means
- O curso terá sempre uma parte ***expositiva*** e outra ***prática*** para fixação dos conceitos introduzidos.
  - Quizzes e exercícios envolvendo o uso dos algoritmos discutidos.


# Objetivo do curso

- O objetivo principal do curso é apresentar
  - os conceitos fundamentais da teoria do aprendizado de máquina.
  - um conjunto de ferramentas (ou seja, algoritmos) de aprendizado de máquina para solução de problemas.
- Ao final do curso vocês devem ser capazes de
  - Entender e discutir sobre os principais algoritmos de ML.
  - Compreender a terminologia utilizada na área.
  - Aplicar algoritmos de ML para a resolução de problemas.
  - Analisar e entender novos algoritmos de ML.
  - Criar projetos que envolvam ML.



# Critérios de Avaliação

- 2 trabalhos com peso de 85% cada.
  - Envolvendo questões teóricas e/ou práticas.
  - **Uma parte de cada trabalho será feita presencialmente.**
- 2 conjuntos de exercícios (quizzes e laboratórios) com peso de 15% cada.
  - Podem sempre ser entregues até a próxima aula.
  - Podem ser resolvidos em grupo, mas entregas devem ser individuais.
  - Exercícios serão atribuídos através de tarefas do MS Teams.
- **Frequência**
  - Gerada automaticamente pelo Teams.
  - Por favor, acompanhem a frequência no portal.



# Cronograma

| Aula | Data       | Dia    | Horário        | Atividade   |
|------|------------|--------|----------------|---|
| 1    | 30/7/2022  | Sábado | 08:00 às 09:40 | Introdução ao Aprendizado de Máquina                  |
| 2    | 6/8/2022   |        |                | Introdução ao Aprendizado de Máquina                  |
| 3    | 13/8/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 4    | 20/8/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 5    | 27/8/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 6    | 3/9/2022   |        |                | Introdução ao Aprendizado de Máquina                  |
| 7    | 10/9/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 8    | 17/9/2022  |        |                | <b>Avaliação Presencial I (Projeto I – Parte I)</b>   |
| 9    | 24/9/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 10   | 1/10/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 11   | 8/10/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 12   | 15/10/2022 |        |                | Introdução ao Aprendizado de Máquina                  |
| 13   | 22/10/2022 |        |                | Introdução ao Aprendizado de Máquina                  |
| 14   | 29/10/2022 |        |                | Introdução ao Aprendizado de Máquina                  |
| 15   | 5/11/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 16   | 12/11/2022 |        |                | <b>Avaliação Presencial II (Projeto II – Parte I)</b> |
| 17   | 19/11/2022 |        |                | Introdução ao Aprendizado de Máquina                  |
| 18   | 26/11/2022 |        |                | Introdução ao Aprendizado de Máquina                  |
| 19   | 3/12/2022  |        |                | Introdução ao Aprendizado de Máquina                  |
| 20   | 10/12/2022 |        |                | Introdução ao Aprendizado de Máquina                  |

# Referências


- [1] Stuart Russell and Peter Norvig, *“Artificial Intelligence: A Modern Approach,”* Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [2] Aurélien Géron, *“Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems”*, 1st ed., O'Reilly Media, 2017.
- [3] Joseph Misiti, *“Awesome Machine-Learning,”* on-line data base with several free and/or open-source books (<https://github.com/josephmisiti/awesome-machine-learning>).
- [4] Andriy Burkov, *“The Hundred-Page Machine-Learning Book,”* Andriy Burkov 2019.
- [5] C. M. Bishop, *“Pattern Recognition and Machine Learning,”* Springer, 1st ed., 2006.
- [6] S. Haykin, *“Neural Networks and Learning Machines,”* Prentice Hall, 3ª ed., 2008.
- [7] Coleção de livros:  
<https://drive.google.com/drive/folders/1lylIMu1w6POBhrVnw11yqXXy6BjC439j?usp=sharing>

# Avisos


- Entregas de exercícios (laboratórios e quizzes) devem ser feitas no MS Teams.
  - Se atentem às datas e horários de entrega.
- Todo material do curso será disponibilizado no MS Teams e no GitHub:
  - <https://github.com/zz4fap/t320> aprendizado de maquina
- Horários de Atendimento
  - Professor: quintas-feiras das 18:00 às 19:00 e sextas-feiras das 16:00 às 17:00.
  - Monitor (Maycol teles: **maycol.teles@ges.inatel.br**): quartas-feiras das 18:30 às 19:30.
  - Atendimento remoto via MS Teams.

# Classificação

- Tarefa (ou problema) de aprendizado supervisionado.
  - As saídas esperadas são conhecidas.
- Envolve encontrar uma função,  $f(x)$ , que mapeie os atributos de entrada em **valores discretos**, ou seja, em classes.



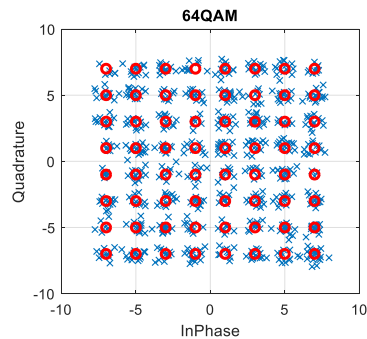

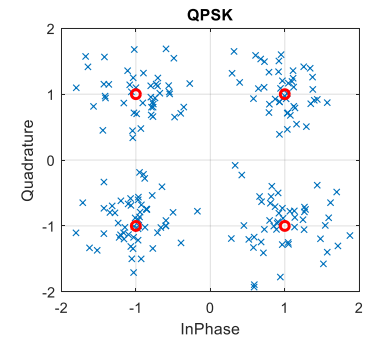

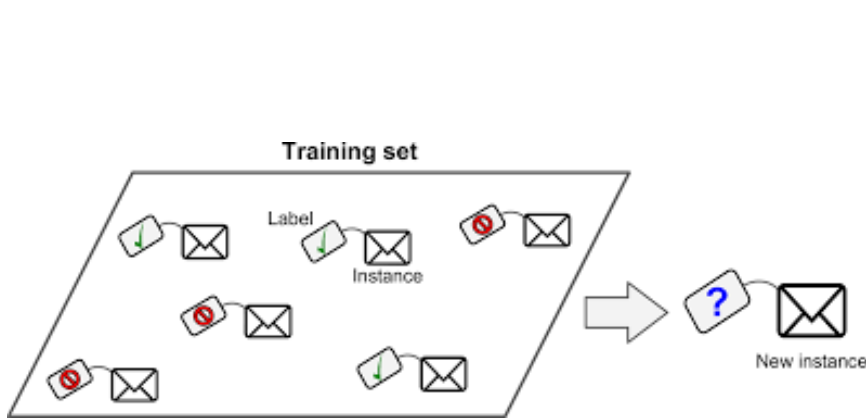
$f(x)$  **aproxima** os dados.



$f(x)$  **separa** os dados.




# Motivação para tarefas de classificação



- Classificação de emails entre SPAM e HAM (legítimo).
- Classificação de objetos.
- Detecção ou classificação de símbolos.
- Classificação de modulações (QPSK, AM, FM, etc.).

# Motivação para tarefas de classificação



- Reconhecimento de texto escrito à mão.
- Classificação de texto.
- Classificação de sentimentos.

# Definição do problema de classificação

- **Problema:** encontrar uma função  $f(\mathbf{x})$  que atribua a cada **exemplo de entrada**,  $\mathbf{x}$ , uma das  $Q$  classes possíveis,  $C_q$ ,  $q = 1, \dots, Q$  e a qual o exemplo pertence.
  - Por exemplo, as classes podem ser
    - Spam e ham (legítimo).
    - Dígitos de 0 a 9.
    - Símbolos de uma modulação específica.
    - Objetos (carros, barcos, cães, gatos, etc.)
- Semelhante ao problema da **regressão linear**, existe um conjunto de treinamento com  $N$  pares de **vetores de atributos** e **rótulos**  $\{\mathbf{x}(i); y(i)\}_{i=0}^{N-1}$  que é utilizado para treinar um **classificador**, onde
  - $\mathbf{x}(i) = [x_1(i) \ \dots \ x_K(i)]^T \in \mathbb{R}^{K \times 1}$  representa o  $i$ -ésimo vetor de atributos, o qual é composto por  $K$  atributos,  $x_1(i), \dots, x_K(i)$
  - e  $y(i)$  representa o  $i$ -ésimo **rótulo**.
- Portanto, como vocês já devem ter percebido, **classificadores** são algoritmos de **treinamento supervisionado**.

# Representação da saída desejada

- A **saída desejada** de um classificador para um **vetor de atributos**,  $x(i)$  deve ser um valor que identifique a **classe** à qual  $x(i)$  pertence.
- Sendo assim, a saída  $\hat{y}(i)$  de um **classificador**, é uma variável **categórica** (ou seja, **discreta**).
- Portanto, para realizarmos o treinamento do **modelo de classificação**, devemos escolher uma **representação numérica** para a **saída**,  $y$ .
- Assim, como veremos a seguir, duas opções podem ser adotadas, dependendo se a classificação é **binária** ou **multi-classes**.



# Representação da saída desejada

- **Classificação binária:** existem apenas duas classes possíveis,  $C_1$  e  $C_2$ , onde  $C_1$  é chamada de ***classe negativa*** e  $C_2$  a ***classe positiva***.
- Portanto, nesse caso, podemos utilizar ***uma única saída escalar binária*** para indicar a ***classe*** correspondente ao ***vetor de atributos de entrada***:

$$y(i) = \begin{cases} 0, & \mathbf{x}(i) \in C_1 \\ 1, & \mathbf{x}(i) \in C_2 \end{cases}.$$

- Assim,  $y(i) \in \mathbb{R}^1$ , de maneira que o classificador realiza um mapeamento  $\mathbb{R}^{K \times 1} \rightarrow \mathbb{R}^1$ , ou seja,  $y = f(\mathbf{x})$ , onde  $\mathbf{x} \in \mathbb{R}^{K \times 1}$  e  $y \in \mathbb{R}^1$ .
- Também é possível utilizar  $y(i) = -1$  para  $\mathbf{x}(i) \in C_1$ , ou seja

$$y(i) = \begin{cases} -1, & \mathbf{x}(i) \in C_1 \\ 1, & \mathbf{x}(i) \in C_2 \end{cases}.$$


# Representação da saída desejada

- **Classificação multi-classes:** existem mais de 2 classes possíveis ( $Q > 2$ ).
  - Geralmente, nesse caso, o classificador terá  $Q$  saídas.
  - Uma estratégia bastante utilizada para representar estas classes é conhecida como codificação **one-hot**.
- **Codificação one-hot:** utiliza uma representação **vetorial binária** para as saídas.
  - Ou seja, as saídas são vetores com o valor 1 no elemento representando a classe do exemplo de entrada e 0 nos demais elementos.
  - Nesse caso, o **classificador** possui **múltiplas saídas**, cada uma representando uma classe específica.
  - **Exemplo:** imaginemos um classificador de notícias com quatro classes possíveis: *esportes*, *política*, *ciências* e *variedades*. Como seria a representação com codificação **one-hot**?

$$\left. \begin{array}{l} \text{esportes:} \\ \text{política:} \\ \text{ciências:} \\ \text{variedades:} \end{array} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}^T \right\} \text{ Assim, } \mathbf{y}(i) \in \mathbb{R}^{Q \times 1}, \text{ de maneira} \\ \text{que o classificador realiza um} \\ \text{mapeamento } \mathbb{R}^{K \times 1} \rightarrow \mathbb{R}^{Q \times 1}.$$




# Fronteiras de decisão de um classificador

- Antes, usávamos **funções hipótese** para aproximar um **modelo gerador**, agora, as usaremos para separar classes.
- Para facilitar o entendimento, vamos imaginar o **espaço bi-dimensional**,  $\mathbb{R}^2$ , criado pelos **atributos**  $x_1$  e  $x_2$ .
- Esse espaço pode ser dividido em **regiões de decisão**,  $R_i, i = 1, \dots, Q$ , onde cada **região** corresponde a uma classe.
- As regiões de decisão são separadas por **fronteiras de decisão**.
- Uma **fronteira de decisão** corresponde a uma **superfície** (também chamada de **superfície de separação**) no **espaço de atributos** que separe as classes de forma ótima.



# Fronteiras de decisão de um classificador

- As **superfícies de decisão** podem ser **lineares** (e.g., retas e planos) ou **não-lineares** (e.g., círculos).
- As **superfícies de decisão** são definidas por **funções** (lineares ou não) que separam as classes.
- Essas funções são normalmente chamadas de **funções discriminantes**, pois separam as classes.
- As figuras mostram **regiões de decisão** em problemas de classificação **binária** e **multi-classes**.





# Funções discriminantes lineares

- Em geral, uma **função discriminante linear** pode ser escrita da seguinte forma

$$g(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2 + \dots + a_Kx_K = \mathbf{a}^T \mathbf{x},$$

que nada mais é do que uma **combinação linear dos pesos**, assim como nós vimos em regressão linear.


- $g(\mathbf{x})$  também pode ser vista como um **hiperplano** que separa as classes. Um **hiperplano** pode ser 1 ponto em 1D, uma reta em 2D, um plano em 3D, etc.

- O coeficiente  $a_0$  (**bias**) dá o deslocamento com relação à origem.
- E o restante dos pesos determina a orientação do **hiperplano**.


- A ideia aqui é encontrar os pesos da **função discriminante** de tal forma que

$$C_q = \begin{cases} 1, & g(\mathbf{x}) < 0 \\ 2, & g(\mathbf{x}) > 0 \\ \text{uma ou outra,} & g(\mathbf{x}) = 0 \end{cases} \longrightarrow \text{Indeterminação: empate entre as classes.}$$

- OBS.: Como vimos anteriormente, podemos ter também **funções discriminantes não-lineares em relação aos atributos**, e.g.,  $g(\mathbf{x}) = a_0 + x_1^2 + x_2^2$  (eq. de um círculo centrado na origem, onde  $a_0 = -r^2$ ).




# Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$




- Analisem a figura.
- Temos 2 classes, 2 atributos,  $x_1$  e  $x_2$ , e queremos encontrar uma **função discriminante**,  $g(\mathbf{x})$ , que as separe.
- Qual formato deve ter esta **função discriminante**?
  - O formato mais simples (navalha de Occam) é o de uma reta.

# Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$



- Visualmente, traçamos uma reta em uma posição que separe as classes da melhor forma possível.
- A **função discriminante** que representa esta reta é definida como
$$g(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2$$
- Agora que definimos uma função e sua posição no gráfico, precisamos encontrar os **pesos** e as **regiões de decisão**.

# Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$



- Temos 3 incógnitas e 3 equações:
  - $(x_1 = 0, x_2 = 1) \rightarrow 0 = a_0 + a_2 \therefore a_0 = -a_2$
  - $(x_1 = 1, x_2 = 2) \rightarrow 0 = a_0 + a_1 + 2a_2 \therefore a_1 = -(a_0 + 2a_2)$
  - $(x_1 = 2, x_2 = 3) \rightarrow 0 = a_0 + 2a_1 + 3a_2 \therefore a_1 = -(a_0 + 3a_2)/2$
- Resolvendo o sistema, encontramos  $a_0 = 1, a_1 = 1, a_2 = -1$ , então
  - $g(\mathbf{x}) = 1 + x_1 - x_2$

# Tarefas

- **Quiz:** “*T320 - Quiz - Classificação (Parte I)*” que se encontra no MS Teams.
- **Exercício Prático:** Laboratório #1.
  - Pode ser baixado do MS Teams ou do GitHub.
  - Pode ser respondido através do link acima (na nuvem) ou localmente.
  - [Instruções para resolução e entrega dos laboratórios](#).
  - **Atividades podem ser feitas em grupo, mas as entregas devem ser individuais.**

Obrigado!

