


# T320 - Introdução ao Aprendizado de Máquina II: *Classificação (Parte I)*



**Inatel**



Felipe Augusto Pereira de Figueiredo  
[felipe.figueiredo@inatel.br](mailto:felipe.figueiredo@inatel.br)

# A disciplina

- Continuação de ***T319 - Introdução ao Aprendizado de Máquina I.***
- ***Curso introdutório*** onde veremos os conceitos básicos de funcionamento dos seguintes algoritmos de ***machine learning*** (ML):
  - Classificadores
    - Regressão logística
    - Regressão softmax
  - Redes Neurais
  - Clustering
    - k-Means
- O curso terá sempre uma parte ***expositiva*** e outra ***prática*** para fixação dos conceitos introduzidos.
  - Quizzes e laboratórios envolvendo os conceitos discutidos.

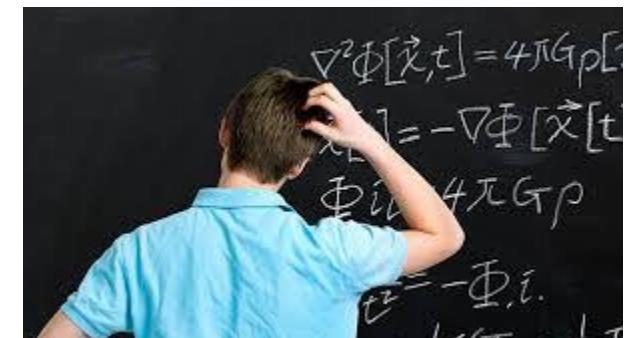
# Objetivo do curso

- O objetivo principal do curso é apresentar
  - os **conceitos fundamentais** da teoria do aprendizado de máquina.
  - um **conjunto de ferramentas** (i.e., algoritmos, métricas, técnicas) de aprendizado de máquina para solução de problemas.
- Ao final do curso vocês devem ser capazes de
  - Entender e discutir sobre os principais algoritmos de ML.
  - Compreender a terminologia utilizada na área.
  - Entender o funcionamento de novos algoritmos de ML.
  - Aplicar algoritmos de ML para a resolução de problemas.



# Critérios de Avaliação

- **Dois (2) trabalhos em grupo** com peso de 85% cada.
  - Envolvem questões práticas e/ou teóricas.
  - **Uma parte de cada trabalho será feita presencialmente.**
- Dois (2) conjuntos de exercícios (**quizzes e laboratórios**) com peso de 15% cada.
  - Podem ser resolvidos em grupos de no máximo 3 alunos.
  - Exercícios serão atribuídos e entregues através do MS Teams.
- Extra: 10% da nota da FETIN na segunda nota.
  - O trabalho precisa usar IA.
- **Frequência**
  - Gerada automaticamente pelo Teams.
  - Por favor, acompanhem suas frequências no portal.



# Cronograma

Aula	Data	Dia	Horário	Atividade
1	14/2/2026			Introdução ao Aprendizado de Máquina
2	21/2/2026			Introdução ao Aprendizado de Máquina
3	28/2/2026			Introdução ao Aprendizado de Máquina
4	7/3/2026			Introdução ao Aprendizado de Máquina
5	14/3/2026			Introdução ao Aprendizado de Máquina
6	21/3/2026			Introdução ao Aprendizado de Máquina
7	28/3/2026			Introdução ao Aprendizado de Máquina
8	4/4/2026*			Introdução ao Aprendizado de Máquina
9	11/4/2026			Introdução ao Aprendizado de Máquina
10	18/4/2026			Introdução ao Aprendizado de Máquina
11	25/4/2026			Introdução ao Aprendizado de Máquina
12	2/5/2026	Sábado	10:00 às 11:40	<b>Avaliação Presencial I (Projeto I) (Sala I-??)</b>
13	9/5/2026			Introdução ao Aprendizado de Máquina
14	16/5/2026			Introdução ao Aprendizado de Máquina
15	23/5/2026*			Introdução ao Aprendizado de Máquina
16	30/5/2026			Introdução ao Aprendizado de Máquina
17	6/6/2026			<b>Avaliação Presencial II (Projeto II) (Sala I-??)</b>
18	13/6/2026			Introdução ao Aprendizado de Máquina
19	20/6/2026			Introdução ao Aprendizado de Máquina
20	27/6/2026			Introdução ao Aprendizado de Máquina

\*Feriados (as reposições serão assíncronas)

# Referências


- [1] Stuart Russell e Peter Norvig, “*Artificial Intelligence: A Modern Approach*,” Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [2] Aurélien Géron, “*Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*”, 1st ed., O'Reilly Media, 2017.
- [3] Levy Boccato, “Notas de aula do curso Tópicos em Sistemas Inteligentes II - Aprendizado de Máquina” (IA006), disponíveis em [https://www.dca.fee.unicamp.br/~lboccato/ia006\\_2s2019.html](https://www.dca.fee.unicamp.br/~lboccato/ia006_2s2019.html) (2019).
- [4] Joseph Misiti, “*Awesome Machine-Learning*,” on-line data base with several free and/or open-source books (<https://github.com/josephmisiti/awesome-machine-learning>).
- [5] C. M. Bishop, “*Pattern Recognition and Machine Learning*,” Springer, 1st ed., 2006.
- [6] Coleção de livros, <https://tinyurl.com/mp64ksye>

# Avisos


- Toda nossa comunicação será feita via Teams.
- Todas as aulas serão gravadas e ficarão disponíveis na pasta “Recordings”.
- Todo material do curso está disponível no GitHub:
  - [https://github.com/zz4fap/t320\\_aprendizado\\_de\\_maquina](https://github.com/zz4fap/t320_aprendizado_de_maquina)
- Entregas de aboratórios e quizzes devem ser feitas através do Teams.
  - Se atentem às datas e horários de entrega das atividades.
- Vídeos do minicurso de Python e de como usar o Colab estão na pasta "Recordings".
- Horários de atendimento
  - Professor: sextas-feiras das 18:30 às 19:30.
  - Monitor (Marcus Wilians Gomes Chagas: [marcuswilians@gea.inatel.br](mailto:marcuswilians@gea.inatel.br)): todas as terças-feiras das 17:30 às 19:30.
  - **Atendimento remoto via Teams.**

# Classificação

- Tarefa (ou problema) de **aprendizado supervisionado**.
  - As saídas esperadas (rótulos) são conhecidas.
- Envolve encontrar uma função,  $f(x)$ , que **mapeie** os atributos de entrada em um **conjunto finito de valores discretos**, ou seja, em classes.


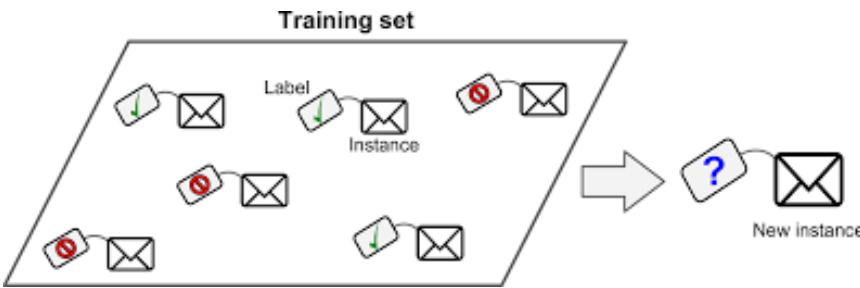


$f(x)$  captura o **comportamento geral** dos dados.



$f(x)$  forma uma **fronteira de decisão**.

# Tarefas de classificação




- Classificação de emails entre *spam* e *ham* (legítimo).
- Classificação de objetos em imagens ou vídeos.
- Detecção ou classificação de símbolos de modulações digitais.
- Classificação de modulações (QPSK, AM, FM, etc.).

# Tarefas de classificação

0 0 0 0 0 0 0 0 0 0 0 0 0  
1 1 1 1 1 1 1 1 1 1 1 1 1  
2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2  
3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3  
4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4  
5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5  
6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6  
7 7 7 7 7 7 7 7 7 7 7 7 7 7 7 7 7  
8 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8  
9 9 9 9 9 9 9 9 9 9 9 9 9 9 9 9 9



- Reconhecimento de texto.
- Classificação de texto (e.g., notícias).
- Classificação de sentimentos.
- Classificação de doenças (e.g., pulmonares).



# Definição do problema de classificação

- **Problema:** encontrar uma função,  $f(\mathbf{x})$ , que atribua a um *exemplo de entrada*,  $\mathbf{x}$ , uma de  $Q$  classes possíveis, as quais denotaremos como  $C_q, q = 1, \dots, Q$ .
  - Por exemplo, as classes podem ser
    - *Spam* e *ham* (legítimo):  $Q = 2$ .
    - Dígitos de 0 a 9:  $Q = 10$ .
    - Símbolos de uma modulação específica (e.g., QPSK:  $Q = 4$ ).
    - Objetos (carros, barcos, cães, gatos, etc.)
- Semelhante ao problema da *regressão linear*, existe um conjunto de treinamento com  $N$  pares de *vetores de atributos* e *rótulos*  $\{\mathbf{x}(i); y(i)\}_{i=0}^{N-1}$  que é utilizado para treinar um *classificador*, onde
  - $\mathbf{x}(i) = [x_1(i) \ \cdots \ x_K(i)]^T \in \mathbb{R}^{K \times 1}$  representa o  $i$ -ésimo vetor de atributos, o qual é composto por  $K$  atributos,  $x_1(i), \dots, x_K(i)$ ;
  - e  $y(i)$  representa o  $i$ -ésimo *rótulo*.

# Como representar a saída desejada?



- A *saída desejada* (i.e., *rótulo*) de um classificador para um *vetor de atributos*,  $x(i)$ , deve ser um **valor que identifique** a qual *classe* o vetor  $x(i)$  pertence.
- Sendo assim, a *saída* de um *classificador* é uma **variável categórica** (i.e., *valor discreto pertencente a um conjunto finito de valores*).

# Como representar a saída desejada?



- Portanto, para realizarmos o treinamento do ***modelo de classificação***, nós devemos escolher uma ***representação numérica*** para as ***saídas desejadas***.
- Assim, como veremos a seguir, duas opções podem ser adotadas, dependendo se a classificação é ***binária*** ( $Q = 2$ ) ou ***multi-classes*** ( $Q > 2$ ).

# Representação da saída desejada

- **Classificação binária** ( $Q = 2$ ): existem apenas duas classes possíveis,  $C_1$  e  $C_2$ , onde  $C_1$  é chamada de **classe negativa** e  $C_2$  de **classe positiva**.
- Portanto, nesse caso, o classificador possui **uma única saída escalar binária** para indicar a **classe** correspondente ao **vetor de atributos**:

$$y(i) = \begin{cases} 0, & x(i) \in C_1 \\ 1, & x(i) \in C_2 \end{cases}.$$


- Assim,  $y(i) \in \mathbb{R}^1$  (**escalar**), de maneira que **o classificador realiza um mapeamento**  $\mathbb{R}^{K \times 1} \rightarrow \mathbb{R}^1$ , i.e.,  $y(i) = f(x(i))$ , onde  $x(i) \in \mathbb{R}^{K \times 1}$ .
- Também é possível utilizar  $y(i) = -1$  para  $x(i) \in C_1$ , ou seja

$$y(i) = \begin{cases} -1, & x(i) \in C_1 \\ 1, & x(i) \in C_2 \end{cases}.$$

# Representação da saída desejada



- **Classificação multi-classes:** existem mais de 2 classes possíveis ( $Q > 2$ ).
- Uma estratégia bastante utilizada para representar estas classes é conhecida como *codificação one-hot*.




# Representação da saída desejada

- **Codificação one-hot:** saídas são representadas por *vetores binários*.
  - As saídas são vetores com comprimento  $Q$  com o valor 1 no elemento que representa a classe do exemplo de entrada e 0 nos demais elementos.
  - Nesse caso, o *classificador possui múltiplas saídas* ( $Q$  saídas), cada uma representando uma classe específica.
  - **Exemplo:** imaginemos um *classificador de notícias* com quatro classes possíveis: *esportes*, *política*, *ciências* e *variedades*.
  - Como seria a representação com a codificação **one-hot**?

$$\left. \begin{array}{ll} \text{esportes:} & [1 \quad 0 \quad 0 \quad 0]^T \\ \text{política:} & [0 \quad 1 \quad 0 \quad 0]^T \\ \text{ciências:} & [0 \quad 0 \quad 1 \quad 0]^T \\ \text{variedades:} & [0 \quad 0 \quad 0 \quad 1]^T \end{array} \right\}$$


Assim,  $y(i) \in \mathbb{R}^{Q \times 1}$ , de maneira que o *classificador realiza um mapeamento*  $\mathbb{R}^{K \times 1} \rightarrow \mathbb{R}^{Q \times 1}$ .

# Fronteiras de decisão de um classificador



- Antes, nós usávamos **funções hipótese** para **aproximar o comportamento de um conjunto de dados**, agora, as usaremos para **separar grupos de dados (i.e., classes)**.
- Para facilitar o entendimento, vamos imaginar o **espaço bi-dimensional**,  $\mathbb{R}^2$ , criado pelos **atributos**  $x_1$  e  $x_2$ , mostrado na figura ao lado.
- Os **pares de atributos** pertencem a duas classes ( $Q = 2$ ):
  - Círculos azuis pertencem à classe  $C_1$ .
  - Triângulos vermelhos pertencem à classe  $C_2$ .




# Fronteiras de decisão de um classificador




- Esse espaço pode ser dividido em **duas regiões de decisão**,  $R_1$  e  $R_2$ , onde **cada região** corresponde a **uma classe**.
- As regiões de decisão são separadas por **fronteiras de decisão**, que nada mais são do que **funções**.
- Na figura, como  $Q = 2$ , temos apenas uma fronteira de decisão.
- Uma **fronteira de decisão** corresponde a uma **superfície de separação** (1D, 2D, 3D, etc.) no **espaço de atributos** que separa as classes.

# Fronteiras de decisão de um classificador

- As *superfícies de separação* podem ser *lineares* (e.g., retas e planos) ou *não-lineares* (e.g., círculos e elipses).
- *Superfícies de separação* são *funções* (lineares ou não) que separam as classes.
- Essas funções são chamadas de *funções discriminantes*, pois separam as classes.
- As figuras abaixo mostram *regiões de separação* em problemas de classificação *binária* e *multi-classes*.




# Funções discriminantes



- Uma *função discriminante* com formato de **hiperplano** é dada por 
$$g(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2 + \cdots + a_Kx_K = \mathbf{a}^T \mathbf{x}$$
.
- Um **hiperplano** pode ser 1 ponto em 1D, uma reta em 2D, um plano em 3D, etc.
  - O coeficiente  $a_0$  (**bias**) dá o deslocamento com relação à origem.
  - O restante dos pesos determina a orientação do **hiperplano**.
- Lembrem-se que **hiperplanos** fazem *mapeamentos lineares* dos atributos nas saídas.

# Funções discriminantes



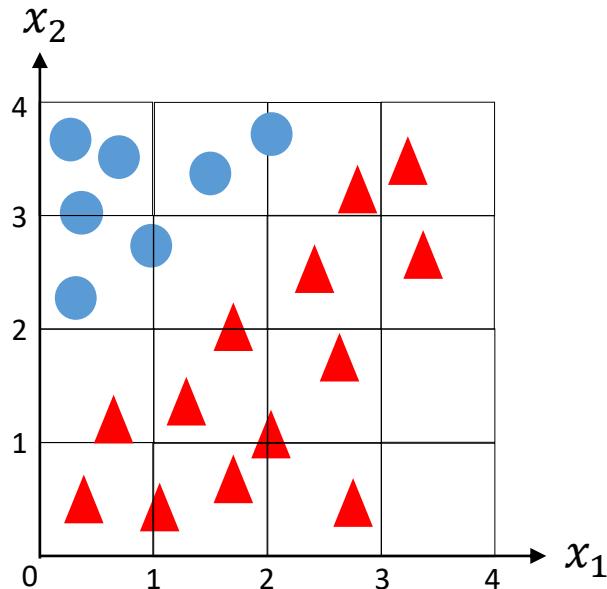
- Nosso **objetivo é encontrar os pesos da função discriminante** de tal forma que a classe atribuída a um exemplo de entrada,  $x$ , seja:

$$C_q = \begin{cases} q = 1, & g(x) < 0 \\ q = 2, & g(x) > 0 \\ \text{indeterminação}, & g(x) = 0 \end{cases}$$

Acima da função.  
Abaixo da função.  
empate entre as classes, pois a amostra está sobre a função.

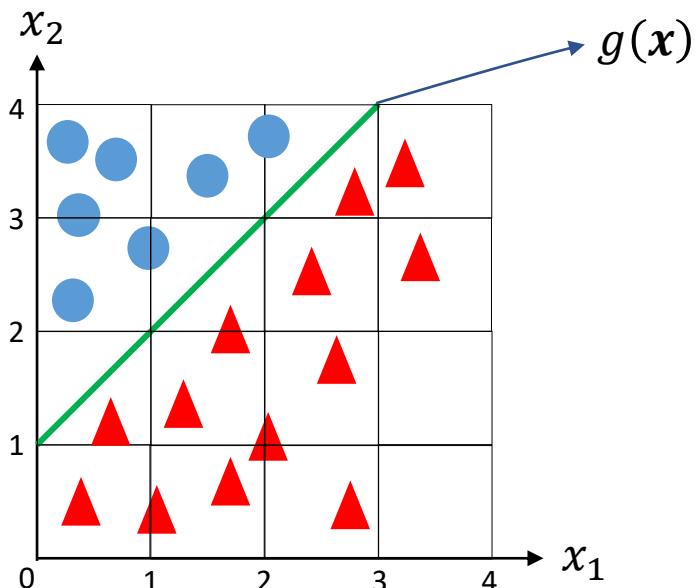
- OBS.: Podemos usar também **funções discriminantes com mapeamentos não-lineares**.
  - Exemplo:  $g(x) = a_0 + x_1^2 + x_2^2$  (eq. de um círculo centrado na origem, onde  $a_0 = -r^2$ ).

# Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$




- Analisem a figura ao lado.
- Temos 2 classes, 2 atributos,  $x_1$  e  $x_2$ , e queremos encontrar uma **função discriminante**,  $g(\mathbf{x})$ , que as separe.
- Qual formato deve ter esta **função discriminante** para que ela tenha boa capacidade de generalização?
  - Lembrem-se do princípio da navalha de Occam: *a explicação mais simples (i.e., menos complexa) é geralmente a mais provável de estar correta.*

# Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$




- Qual formato deve ter esta **função discriminante** para que ela tenha boa capacidade de generalização?
  - O formato mais simples, seguindo o princípio da navalha de Occam, é o de uma **reta** traçada no plano formado por  $x_1$  e  $x_2$ .

# Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$




- **Visualmente**, nós traçamos a reta em uma posição que separe as classes da melhor forma possível.
- A **função discriminante** que representa esta reta é definida como
$$g(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2 \quad (\text{plano})$$
- Agora que definimos o formato da função e sua posição no gráfico, precisamos **encontrar os pesos** e, com isso, **definir as regiões de decisão**.
- Como podemos encontrar os pesos?

# Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$



- Se temos 3 incógnitas, precisamos de um sistema com 3 equações:
  - $(x_1 = 0, x_2 = 1) \rightarrow 0 = a_0 + a_2 \therefore a_0 = -a_2$
  - $(x_1 = 1, x_2 = 2) \rightarrow 0 = a_0 + a_1 + 2a_2 \therefore a_1 = -(a_0 + 2a_2)$
  - $(x_1 = 2, x_2 = 3) \rightarrow 0 = a_0 + 2a_1 + 3a_2 \therefore a_1 = -(a_0 + 3a_2)/2$
- Resolvendo o sistema, encontramos  $a_0 = 1$ ,  $a_1 = 1$ ,  $a_2 = -1$ , então
  - $g(\mathbf{x}) = 1 + x_1 - x_2$

# Exemplo: Encontrando os pesos da função discriminante, $g(\mathbf{x})$



- Vamos definir as **regiões de decisão** substituindo alguns valores em  $g(\mathbf{x}) = 1 + x_1 - x_2$ .
  - $x_1 = 1$  e  $x_2 = 1$  resulta em  $g(\mathbf{x}) > 0$ .
    - ✓ Região da classe **positiva**,  $C_2$ .
  - $x_1 = 1$  e  $x_2 = 3$  resulta em  $g(\mathbf{x}) < 0$ .
    - ✓ Região da classe **negativa**,  $C_1$ .
  - $x_1 = 1$  e  $x_2 = 2$  resulta em  $g(\mathbf{x}) = 0$ .
    - ✓ **Indeterminação**: não podemos afirmar a qual classe o exemplo pertence.
    - ✓ Podemos atribuir arbitrariamente a uma das duas classes, escolher a classe que possui maior número de exemplos ou a mais frequente.
- O classificador pode ser implementado como uma **estrutura de controle de fluxo**.

# Tarefas

- **Quiz:** “*T320 - Quiz - Classificação (Parte I)*” que se encontra no MS Teams.
- **Exercício Prático:** Laboratório #1.
  - Pode ser acessado através do link acima (Google Colab) ou no GitHub.
  - Se atentem aos prazos de entrega.
  - Instruções para resolução e entrega dos laboratórios.

Obrigado!

