



T320 - Introdução ao Aprendizado de Máquina II: *Classificação (Parte II)*



Recapitulando


- Anteriormente, vimos alguns exemplos de aplicação de algoritmos de ***classificação***:
 - Detecção de spam.
 - Análise de sentimentos.
 - Reconhecimento de objetos, faces, letras/dígitos.
- Definimos o problema da classificação e discutimos que ele também é um problema de ***aprendizado supervisionado***.
- Aprendemos que as classes são separadas através de ***funções discriminantes*** e que o desafio é encontrar funções adequadas e seus respectivos pesos.
- A partir desta aula, começaremos a discutir como encontrar os pesos.

Classificação linear



- Como vimos, o objetivo da **classificação** é usar vetores de atributos, $\mathbf{x}$, de, por exemplo, um e-mail ou uma imagem, para **identificar** a qual **classe** ele pertence.

Classificação linear



- Um **classificador linear** atinge esse objetivo **tomando uma decisão** (e.g., os **ifs** e **elses**) **com base** no valor de **combinações lineares dos atributos em relação a alguns pesos**, i.e., na saída de uma ou mais **funções discriminantes lineares**.
- Ou seja, com base nos valores das funções discriminantes, o classificador deve retornar um **valor de um conjunto finito e discreto**.

Classificação linear

- Portanto, a saída de um **classificador linear** é dada pela função $h_a(\mathbf{x})$, chamada de **função hipótese de classificação**


$$\hat{y} = h_a(\mathbf{x}) = f(g(\mathbf{x})) = f\left(\sum_{k=0}^K a_k x_k\right) = f(\mathbf{a}^T \mathbf{x}),$$

produto
escalar


onde, $\mathbf{x} = [1, x_1, \dots, x_K]^T$ é o vetor de atributos com o primeiro elemento sendo o atributo de *bias*, $x_0 = 1$, e $f(\cdot)$ é uma **função de limiar de decisão**.

- **Função de limiar de decisão** é uma função que **mapeia** a saída da **função discriminante linear**, $g(\mathbf{x})$, em uma das Q possíveis classes C_q , $q = 1, \dots, Q$.
- Ela é apenas uma **formalização matemática** para os **ifs** e **elses** que usamos no exemplo para decidir as classes dos atributos.
- OBS.: Na **teoria original** da classificação linear, as **funções discriminantes** seguiam equações de **hiperplanos**: $\sum_{k=0}^K a_k x_k$.

Classes linearmente separáveis




Classes linearmente separáveis.




Classes não-linearmente separáveis.

- Dado um **conjunto de treinamento**, a tarefa do **classificador** é a de **aprender** uma **função hipótese de classificação**, $h_a(x)$, que receba um exemplo de entrada (e.g., x_1 e x_2) e retorne a classe do exemplo.
- Para que um **classificador linear** aprenda uma boa separação, as classes devem ser **linearmente separáveis**.
- Isso significa que as classes devem ser **suficientemente separadas** umas das outras para garantir que a **superfície de decisão** seja um **hiperplano**.

Classes linearmente separáveis





Classes linearmente separáveis.



Classes não-linearmente separáveis.

- Classes que podem ser separadas por um **hiperplano** são chamadas de **linearmente separáveis**.
- Na primeira figura, a **fronteira de decisão** é definida por um **hiperplano**, i.e., uma reta.
- Na segunda figura, devido à disposição das classes, não existe um **hiperplano** que as separe.
- **Originalmente**, **classificação linear** é usada quando as classes podem ser separadas por **hiperplanos**: $\sum_{k=0}^K a_k x_k$.


Classificação não-linear



- Mas e se não pudermos separar as classes com um **hiperplano**, ou seja, se elas não forem **linearmente separáveis**?
- Nestes casos, usamos **polinômios**.
- Os polinômios podem fazer **mapeamentos não lineares dos atributos no valor de saída**:
 - $g(\mathbf{x}) = (x_1 - a)^2 + (x_2 - b)^2 - r^2$, Círculo centrado em (a, b) e com raio r .
 - $g(\mathbf{x}) = \frac{(x_1 - a)^2}{c^2} + \frac{(x_2 - b)^2}{d^2} - 1$, Elipse centrada em (a, b) , com largura $2c$ e altura $2d$.
 - $g(\mathbf{x}) = (x_1 - a)(x_2 - b) - c$, Hipérbole retangular com eixos paralelos às suas assíntotas.


Função de limiar de decisão

Função de limiar de decisão



- Para o exemplo ao lado, podemos definir a **função hipótese de classificação** como duas **condições**:
$$\hat{y} = h_a(\mathbf{x}) = \begin{cases} 0, & g(\mathbf{x}) = \mathbf{x}^T \mathbf{a} < 0 \text{ (Classe -)} \\ 1, & g(\mathbf{x}) = \mathbf{x}^T \mathbf{a} \geq 0 \text{ (Classe +)} \end{cases} \left\{ \begin{array}{l} \text{if} \\ \text{else} \end{array} \right.$$
- Percebam que a saída da **função** é **binária**.
- O mapeamento entre o valor da função discriminante, $g(\mathbf{x})$, e a saída 0 ou 1 é feito através da **função de limiar de decisão**, $f(g(\mathbf{x}))$.
 - No caso acima ela é feita por uma **estrutura condicional**.
- Como implementamos essas **condições** através de uma função matemática?

Função de limiar de decisão rígido




- Uma ***função de limiar de decisão*** simples que mapeia o valor de $g(x)$ em 2 valores de saída é a ***função de limiar de decisão rígido***.
- Ela é mostrada na figura ao lado e é definida como

$$f(g(x)) = \begin{cases} 0, & g(x) < 0 \\ 1, & g(x) > 0 \\ \text{Indeterminado}, & g(x) = 0 \end{cases}$$


Conhecida também
como ***função heaviside***
ou degrau unitário.

Classificação com limiar de decisão rígido




- Agora que a **função hipótese de classificação**, $h_a(x)$, tem uma **forma matemática bem** definida, precisamos pensar em **como encontrar os pesos**, a .

Classificação com limiar de decisão rígido




- Queremos encontrar os pesos de tal forma que **o erro de classificação seja minimizado**, i.e., que os exemplos sejam classificados corretamente.
- No caso da **regressão linear**, nós fizemos isso de duas maneiras:
 - i. de forma fechada (com a **equação normal**) tomando a derivada parcial do erro em relação aos pesos, igualando a zero e resolvendo a equação em relação aos pesos;
 - ii. e através do algoritmo do **gradiente descendente**, com as derivadas parciais do erro em função aos pesos.

Classificação com limiar de decisão rígido



- Entretanto, com a **função de limiar rígido**, **nenhuma das duas abordagens é possível** devido à **derivada** de $f(g(x))$ ser igual a zero em todos os pontos exceto em $g(x) = 0$, onde ela é indeterminada.

Classificação com limiar de decisão rígido



Como encontramos os pesos dada essa limitação?

Classificação com limiar de decisão rígido

- Uma possível solução é utilizar uma *regra intuitiva* de atualização dos **pesos** que **converge para uma solução dado que exista uma função discriminante adequada e que as classes não se sobreponham**.
- Essa *regra intuitiva de atualização dos pesos* é dada pela seguinte equação

$$\mathbf{a} \leftarrow \mathbf{a} + \alpha \left(y(i) - h_{\mathbf{a}}(\mathbf{x}(i)) \right) \mathbf{x}(i), \forall i,$$

onde α é o passo de aprendizagem, o qual deve ser sempre maior do que zero.


- A regra possui a mesma forma da regra do **gradiente descendente estocástico (GDE)** usada na **regressão linear**, mas, aqui, a saída de $h_{\mathbf{a}}(\mathbf{x}(i))$ é discreta.

Classificação com limiar de decisão rígido

$$\mathbf{a} \leftarrow \mathbf{a} + \alpha \left(y(i) - h_{\mathbf{a}}(\mathbf{x}(i)) \right) \mathbf{x}(i), \forall i.$$


- Por razões que discutiremos mais adiante, esta regra é chamada de ***regra de aprendizagem do perceptron***.
- Os pesos são atualizados usando-se apenas ***um exemplo por vez***, escolhido de forma ***aleatória*** do conjunto de treinamento, assim como fizemos com o GDE.
- Como ***classificadores binários*** têm rótulos e valores de saída iguais a 0 ou 1, o comportamento da regra de atualização é diferente do comportamento do GDE.
- Como veremos a seguir, existem apenas 3 possibilidades para a regra.

Classificação com limiar de decisão rígido




- Primeira possibilidade
 - Se o valor de saída do classificador for igual ao esperado, i.e., $h_a(\mathbf{x}(i)) = y(i)$, então $y(i) - h_a(\mathbf{x}(i)) = 0$.
- Observem que se na equação de atualização dos pesos
$$\mathbf{a} = \mathbf{a} + \alpha \left(y(i) - h_a(\mathbf{x}(i)) \right) \mathbf{x}(i),$$
 $y(i) - h_a(\mathbf{x}(i)) = 0$, então, **os pesos não são atualizados**.

Classificação com limiar de decisão rígido






- Equação de atualização dos pesos
$$\mathbf{a} = \mathbf{a} + \alpha \left(y(i) - h_{\mathbf{a}}(\mathbf{x}(i)) \right) \mathbf{x}(i).$$
- Segunda possibilidade
 - Se $y(i) = 1$, mas $h_{\mathbf{a}}(\mathbf{x}(i)) = 0$, então
$$\mathbf{a} = \mathbf{a} + \alpha \mathbf{x}(i).$$
 - Assim, o k -ésimo peso, a_k , tem seu valor **aumentado** quando o valor de $a_k \times x_k$ é positivo e **diminuído** quando o valor de $a_k \times x_k$ é negativo.
 - Isso faz sentido, pois nós queremos **aumentar** o valor de $g(\mathbf{x})$, de tal forma que $g(\mathbf{x}) > 0$ e, conseqüentemente, $h_{\mathbf{a}}(\mathbf{x})$ tenha como saída o valor 1.
 - Lembrando que $g(\mathbf{x}) = a_0 + a_1x_1 + \dots + a_Kx_K$.

Classificação com limiar de decisão rígido




- Equação de atualização dos pesos
$$\mathbf{a} = \mathbf{a} + \alpha \left(y(i) - h_{\mathbf{a}}(\mathbf{x}(i)) \right) \mathbf{x}(i).$$
- Terceira possibilidade
 - Se $y(i) = 0$, mas $h_{\mathbf{a}}(\mathbf{x}(i)) = 1$, então
$$\mathbf{a} = \mathbf{a} - \alpha \mathbf{x}(i).$$
 - Assim, o k -ésimo peso, a_k , tem seu valor **diminuído** quando o valor de $a_k \times x_k$ é positivo e **aumentado** quando o valor de $a_k \times x_k$ é negativo.
 - Isso faz sentido, pois nós queremos **diminuir** o valor de $g(\mathbf{x})$, de tal forma que $g(\mathbf{x}) < 0$ e, conseqüentemente, $h_{\mathbf{a}}(\mathbf{x})$ tenha como saída o valor 0.
 - Lembrando que $g(\mathbf{x}) = a_0 + a_1x_1 + \dots + a_Kx_K$.

Classificação com limiar de decisão rígido




- A **regra de aprendizagem do perceptron** converge para um **separador perfeito** quando:
 - As classes são **suficientemente separadas** umas das outras e, portanto, não se sobrepõem.
 - E existe uma **função discriminante adequada para o problema**, mesmo que não seja um **hiperplano**.
 - ✓ Não precisa ser um problema linearmente separável.
- **Separador perfeito**: com **erro de classificação igual a zero**, ou seja, todos os exemplos são perfeitamente classificados.
- Porém, na prática essa situação não é muito comum.

Classificação com limiar de decisão rígido




- Quando as classes se sobrepõem, a ***regra de aprendizagem do perceptron*** falha em convergir para uma solução perfeita.
- Não há convergência, pois os pesos são ***ajustados com uma única amostra por vez***, fazendo com que $g(x)$ ***mude de posição a cada atualização***.

Classificação com limiar de decisão rígido




- Porém, se *α decrescer de acordo com as iterações de treinamento*, então a regra tem uma chance de convergir para uma solução de *erro mínimo*, mas não igual a zero.
 - Abordagem similar à que usamos com o GDE.
- Podemos também usar o *early-stopping* e *guardar* os *pesos* que resultaram no *menor erro de validação*.

Classificação com limiar de decisão rígido




- Outro problema com classificadores que usam **limiar de decisão rígido** é a **falta de informação sobre a confiança** quanto a uma classificação.
- Na figura ao lado, dois exemplos estão bem próximos da **fronteira de decisão** enquanto outros dois estão bem distantes dela.
- Como o classificador com **limiar de decisão rígido** classificaria esses exemplos?

Classificação com limiar de decisão rígido




- Olhando para a função de **limiar de decisão rígido**, percebemos que o classificador faz previsões **muito confiantes** sempre iguais 0 para $g(x) < 0$ e iguais a 1 quando $g(x) > 0$, **independente se o exemplo está distante ou próximo da fronteira de decisão**.

Classificação com limiar de decisão rígido




- Exemplos **mais distantes da fronteira** têm uma **probabilidade maior** de **realmente pertencerem à classe onde estão**.
 - Quanto maior o valor absoluto de $g(x)$, mais distante da fronteira está o exemplo.
- Por outro lado, exemplos **próximos da fronteira** têm **probabilidade menor** de pertencerem à classe onde estão.
 - Quanto menor o valor absoluto de $g(x)$, mais próximo da fronteira está o exemplo.

Classificação com limiar de decisão rígido



- Assim, usando o **limiar de decisão rígido**, os
 - dois **pontos azuis** são classificados como pertencentes à **classe negativa** (valor 0) e
 - os dois **triângulos vermelhos** classificados como pertencentes à **classe positiva** (valor 1), mesmo tendo valores **absolutos de $g(x)$ bem diferentes**.

Classificação com limiar de decisão rígido



- Em resumo, *pontos distantes da fronteira* de decisão *deveriam ter uma confiança* (ou probabilidade) de *pertencerem a uma determinada classe bem maior do que pontos próximos*.
- Porém, isso não é refletido na saída do classificador com limiar de decisão rígido.
- Entretanto, em muitas situações, nós precisamos de *predições mais graduadas*, que indiquem incertezas quanto à predição.

Tarefas

- **Quiz:** “*T320 - Quiz - Classificação (Parte II)*” que se encontra no MS Teams.
- **Exercício Prático:** [Laboratório #2](#).
 - Pode ser acessado através do link acima (Google Colab) ou no GitHub.
 - Se atentem aos prazos de entrega.
 - [Instruções para resolução e entrega dos laboratórios](#).

Obrigado!

