T320 - Introdução ao Aprendizado de Máquina II:

Classificação (Parte II)

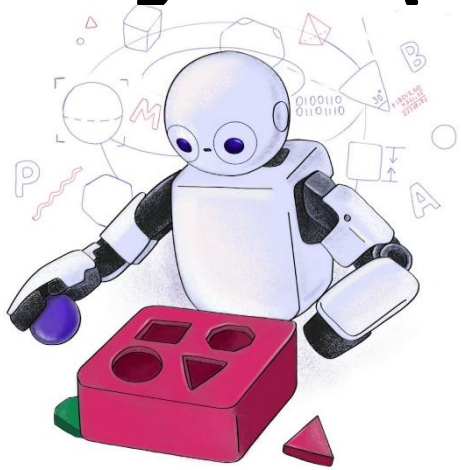

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Recapitulando

- Anteriormente, vimos exemplos de uso de algoritmos de ***classificação***.
  - Classificação de spam.
  - Análise de sentimentos.
  - Reconhecimento de dígitos.
- Definimos o problema da classificação e concluímos que ele também é um problema de aprendizado do supervisionado.
- Aprendemos que as classes são separadas através de ***funções discriminantes*** e que o desafio é encontrar uma função adequada e os pesos correspondentes.

Classificação linear

- Como vimos, o objetivo da ***classificação*** é usar as características (i.e., atributos) de, por exemplo, um objeto para identificar a qual classe ele pertence.
- Um ***classificador linear*** atinge esse objetivo tomando uma decisão de classificação com base no valor de uma ***combinação linear*** dos ***atributos***, ou seja, na saída de uma ***função discriminante linear***.
- A saída de um classificador linear é dada por

$$y = h_{\boldsymbol{a}}(\boldsymbol{x}) = f(g(\boldsymbol{x})) = f\left(\sum_{k=0}^{K} a_k x_k\right) = f(\boldsymbol{a}^T \boldsymbol{x}),$$

onde $\boldsymbol{x} = [1, x_1, \ldots, x_K]^T$ e $f(.)$ é uma ***função de limiar de decisão***.

  - ***Função de limiar de decisão*** é uma função que converte a saída da ***função discriminante linear***, $\boldsymbol{a}^T \boldsymbol{x}$ (produto escalar), na saída desejada, ou seja, na classe C_q do objeto.
  - Ela é apenas uma formalização matemática para os ***if***s e ***else***s que usamos para definir as classes.
- Originalmente, as ***funções discriminantes*** eram apenas formadas por equações de hiperplanos: $\sum_{k=0}^{K} a_k x_k$.
- $h_{\boldsymbol{a}}(\boldsymbol{x})$ é conhecida como ***função hipótese de classificação***.

Classificação linear

- Dado um ***conjunto de treinamento***, a tarefa do ***classificador*** é a de ***aprender*** uma ***função hipótese de classificação***, $h_{\alpha}(\boldsymbol{x})$, que recebe um exemplo (e.g., x_1 e x_2) e retorna a classe do exemplo.
- Classificadores binários têm como saída o valor ***0*** caso o exemplo pertença à classe C_1 (também chamada de ***classe negativa***) ou ***1*** caso ele pertença à classe C_2 (também chamada de ***classe positiva***).
- Para que um ***classificador linear*** funcione corretamente, as duas classes devem ser ***linearmente separáveis***.
- Isso significa que as classes devem ser ***suficientemente separadas*** umas das outras para garantir que a ***superfície de decisão*** consista de um ***hiperplano***.
- Classes que podem ser separadas por um ***hiperplano*** são chamadas de ***linearmente separáveis***.
- Na primeira figura, a ***fronteira de decisão*** é definida por uma ***função discriminante*** que é uma **reta:** $g(\boldsymbol{x}) = 1 - x_1 - x_2$.
- Na segunda figura, devido à proximidade das classes, não existe um ***hiperplano*** que as separe.

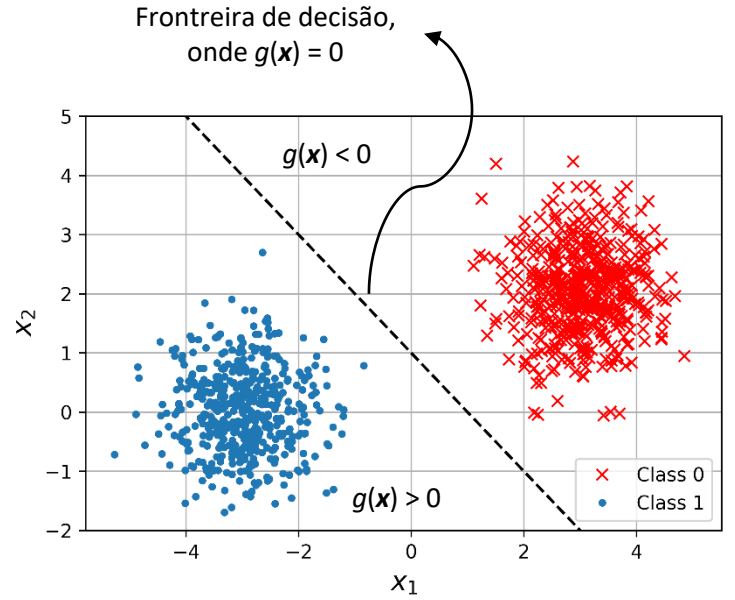

Classes linearmente separáveis.

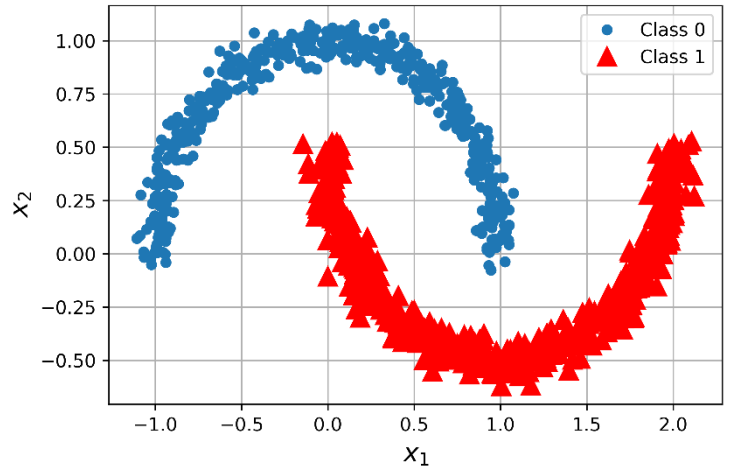

Classes não-linearmente separáveis.

Limiar de decisão rígido

- Para o exemplo ao lado, podemos definir a ***função hipótese de classificação*** como

$$y = h_{\boldsymbol{a}}(\boldsymbol{x}) = \begin{cases} 0, & g(\boldsymbol{x}) = \boldsymbol{x}^T\boldsymbol{a} < 0 \text{ (Classe 1)} \\ 1, & g(\boldsymbol{x}) = \boldsymbol{x}^T\boldsymbol{a} \geq 0 \text{ (Classe 2)} \end{cases}$$

- Percebam que a saída da ***função hipótese*** é binária, ou seja, temos apenas 2 possíveis valores, 0 ou 1.
- O mapeamento entre o valor da função discriminante, $g(\boldsymbol{x})$, e a saída 0 ou 1 é feita através da ***função de limiar de decisão***, $f(g(\boldsymbol{x}))$.
- Uma ***função de limiar de decisão*** que faça o mapeamento do valor de $g(\boldsymbol{x})$ em apenas 2 valores é chamada de ***função de limiar de decisão rígido***.
- A **função de limiar de decisão rígido** é mostrada na figura ao lado e é definda como

Conhecida também como ***função heaviside.***

$$f(z) = \begin{cases} 0, & z < 0 \\ 1, & z > 0 \\ \text{Indeterminado}, & z = 0 \end{cases}$$

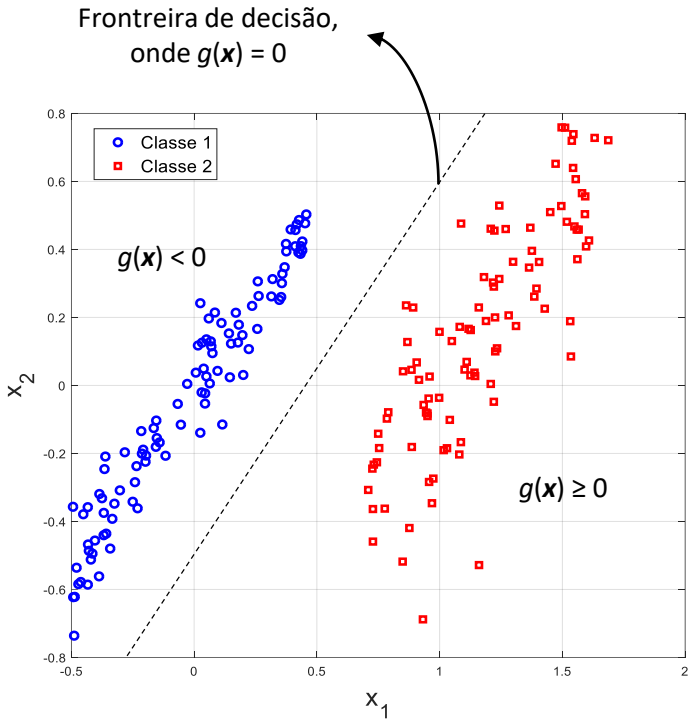

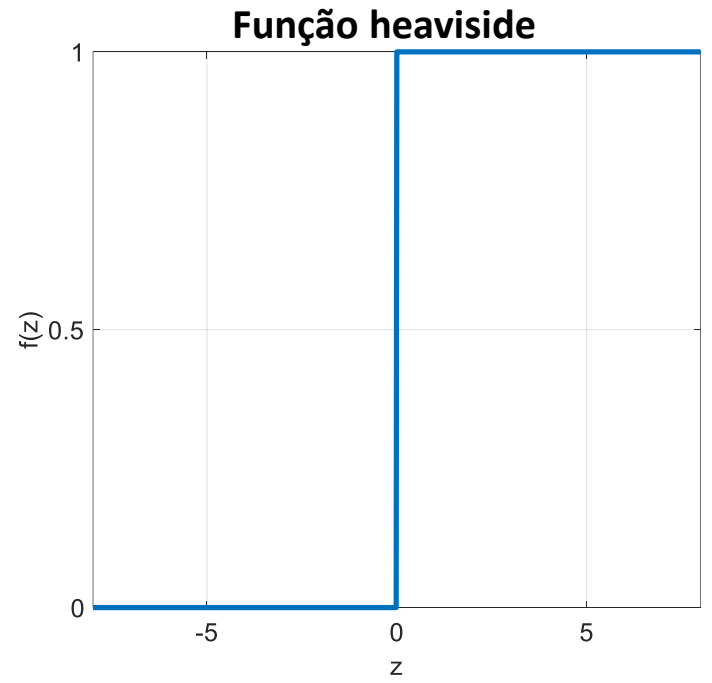

Classificadores lineares com limiar de decisão rígido

- Agora que a ***função hipótese***, $h_{\boldsymbol{a}}(\boldsymbol{x})$, tem uma forma matemática bem definida, nós podemos pensar em como escolher os pesos $\boldsymbol{a}$ que ***minimizem o erro de classificação***.
- No caso da ***regressão linear***, nós fizemos isso de duas maneiras:
  i. de forma fechada (através da ***equação normal***) fazendo o gradiente igual a zero e resolvendo a equação para os pesos;
  ii. e através do algoritmo do ***gradiente descendente***.
- Entretanto, com a ***função de limiar rígido***, nenhuma das duas abordagens é possível devido ao fato do ***gradiente*** ser igual a zero em todos os pontos do espaço de pesos exceto no ponto onde $\boldsymbol{x}^T \boldsymbol{a} = 0$, e mesmo assim, o ***gradiente*** é indeterminado nesse ponto.
- **Portanto, o que podemos fazer?**

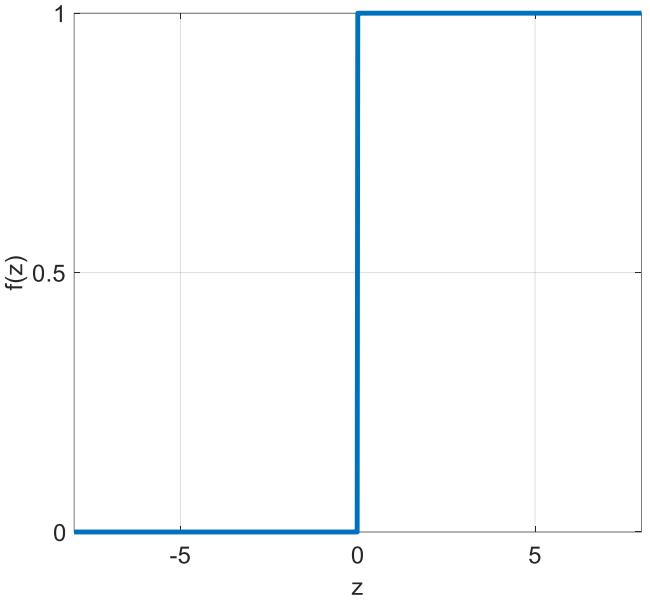

Classificadores lineares com limiar de decisão rígido

- Uma possível abordagem para o problema quando utilizamos um ***limiar de decisão rígido*** é utilizar uma ***regra intuitiva*** de atualização dos ***pesos*** que converge para uma solução ***dado que exista uma função discriminante adequada e que as classes não se sobreponham***.
- A atualização dos ***pesos*** é dada pela seguinte equação

Os pesos são atualizados a cada novo exemplo.

$$\boldsymbol{a} = \boldsymbol{a} + \alpha \left(y(i) - h_{\boldsymbol{a}}\left(\boldsymbol{x}(i)\right)\right) \boldsymbol{x}(i), \forall \mathrm{i},$$

a qual é essencialmente idêntica à regra de atualização para a ***regressão linear*** quando utilizamos o ***gradiente descendente estocástico***.

- Esta regra é chamada de ***regra de aprendizagem do perceptron***, por razões que discutiremos em breve.
- Essa regra de aprendizagem é aplicada a um exemplo por vez, escolhendo exemplos aleatóriamente, assim como fizemos com o ***gradiente descendente estocástico***.
- Como estamos considerando classificadores com valores de saída 0 ou 1, o comportamento da regra de atualização será diferente do comportamento para a regressão linear, como veremos a seguir.

Classificadores lineares com limiar de decisão rígido

$$\boldsymbol{a} = \boldsymbol{a} + \alpha \left(y(i) - h_{\boldsymbol{a}}\left(\boldsymbol{x}(i)\right)\right) \boldsymbol{x}(i)$$

- Ambos, o valor desejado, y, e a saída da ***função hipótese***, $h_{\boldsymbol{a}}(\boldsymbol{x})$, assumem os valores 0 ou 1, portanto, existem 3 possibilidades:
  - Se a saída estiver correta, i.e., $y = h_{\boldsymbol{a}}(\boldsymbol{x})$, então os pesos não são atualizados.
  - Se $y = 1$, mas $h_{\boldsymbol{a}}(\boldsymbol{x}) = 0$, então o peso a_k tem seu valor ***aumentado*** quando o valor de x_k é positivo e ***diminuído*** quando o valor de x_k é negativo.
    - Isso faz sentido pois nós queremos aumentar o valor do produto escalar $\boldsymbol{x^T a}$, ou seja, $g(\boldsymbol{x})$, de tal forma que $h_{\boldsymbol{a}}(\boldsymbol{x})$ tenha como saída o valor 1.
  - Se $y = 0$, mas $h_{\boldsymbol{a}}(\boldsymbol{x}) = 1$, então o peso a_k tem seu valor ***diminuido*** quando o valor de x_k é positivo e ***aumentado*** quando o valor de x_k é negativo.
    - Isso faz sentido pois nós queremos diminuir o valor do produto escalar $\boldsymbol{x^T a}$, ou seja, $g(\boldsymbol{x})$, de tal forma que $h_{\boldsymbol{a}}(\boldsymbol{x})$ tenha como saída o valor 0.

Classificadores lineares com limiar de decisão rígido

- A ***regra de aprendizagem do perceptron*** converge para um ***separador perfeito*** quando:
  - As classes são ***suficientemente separadas*** umas das outras, ou seja, não se sobrepõem.
  - Existe uma ***função discriminante*** adequada para o problema, mesmo que não seja um ***hiperplano***.
- ***Separador perfeito:*** com erro de classificação igual a zero, ou seja, todos os exemplos são perfeitamente classificados.
- Porém, na prática essa situação não é muito comum.
- Nesse caso, a ***regra de aprendizagem do perceptron*** falha em convergir para uma solução perfeita.
- Em geral, essa regra não converge para uma solução estável para valores fixos do ***passo de aprendizagem***, α, mas se α decresce de acordo com as iterações, então a regra tem uma chance de convergir para uma solução de erro mínimo quando os exemplos são apresentados de forma aleatória.
- Podemos também usar o ***early-stop*** e utilizar os ***pesos*** que resultaram no menor erro de validação.

Exemplo: classificador_linear_com_limiar_rigido.ipynb

Classificadores lineares com limiar de decisão rígido

- Outro problema com classificadores que usam ***limiar de decisão rígido*** é a falta de informação sobre a confiança do classificador quanto a um resultado.
- No exemplo ao lado, dois exemplos estão bem próximos da ***fronteira de decisão*** enquanto outros dois estão bem distantes dela.
- O classificador com limiar rígido, faria uma previsão completamente confiante pelo valor 1 para os dois pontos azuis e 0 para os dois triângulos vermelhos, mesmo eles tendo valores bem diferentes de $g(\boldsymbol{x})$.
- Em muitas situações, nós precisamos de previsões mais graduadas, que indiquem incertezas quanto à classificação.

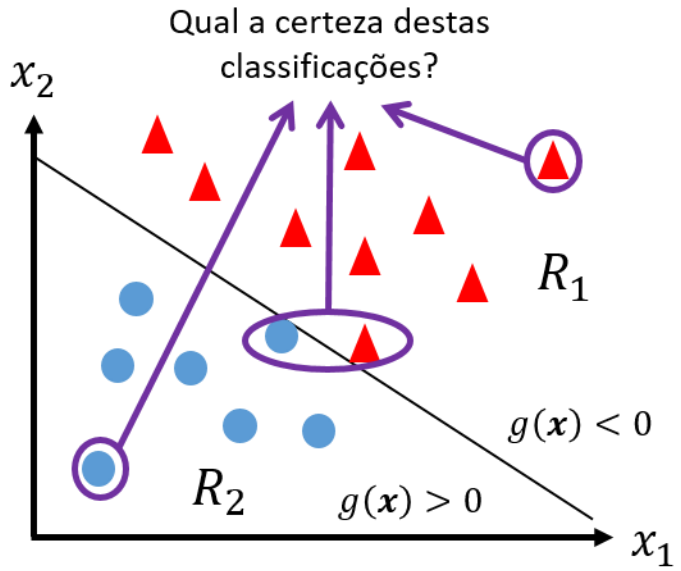

- Os pontos distantes da ***fronteira de decisão*** têm valores absolutos de $g(\boldsymbol{x})$ bem maiores do que os dos pontos próximos, os quais têm valores de $g(\boldsymbol{x})$ muito próximos de 0.
- Ou seja, a cofiança deveria ser maior pra pontos distantes.
- Porém, isso não é refletido na saída do classificador com limiar rígido.

Truque do Kernel

Tarefas

- **Quiz**: “*T320 - Quiz - Classificação (Parte II)*” que se encontra no MS Teams.
- **Exercício Prático**: **Laboratório #2**.
  - Pode ser baixado do MS Teams ou do GitHub.
  - Pode ser respondido através do link acima (na nuvem) ou localmente.
  - Instruções para resolução e entrega dos laboratórios.
  - **Atividades podem ser feitas em grupo, mas as entregas devem ser individuais.**

Obrigado!

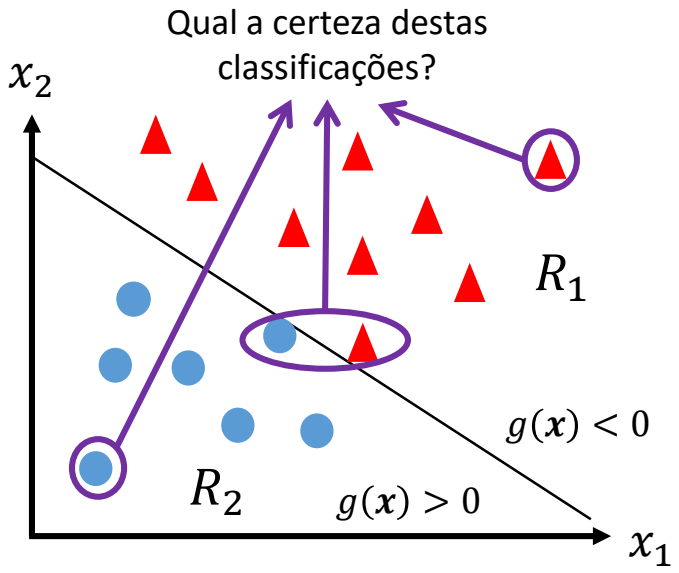
Qual a certeza destas classificações?
x_2
x_1
R_1
R_2
$g(\boldsymbol{x}) < 0$
$g(\boldsymbol{x}) > 0$