


T320 - Introdução ao Aprendizado de Máquina II: *k-Médias*




Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Recapitulando


- Até o momento, todos os algoritmos que aprendemos seguiam o paradigma do aprendizado supervisionado.
- Hoje, falaremos sobre **clustering**, que são algoritmos de **aprendizado não-supervisionado** que visam criar **agrupamentos de dados** (chamados de **clusters** ou **grupos**) segundo seu **grau de semelhança**.
- Em seguida, aprenderemos sobre o algoritmo chamado de **k-Médias** (ou **k-Means**, em inglês) que é um dos algoritmos mais simples de **clustering**.

Motivação




- O que podemos fazer quando não temos informações sobre as classes (i.e., rótulos) a que pertencem os exemplos de um conjunto de dados?

Motivação




- Na figura ao lado, não sabemos a que classe ou classes pertencem os dados, mas podemos observar que alguns exemplos estão *próximos uns dos outros*, formando grupos.

Motivação



- A tarefa mais popular dos algoritmos de aprendizado não supervisionado é a **identificação de clusters**.
- Veremos que com eles, podemos obter informações uteis de dados não rotulados usando algum critério de **similaridade entre eles** (e.g., a **distância**).

Identificação de clusters




OBS.: A identificação visual de *clusters* em um espaço bi ou tridimensional é fácil, mas em quatro ou mais dimensões isso já não é mais possível. Nesses casos, apenas algoritmos de identificação de *clusters* conseguem agrupar os dados.

- Na tarefa de *identificação de clusters*, a *entrada* é um conjunto de *vetores de atributo* (i.e., exemplos) *sem rótulos*.
- A *saída* são valores indicando os *clusters* a que pertencem cada um dos exemplos.


Como representar os clusters?

Unlabelled Data




- Para realizar a clusterização, temos que ***decidir como os clusters serão representados.***
- Existem algumas opções como a densidade, a distribuição e a hierarquia dos dados.
- Porém, a abordagem mais simples usa os ***centroides*** (i.e., ***centros geométricos***) dos *clusters*.
 - O algoritmo que usa centroides é conhecido como k-means.
- Os ***centroides*** são obtidos através da ***média individual de cada atributo das amostras que pertencem ao cluster.***

Como calcular os centroides?



- Por exemplo, suponhamos os seguintes ***vetores de atributos*** em um espaço bidimensional, x_1 e x_2 : (2, 5), (1, 4), (3, 6).
- Nesse caso, o ***centroide*** é representado pelo vetor (2, 5), pois
 - A média do primeiro atributo é $\frac{2+1+3}{3} = 2$.
 - A média do segundo atributo é $\frac{5+4+6}{3} = 5$.
- Os atributos ***devem ser numéricos*** para o cálculo do centroide e da métrica de similaridade.


Como podemos usar os centroides?



centroide é o ponto central de um cluster de dados. Representa a média geométrica das amostras dentro do *cluster*.


- Os **centroides** podem ser usados como
 - forma de comprimir ou sumarizar os dados,
 - Usa-se o centróide para representar todo o *cluster*.
 - forma de detectar anomalias,
 - A distância até o centróide pode indicar uma anomalia.
 - centros para inicialização de modelos de misturas Gaussianas ou de redes de função de base radial,
 - estimativas de valores de atributos ausentes,
 - Usa-se o valor de centróide para preencher o valor.
 - protótipos para classificadores baseados em distância.
 - Classificadores mais simples do que os baseados em modelos supervisionados (e.g., redes neurais)

Quantos devem ser os clusters?



- Os clusters ***não devem se sobrepor***: ***cada exemplo*** deve ***pertencer*** a ***um e apenas a um cluster***.
- Porém, ***dentro do mesmo cluster***, os ***exemplos*** devem estar relativamente ***próximos*** uns dos outros e ***distantes*** dos ***exemplos dos outros clusters***.
- Aí surge uma dúvida.
- Quantos ***clusters*** um conjunto de exemplos contém?

Quantos devem ser os clusters?



- Na figura conseguimos identificar visualmente três clusters.
- No entanto, o número de opções existentes não se limita a essa única possibilidade:
 - em um extremo, todo o conjunto de dados pode ser pensado como formando um grande *cluster*;
 - no outro, cada exemplo pode ser visto como representando seu próprio *cluster* de um único exemplo.
- **Implementações** práticas geralmente evitam esse problema pedindo ao **usuário que forneça o número de clusters**.

Medindo distâncias

- Algoritmos para identificação de *clusters* precisam de uma **métrica para avaliar a distância entre uma amostra e o centroide** de um *cluster*.
- Uma forma de fazer isso é usar a **distância euclidiana** entre os dois vetores (de atributos e do centroide)

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^K (x_i - y_i)^2},$$

onde K é o número de atributos e x_i e y_i são os elementos dos vetores.

- Outras medidas de distância: Minkowski, cosseno, Manhattan e Mahalanobis.

A qual *cluster* um exemplo deve pertencer?

- Vamos supor que existam N *clusters* cujos centroides são denotados pelo vetor, $\mathbf{c}_i, \forall i \in (1, N)$.
- Uma amostra $\mathbf{x}$ tem uma certa distância $d(\mathbf{x}, \mathbf{c}_i)$ para cada centroide.
- Se $d(\mathbf{x}, \mathbf{c}_p)$ é a menor dessas distâncias, então, definimos $\mathbf{x}$ como pertencente ao centroide $\mathbf{c}_p$, ou seja, o p -ésimo *cluster*.
- Portanto, escolhemos a **menor distância** para **definir a qual *cluster* um exemplo pertence**.
- Agora, veremos como funciona o algoritmo *k-Means*.

k-Means

- O "*k*" é um hiperparâmetro que define o número de *clusters*.
- O pseudocódigo do algoritmo é mostrado abaixo.

Entradas: conjunto de exemplos e número de *clusters*, *k*.

1. Defina *k* centroides iniciais.

2. Repita


- a) Calcule a distância de cada exemplo, *x*, para cada um dos *k* centroides.
- b) Atribua cada exemplo, *x*, ao *cluster* mais próximo (menor distância).
- c) Calcule o novo centroide de cada *cluster**

3. Enquanto as posições dos centroides continuarem mudando.

*os novos centroides são calculados como a média aritmética (centro geométrico) das amostras pertencentes a cada *cluster*.


- O algoritmo garantidamente chega a uma situação em que cada exemplo se encontra no *cluster* mais próximo, de modo que, a partir deste momento, os centroides não mudem mais.

Como inicializar os centroides?



- Os procedimentos mais simples para inicializar os centroides são
 - *escolher k exemplos de treinamento aleatórios* e os considerar como os centroides iniciais.
 - *inicializar k vetores com valores aleatórios* retirados de alguma distribuição.
- Os *clusters iniciais* são então criados associando cada um dos exemplos ao seu *centroide mais próximo*.
- O número de *transferências* (i.e., tempo de treinamento) de um exemplo *de um cluster para outro depende dos centroides iniciais*.

Como inicializar os centroides?




- Se os *centroides iniciais* já forem *perfeitos*, *nenhum exemplo precisa ser atribuído a outro cluster* e o algoritmo é encerrado.
- Se eles forem *muito próximos*, o tempo de *treinamento pode ser longo*.
- Portanto, a *inicialização é importante* no sentido de que *um ponto de partida melhor* garante que a *solução seja encontrada mais rápido*.
- Ou seja, o *tempo de convergência* do algoritmo *depende da inicialização*.



Como escolher o número ideal de clusters?

- Existem várias abordagens para determinar o valor ideal de k .
- A mais comum é o método da silhueta.
- O coeficiente de silhueta avalia a **qualidade da clusterização**, considerando a *coesão dentro dos clusters e a separação entre eles*.
- Escolhemos o número de *clusters* que **maximiza** o coeficiente.
 - Quanto mais próximas forem as amostras de um *cluster* e mais distantes das amostras de outro *cluster*, maior o coeficiente.
- A documentação da biblioteca SciKit-Learn contém um exemplo de como usar o coeficiente de silhueta para definir o melhor número de clusters.
 - https://scikit-learn.org/1.5/auto_examples/cluster/plot_kmeans_silhouette_analysis.html

SciKit-Learn: k-Means



k-Means




[Exemplo: kmeans_example.ipynb](#)

Avisos

- Terminamos o conteúdo da disciplina.
- As próximas aulas serão para dúvidas e conclusão do projeto.
- **Projeto:** Projeto #2.
 - Projeto está no github e pode ser feito em grupos de no máximo 3 alunos.
 - **Entrega: 28/06/2026 até às 23:59.**
 - Leiam os enunciados atentamente.
 - Apenas um integrante do grupo precisa fazer a entrega.
 - **Mas não se esqueçam de colocar os nomes de todos os integrantes do grupo.**

Obrigado!



k-means be like:



K-MEANS CLUSTER



Figuras