T320 - Introdução ao Aprendizado de Máquina II:

Redes Neurais Artificiais (Parte I)

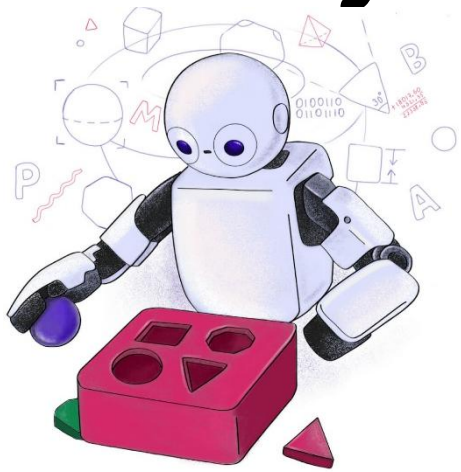

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Introdução

- A partir desta aula, entenderemos como as ideias que discutimos até agora serão úteis na construção de ***modelos matemáticos que aproximam a atividade de aprendizagem do cérebro***.
- Essas ideias, que já discutimos, nos ajudarão a entender o funcionamento das ***redes neurais artificiais*** (RNAs).
- Redes neurais artificiais são os modelos de aprendizado de máquina mais populares e efetivos e mereceriam por sí só uma disciplina em separado.
- Portanto, neste tópico, veremos uma breve visão geral sobre as RNAs.

Redes neurais artificiais

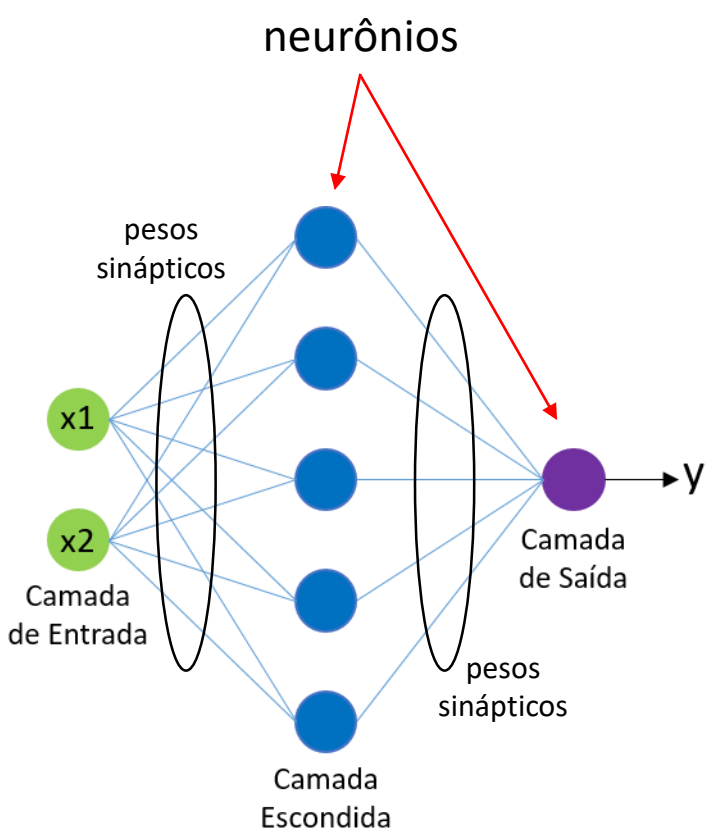

- ***Redes neurais artificiais*** são modelos computacionais ***inspirados*** pelo funcionamento do cérebro dos animais.
- Elas são capazes de realizar tarefas de aprendizado de máquina (e.g., regressão e classificação) com grande eficácia.

Redes Neurais Artificiais

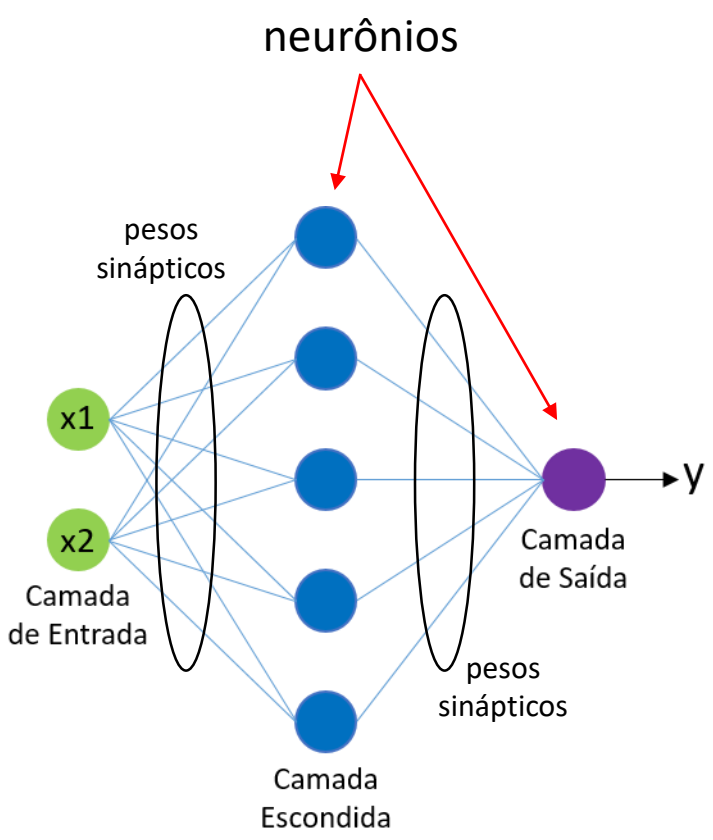

- RNAs são geralmente apresentadas como ***sistemas de nós (unidades ou neurônios) interconectados***, que geram valores de saída quando ativados, simulando o comportamento de ***redes neurais biológicas***.
- Esta primeira parte deste tópico, ***foca nos elementos básicos de construção de uma rede neural***, os ***neurônios***.

Algumas aplicações famosas

- RNAs são versáteis, poderosas e escalonáveis, tornando-as ideais para realizar tarefas altamente complexas de ***aprendizado de máquina***, como por exemplo:
  - Classificar bilhões de imagens (e.g., como o Google Images, Facebook, etc.),
  - Serviços de reconhecimento de fala (e.g., a Siri da Apple, Alexa da Amazon e Google Assistant),
  - Recomendar vídeos que melhor se adequam ao comportamento dos usuários (e.g., YouTube, Netflix),
  - Dirigir um veículo sem intervenção humana,
  - Responder perguntas (e.g., ChatGPT, Gemini, DeepSeek).

Google images

Alexa Google Assistant Siri

YouTube

NETFLIX

WAYMO

Um pouco de contexto

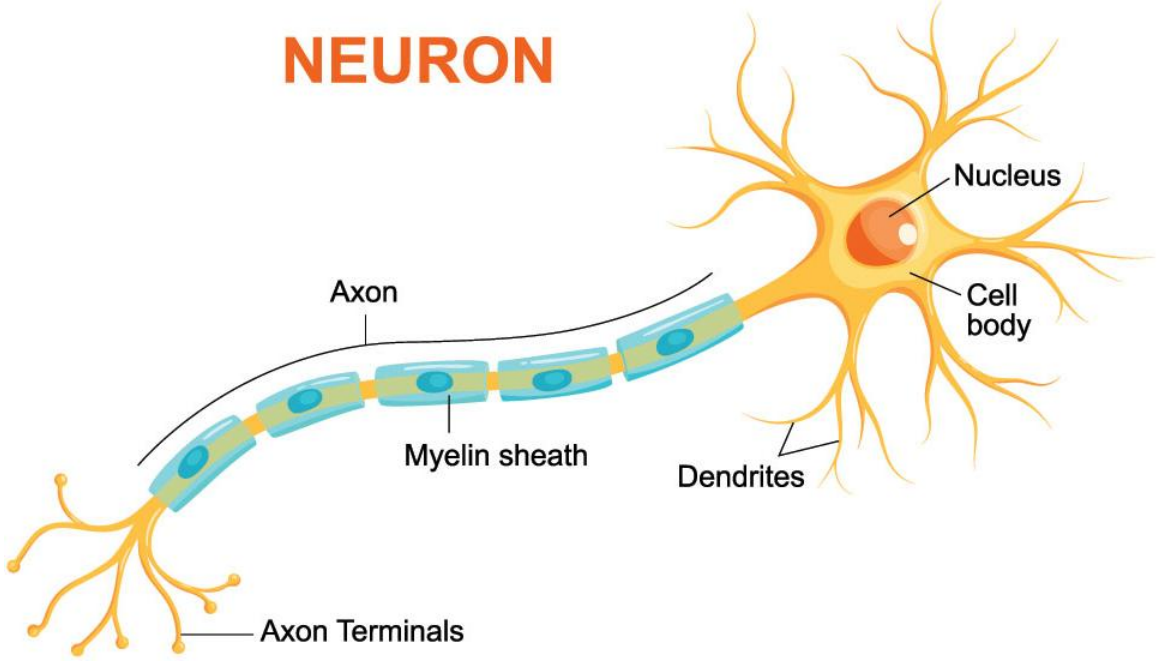

- Os ***neurônios*** são células que possuem ***mecanismos eletroquímicos*** para transferência de informações entre eles.
- Eles apresentam três partes principais:
  - os ***dendritos***,
  - o ***corpo celular (soma)*** e
  - o ***axônio***.

Um pouco de contexto

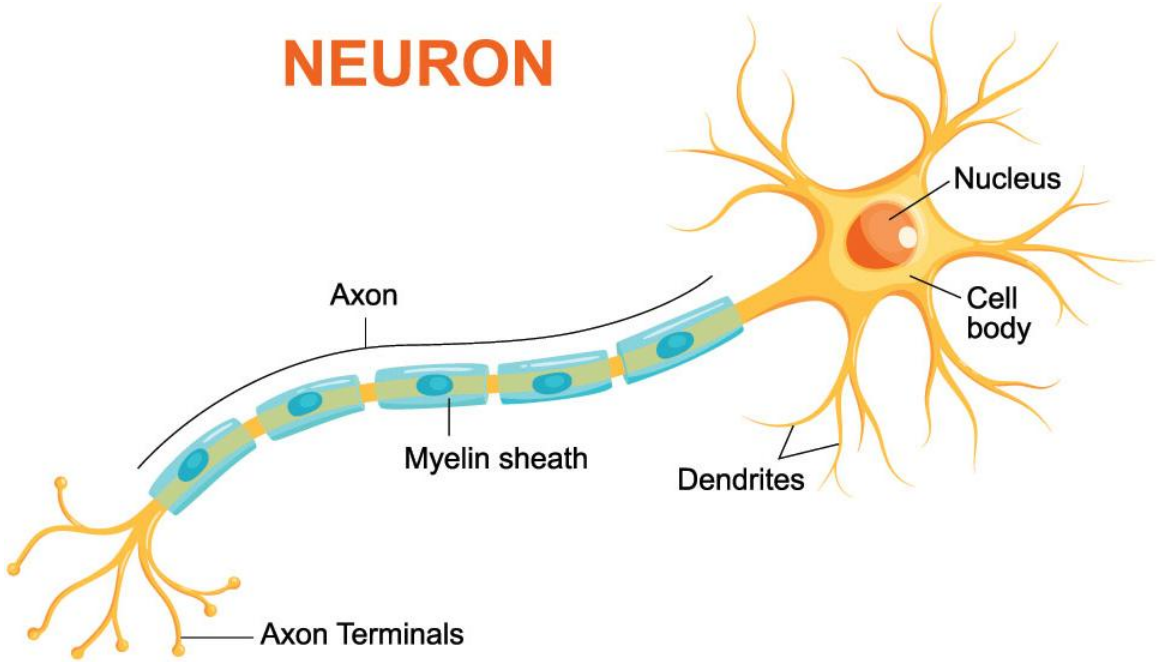

- Os ***dendritos*** são prolongamentos do neurônio que garantem a ***recepção de estímulos*** de outros neurônios, levando impulsos nervosos em direção ao ***corpo celular***.

Um pouco de contexto

- O ***corpo celular*** (também conhecido como ***soma***) contém o núcleo do neurônio e é responsável por realizar a ***integração*** dos estímulos recebidos pelo neurônio através de seus dendritos.

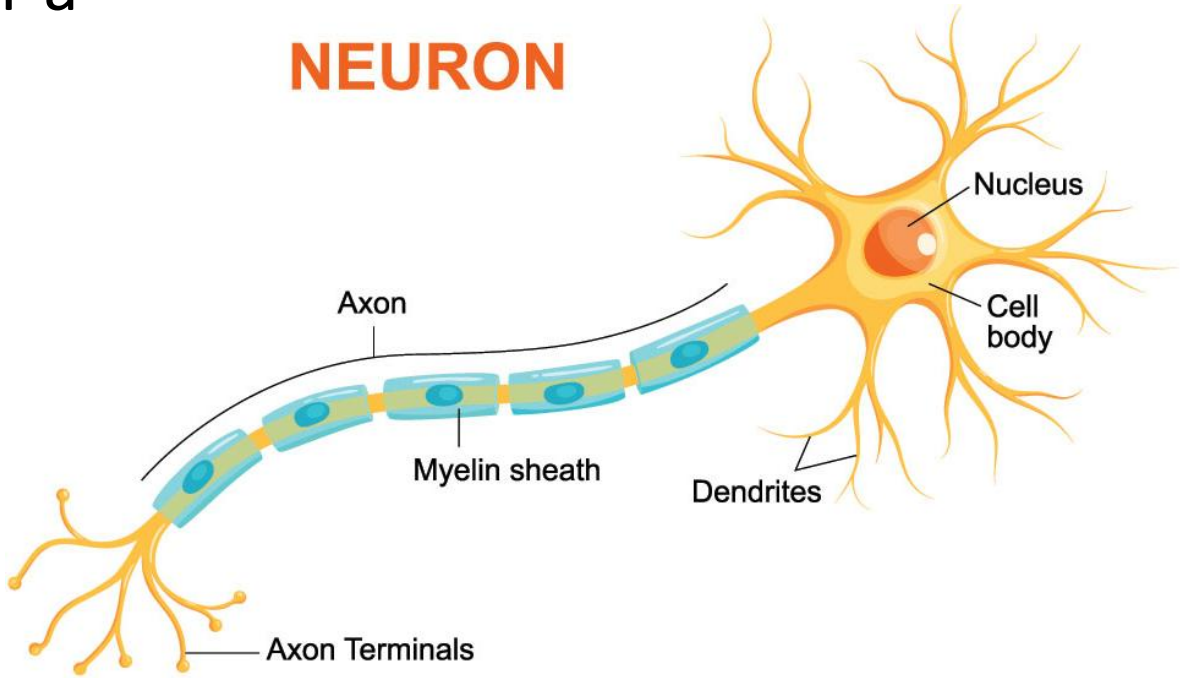

Um pouco de contexto

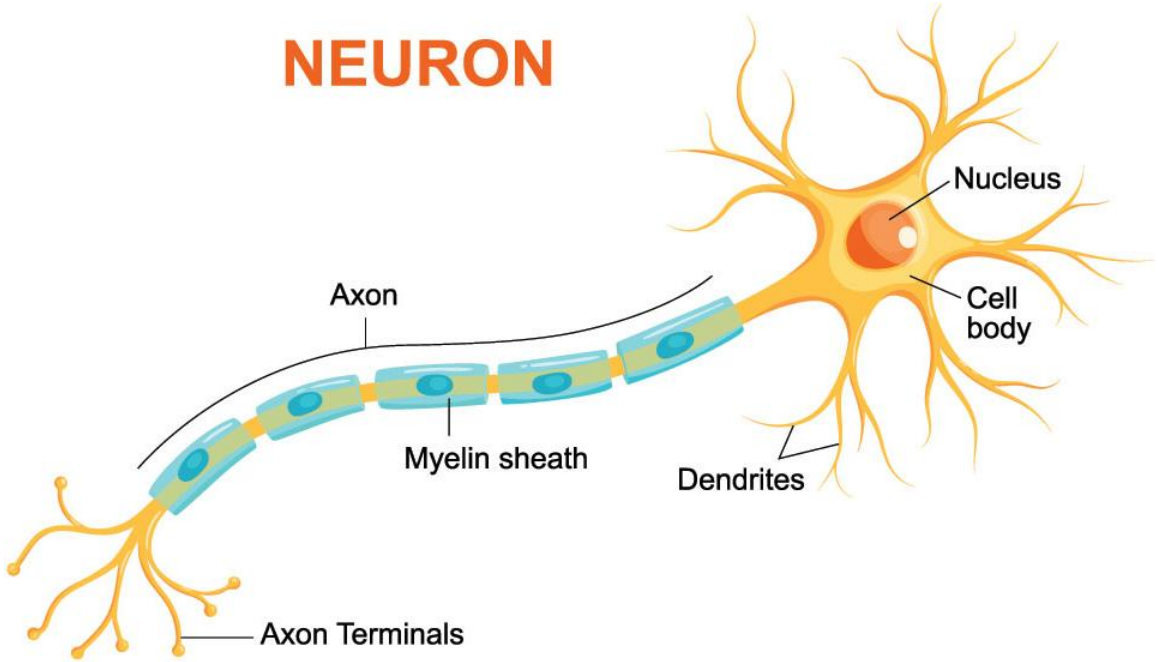

- O ***axônio*** é um prolongamento que garante o envio de informação (estímulos) a outros neurônios através de seus ***terminais***.
- Cada neurônio possui apenas um axônio, o qual é, geralmente, mais longo que os dendritos.

Um pouco de contexto

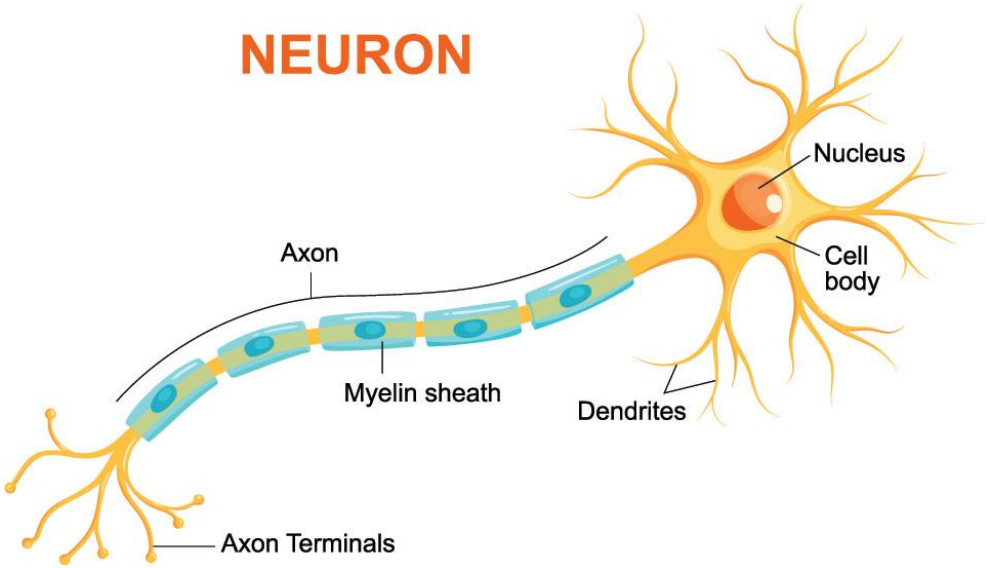

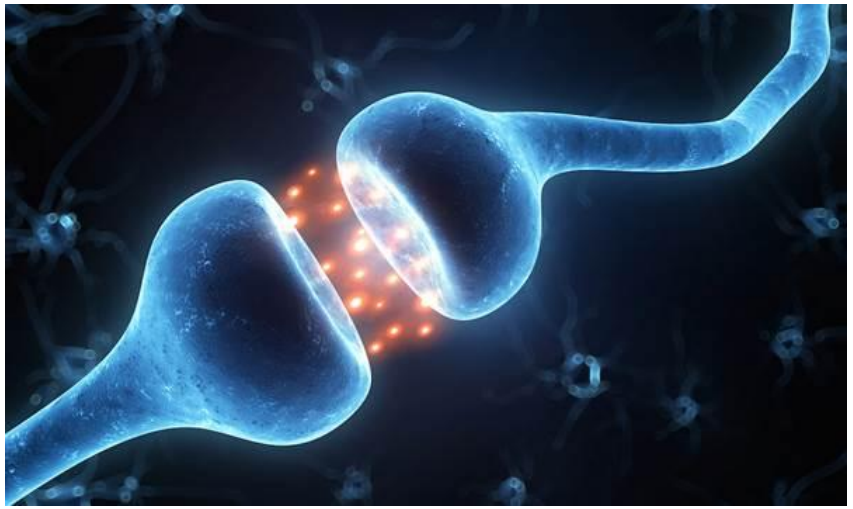

- Os pontos de contato entre os dendritos de um neurônio e os terminais do axônio de outro neurônio são chamados de ***sinapses***.
- A comunicação entre neurônios se dá através das ***sinapses***.
- As sinapses podem ser fortes ou fracas:
  - **Forte**: informação daquele neurônio é importante para o próximo.
  - **Fraca**: informação daquele neurônio não é tão importante para o próximo.

Um pouco de contexto

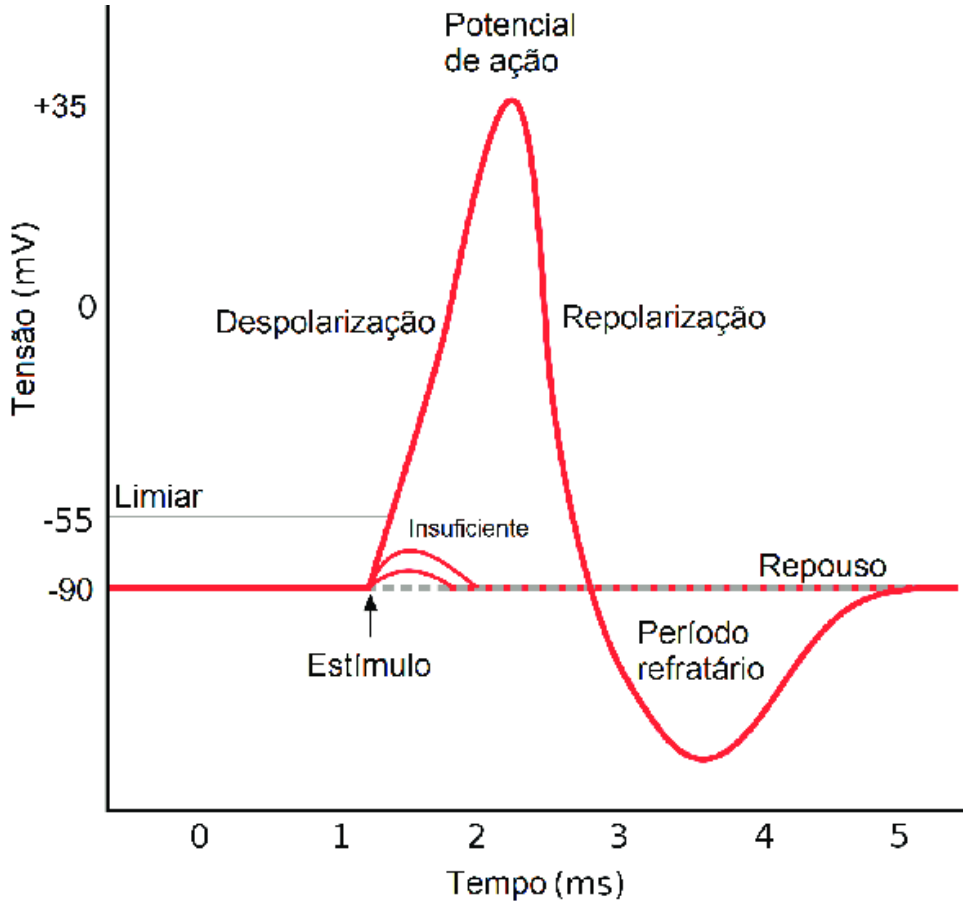

- Em termos bem simples, mas lembrando de que existem exceções, nós podemos simplificar o funcionamento do ***neurônio*** como:
  - O neurônio recebe estímulos elétricos, através dos ***dendritos***.
  - Esses estímulos são somados no ***corpo celular*** (i.e., *soma*).
  - Se a soma dos estímulos exceder um certo ***limiar de ativação***, o ***neurônio*** gera um pulso (ou ***potencial de ação***) que é enviado pelos ***terminais do axônio*** a outros neurônios.

Um pouco de contexto

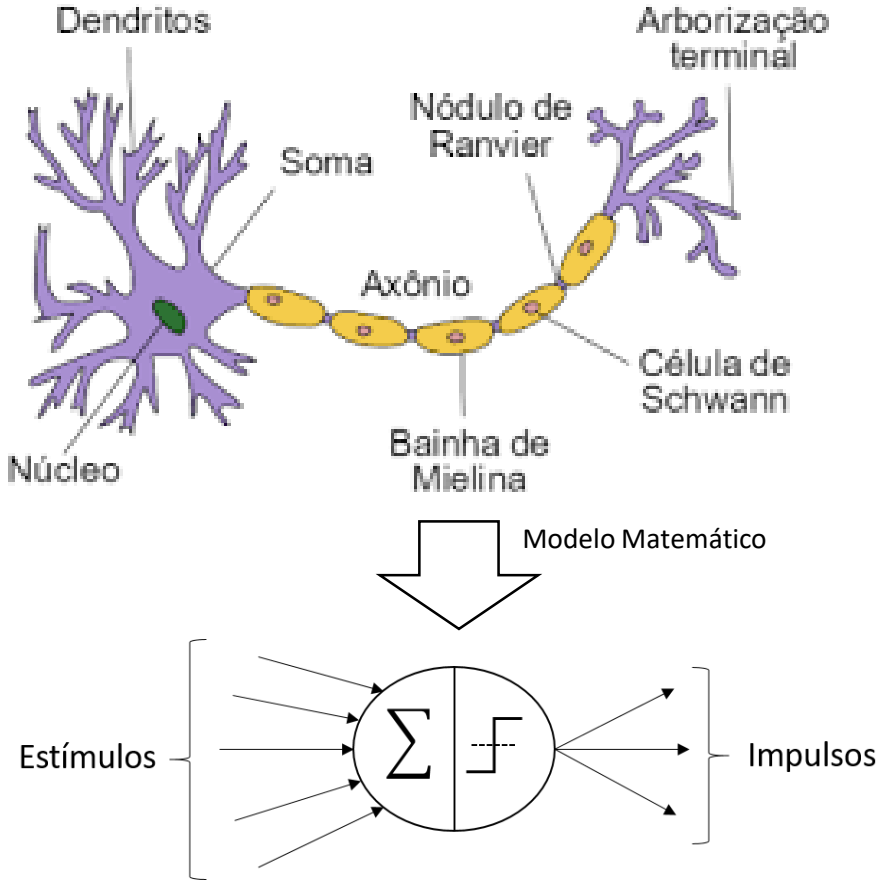

- Um ***neurônio*** pode se conectar a até 20.000 outros ***neurônios*** através das ***sinapses***.
- Os sinais são passados de ***neurônio*** para ***neurônio*** através de ***reações eletroquímicas***.
- Do ponto de vista do nosso curso, o ***neurônio*** será considerado como um ***sistema com várias entradas e uma ou mais saídas*** onde a comunicação entre neurônios é feita através de ***sinais elétricos***.

O modelo de McCulloch e Pitts

Walter Pitts e Warren McCulloch

- O final do século XIX e o início do século XX foram períodos fundamentais para o estabelecimento do conhecimento atual do sistema nervoso.
- De posse desse entendimento, em 1943, dois neurocientistas, Warren McCulloch e Walter Pitts apresentam em um artigo científico o primeiro ***modelo computacional de um neurônio***.
- A partir desse modelo, foi possível estabelecer uma conexão entre o funcionamento de um neurônio e a ***lógica proposicional***.

O modelo de McCulloch e Pitts

- ***Lógica proposicional*** se baseia em ***proposições***.
  - Uma ***proposição*** é uma ***sentença declarativa*** ou ***afirmação***, ou seja, é uma sentença que faz uma ***afirmação sobre um fato***, podendo este ser verdadeiro ou falso.
- O artigo de McCulloch e Pitts fornece *insights* fundamentais sobre como a ***lógica proposicional pode ser processada por um neurônio***.
- Existe uma correspondência direta entre a lógica proposicional e a lógica Booleana.
  - Podemos pensar em uma ***sentença declarativa*** como sendo uma ***expressão Booleana***
    - 1 ou 1 = 1
    - 1 e 0 = 0
- A partir desta correspondência, a relação com a computação foi direta e natural.

O modelo de McCulloch e Pitts

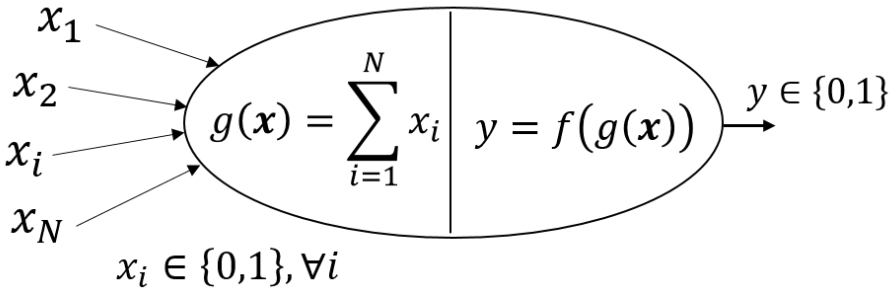

$$y = f(g(\boldsymbol{x})) = \begin{cases} 1, \text{se } g(\boldsymbol{x}) \geq \theta \\ 0, \text{se } g(\boldsymbol{x}) < \theta \end{cases}$$

onde θ é o ***limiar de ativação***.

- A figura ao lado apresenta o modelo matemático do ***neurônio*** proposto por McCulloch e Pitts.
- Grosso modo, o ***neurônio*** de MP é ativado (ou disparado) quando a ***soma*** de suas entradas, $g(\boldsymbol{x})$, excede o ***limiar de ativação***, θ, da função de ativação $f(.)$.
  - Nesse contexto, $g(\boldsymbol{x})$ é chamada ativação.
- O modelo estabelece algumas premissas apresentadas a seguir.

O modelo de McCulloch e Pitts

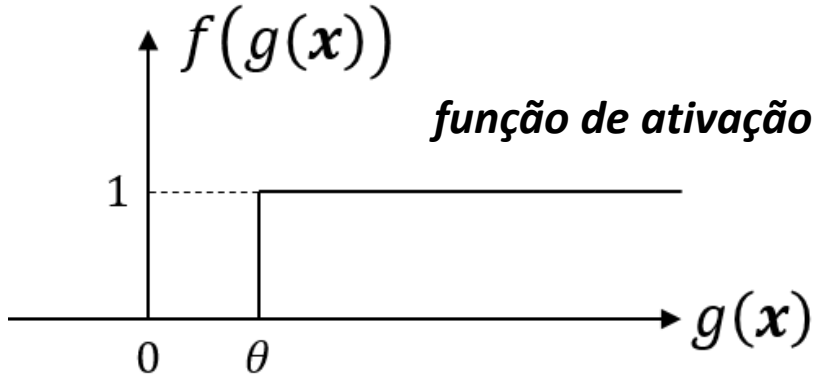

- As premissas desse modelo são:
  - Os valores das entradas, $x_i, \forall i$, ou também chamados de ***sinapses***, são sempre valores ***booleanos***, i.e., '0', ou '1'.
  - As entradas são multiplicadas por ***pesos com magnitudes unitárias*** (+/- 1, excitatórias ou inibitórias) e somadas.
  - A atividade do ***neurônio*** é um processo do tipo "***tudo ou nada***", ou seja, um processo binário (0 ou 1).
  - Portanto, a ***função de ativação*** do neurônio é uma ***função degrau*** com ***ponto de disparo variável***, dependente do ***limiar de ativação***, θ.
  - Um certo número de ***sinapses*** deve ser excitado para que o neurônio "dispare".

O modelo de McCulloch e Pitts

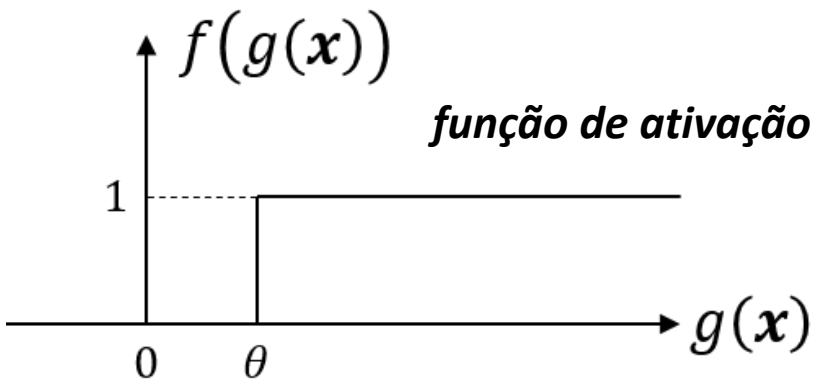

- Portanto, o modelo do ***neurônio*** de McCulloch e Pitts nada mais é do que um ***classificador linear*** com
  - ***limiar de decisão rígido,***
  - ***ponto de disparo variável,***
  - ***pesos com magnitudes unitárias*** e
  - ***atributos booleanos***.

Vamos usar este modelo para implementar portas lógicas

Exemplos de portas lógicas com o modelo M-P

OR			
x_1	x_2	$g(\boldsymbol{x})$	y
0	0	0	0
0	1	1	1
1	0	1	1
1	1	2	1

- Qual é o valor do ***limiar de ativação***, θ?
- Analisando-se $g(\boldsymbol{x})$, vemos que o disparo deve ocorrer quando $g(\boldsymbol{x}) \geq 1$, portanto, $\theta = 1$.

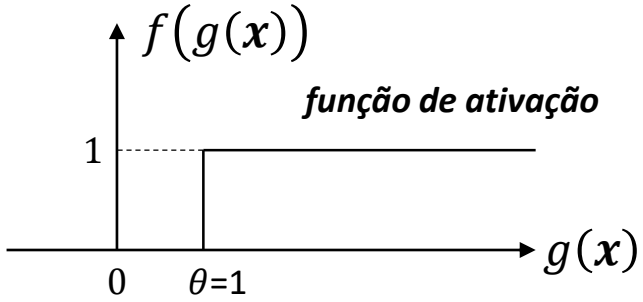

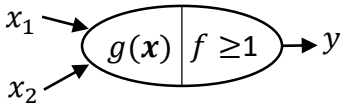

OBS.: pesos iguais a +1.

AND			
x_1	x_2	$g(\boldsymbol{x})$	y
0	0	0	0
0	1	1	0
1	0	1	0
1	1	2	1

- Qual é o valor do ***limiar de ativação***, θ?
- Analisando-se $g(\boldsymbol{x})$, vemos que o disparo deve ocorrer quando $g(\boldsymbol{x}) \geq 2$, portanto, $\theta = 2$.

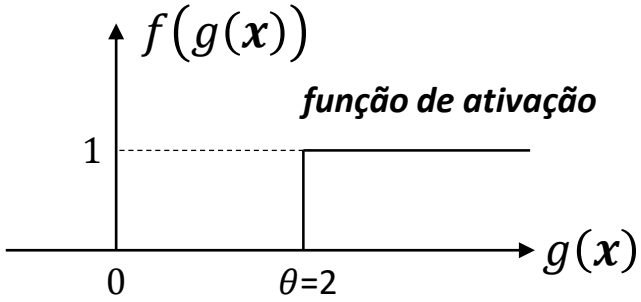

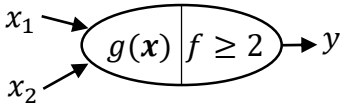

OBS.: pesos iguais a +1.

NOT			
x_1	$-x_1$	$g(\boldsymbol{x})$	y
0	0	0	1
1	-1	-1	0

- Qual é o valor do ***limiar de ativação***, θ?
- Analisando-se x_1, vemos que para o disparo ocorrer, seu valor deve ser ***negado*** (i.e., multiplicado por -1), e assim, o disparo ocorre quando $g(\boldsymbol{x}) \geq 0$, portanto, $\theta = 0$.

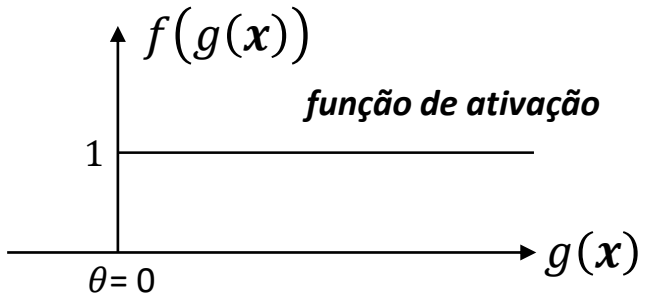

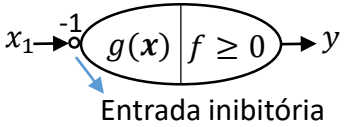

OBS.: Entradas inibitórias são entradas que têm seus valores multiplicados por -1.

Todos esses exemplos podem ser interpretados como problemas de classificação.

Como veremos, eles são linearmente separáveis.

Exemplos de portas lógicas com o modelo M-P

- Qual deve ser o valor do ***limiar de ativação***, θ, para a porta lógica XOR?

Sem entradas inibitórias.

XOR			
x_1	x_2	$g(\boldsymbol{x})$	y
0	0	0	0
0	1	1	1
1	0	1	1
1	1	2	0

$0 < g(\boldsymbol{x}) < 2$

x_1 como entrada inibitória.

XOR			
$-x_1$	x_2	$g(\boldsymbol{x})$	y
0	0	0	0
0	1	1	1
-1	0	-1	1
-1	1	0	0

$g(\boldsymbol{x}) \leq -1$ ou $g(\boldsymbol{x}) \geq 1$

x_2 como entrada inibitória.

XOR			
x_1	$-x_2$	$g(\boldsymbol{x})$	y
0	0	0	0
0	-1	-1	1
1	0	1	1
1	-1	0	0

$g(\boldsymbol{x}) \leq -1$ ou $g(\boldsymbol{x}) \geq 1$

x_1 e x_2 como entradas inibitórias.

XOR			
$-x_1$	$-x_2$	$g(\boldsymbol{x})$	y
0	0	0	0
0	-1	-1	1
-1	0	-1	1
-1	-1	-2	0

$-2 < g(\boldsymbol{x}) < 0$

- **Resposta**: com um único modelo de M-P, não é possível encontrar um ***limiar de ativação*** que resolva este problema, pois como veremos adiante, este problema não é ***linearmente separável***.
- O modelo de M-P só resolve problemas ***linearmente separáveis***.

Tarefa

- **Quiz**: “*T320 - Quiz – Redes Neurais Artificiais (Parte I)*” que se encontra no MS Teams.

Perceptron

- Em 1958, Frank Rosenblatt, propôs um novo ***modelo computacional*** ***mais geral*** que o modelo do ***neurônio*** de McCulloch e Pitts.
- O modelo criado por ele foi chamado de ***perceptron*** e é mostrado na figura ao lado.
- O ***perceptron*** é um modelo para ***aprendizado supervisionado*** de ***classificadores binários***, ou seja ***problemas com duas classes***.
- Assim como o modelo de M-P, o ***perceptron*** só é capaz de classificar padrões ***linearmente separáveis***.
- Ou seja, um ***perceptron*** também não resolve o problema da classificação XOR.

Frank Rosenblatt

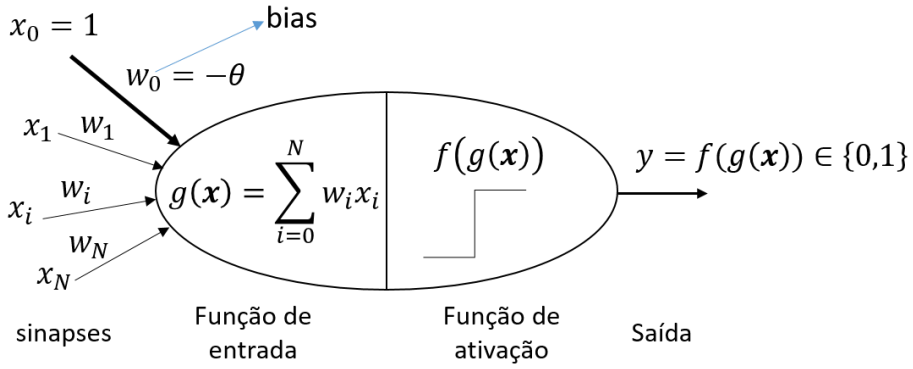

Perceptron

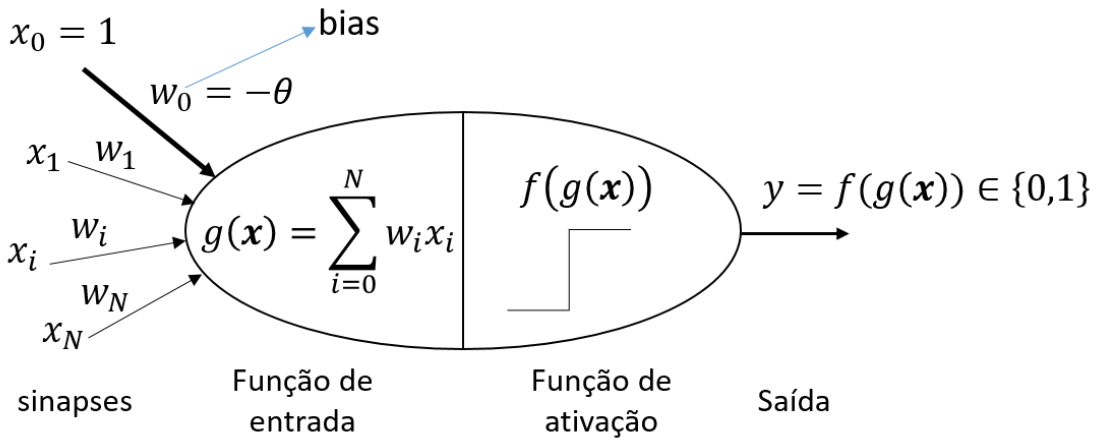

- Esse novo modelo supera algumas das limitações do modelo de M-P:
  - Introdução do conceito de ***pesos sinápticos com valores reais*** para as entradas (ou ***sinapses***).
    - Pesos dão uma medida de importância das sinapses (i.e., atributos).
  - E um método para que o modelo ***aprenda automaticamente os pesos e o ponto de ativação***, que passa a ser um peso também.

Perceptron

- Além disso, as entradas não são mais limitadas a valores booleanos, como no caso do modelo de M-P, ***suportando entradas com valores reais***, o que torna este modelo mais útil e generalizado.
- Assim como no modelo de M-P, a ***função de ativação*** utilizada pelo ***perceptron*** também é a ***função degrau*** com a ***diferença que a transição não mais depende do limiar de ativação***, θ.
- Ou seja, a transição ou ativação sempre ocorre em 0.

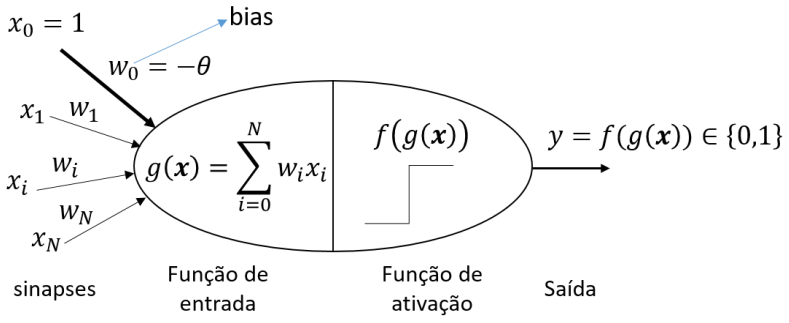

$$y = f(g(\boldsymbol{x})) = \begin{cases} 1, \text{se } g(\boldsymbol{x}) \geq 0 \\ 0, \text{se } g(\boldsymbol{x}) < 0 \end{cases}$$

Percebam que o ***limiar de ativação***, θ, agora faz parte das entradas e é chamado de ***bias***.

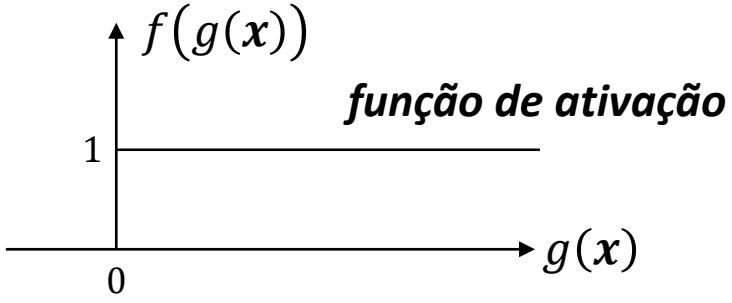

A ativação do Perceptron

- A ativação do ***perceptron*** é causada pela ***combinação linear*** dos ***estímulos de entrada*** em relação aos ***pesos sinápticos***.
  - Se a ***combinação linear*** exceder o ***limiar de ativação***, θ, o ***disparo*** ocorre.
  - Isso é expresso por uma ***função de ativação*** do tipo ***degrau***.

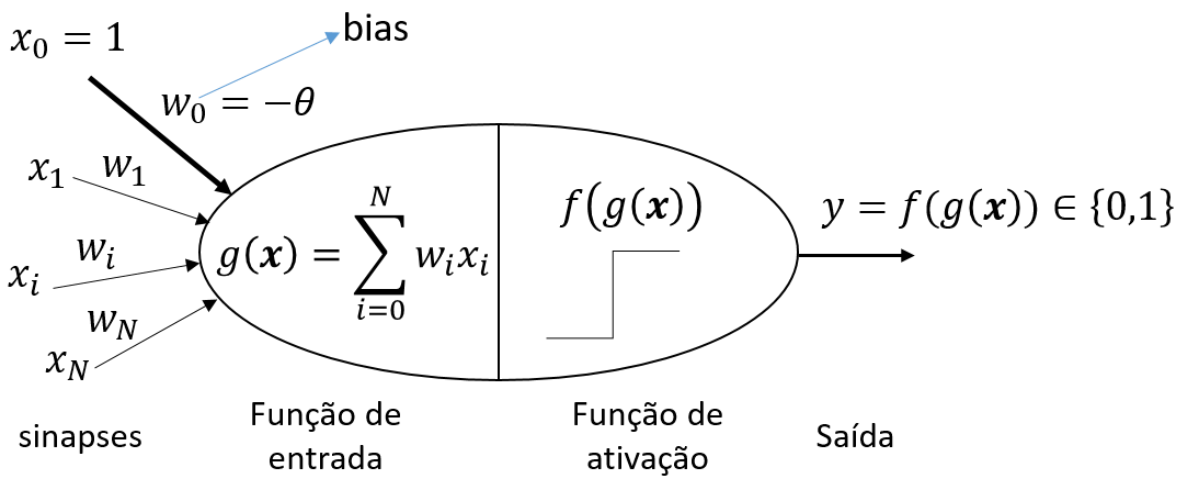

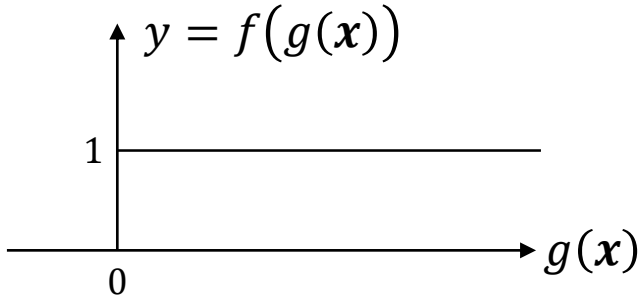

A ativação do Perceptron

- Notem que a ***função de ativação***, $f(.)$, abaixo tem a transição para o valor 1 quando $g(\boldsymbol{x}) = 0$ e o ***limiar de ativação*** é controlado, indiretamente, pelo valor do ***peso de bias***, w_0.
  - O ***limiar de ativação*** foi absorvido pela ***ativação*** $g(\boldsymbol{x})$, e, portanto, podemos usar a ***função de ativação com transição fixa em zero***, pois, agora, ajusta-se o limiar de ativação indiretamente através da atualização do peso w_0.

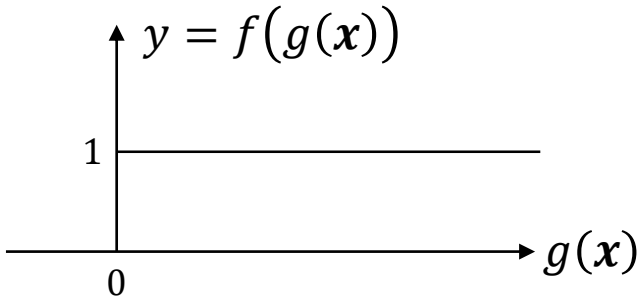

Para que tenhamos a saída do perceptron, y, igual a 1, então

$$g(\boldsymbol{x}) \geq 0 \therefore w_0 + \sum_{i=1}^{N} w_i x_i \geq 0 \ \therefore \sum_{i=1}^{N} w_i x_i \geq -w_0$$

Por exemplo

- Se $w_0 = 1$, $\sum_{i=1}^{N} w_i x_i \geq -1$.
- Se $w_0 = -1$, $\sum_{i=1}^{N} w_i x_i \geq 1$.

A ativação do Perceptron

- Como podemos ver, a ***função discriminante***, $g(\boldsymbol{x})$, do ***perceptron*** tem a forma de um ***hiperplano***

$$g(\boldsymbol{x}) = \sum_{i=0}^{N} w_i x_i,$$ combinação linear das entradas em relação aos pesos

onde x_0 é o atributo de bias com valor constante igual a 1.

- Portanto, como já sabemos, este tipo de função dá origem a um ***classificador binário*** onde as classes são separadas por uma ***superfície de separação linear***.

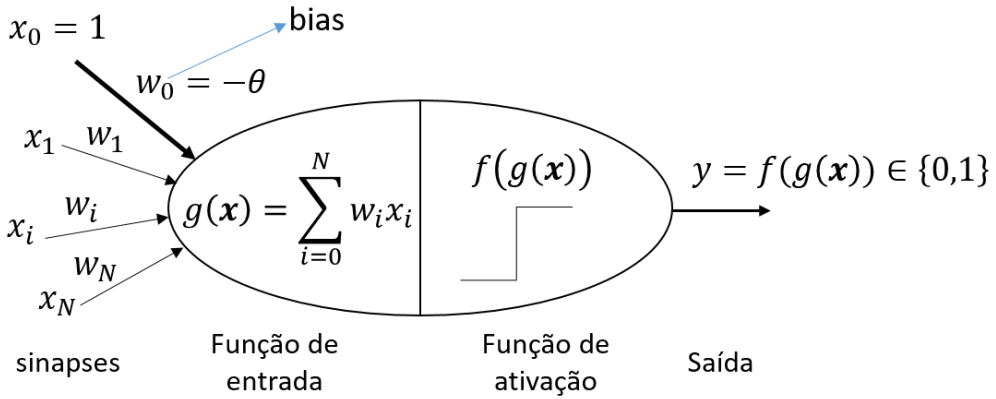

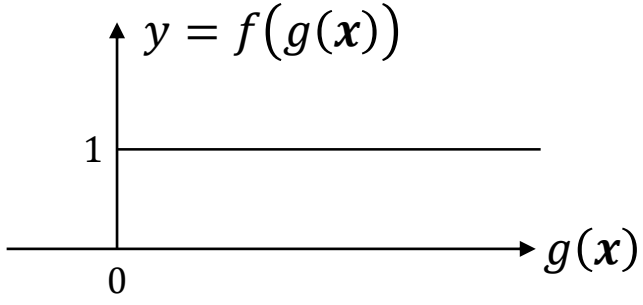

Regra de aprendizado do perceptron

- Devido ao fato da ***função degrau***, $f(g(\boldsymbol{x}))$, ter derivada igual a zero em todos os pontos, exceto em $g(\boldsymbol{x}) = 0$, onde ela é indefinida, nós não podemos utilizar o ***gradiente descendente***.
- Entretanto, como aprendemos anteriormente, usamos a ***regra de aprendizado do perceptron*** para treinar o modelo.
- É uma regra ***simples e intuitiva*** para atualização dos pesos do modelo.

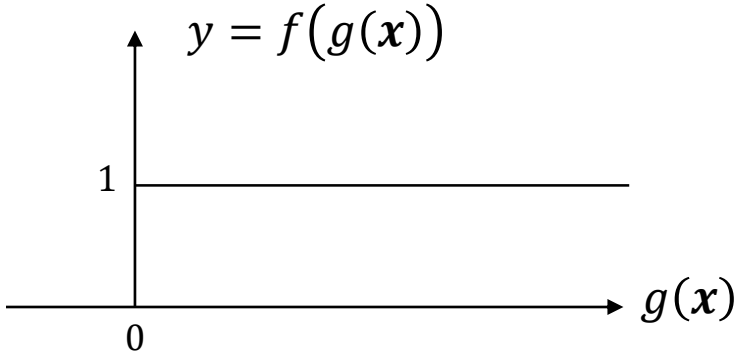

Regra de aprendizado do perceptron

- No caso do perceptron, onde $g(\boldsymbol{x})$, ***por definição***, é um ***hiperplano***, a regra converge para uma solução perfeita se as classes forem ***linearmente separáveis***:
  - Classes ***suficientemente espaçadas*** e que podem ser separadas por um ***hiperplano***.
- A ***equação de atualização dos pesos*** é definida como

$$\boldsymbol{w} \leftarrow \boldsymbol{w} + \alpha(y - \hat{y})\boldsymbol{x},$$

Equação idêntica a da atualização do gradiente descendente estocástico.

onde $\boldsymbol{w}$ é o vetor de pesos, α é o passo de aprendizagem, y é o valor de saída esperado, $\hat{y}$ é a saída do modelo, i.e., $f(g(\boldsymbol{x}))$, e $\boldsymbol{x}$ é o vetor de atributos.

Perceptron

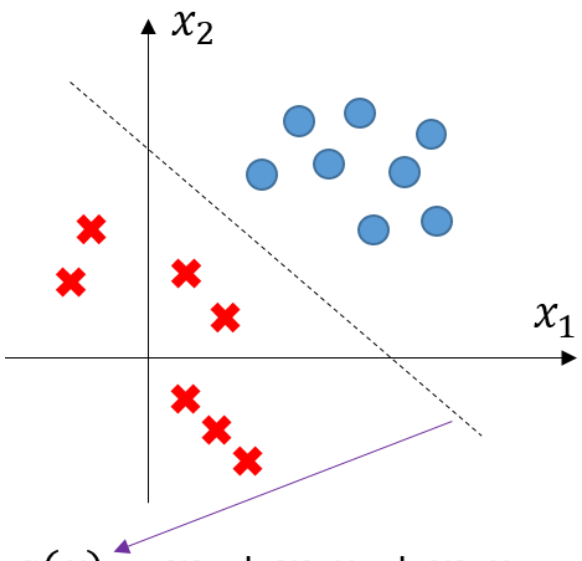

$$g(\boldsymbol{x}) = w_0 + w_1 x_1 + w_2 x_2 = 0$$

A separação das duas classes ocorre onde $g(\boldsymbol{x}) = 0$.

- Como percebemos, o ***perceptron*** é idêntico ao ***classificador binário com limiar de decisão rígido***.
- Por definição, o ***perceptron*** sempre utiliza ***superfícies de separação lineares***, ou seja, sempre teremos $g(\boldsymbol{x})$ como sendo a equação de um ***hiperplano***.
- Portanto, teoricamente, ***sem transformação dos atributos***, um ***único*** ***perceptron*** só é capaz de ***classificar*** dados que sejam ***linearmente separáveis*** (ou seja, separáveis por um ***hiperplano***).

Perceptron

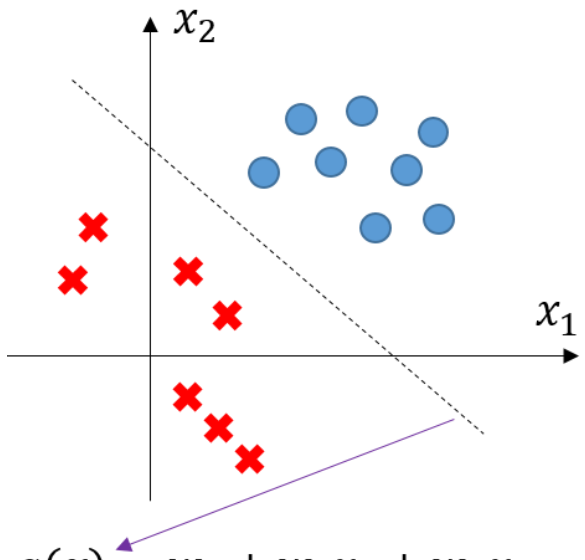

$$g(\boldsymbol{x}) = w_0 + w_1 x_1 + w_2 x_2 = 0$$

A separação das duas classes ocorre onde $g(\boldsymbol{x}) = 0$.

- A figura ao lado ilustra isso para um caso bidimensional.
- Entretanto, como veremos na sequência, podemos ***combinar os resultados de vários perceptrons*** para criar ***superfícies de separação*** que separem dados que não sejam linearmente separáveis sem a necessidade de ***transformar os atributos***.
- Ou seja, não precisaremos usar funções discriminantes, $g(\boldsymbol{x})$, com outros formatos (e.g., polinômios) que não sejam o de um hiperplano.

Perceptron

- Por serem ***linearmente separáveis***, as lógicas AND e OR podem ser separadas por um único perceptron.
- As figuras abaixo demonstram que uma simples reta consegue separar os dados das duas lógicas.

x1	x2	y
0	0	0
0	1	0
1	0	0
1	1	1

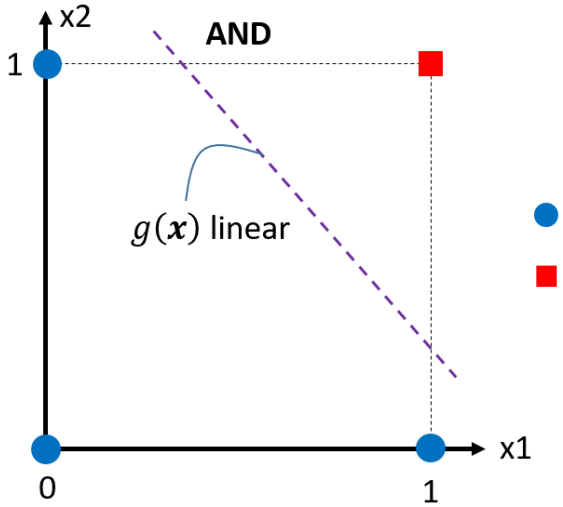

Classe 0 (nível lógico 0)

Classe 1 (nível lógico 1)

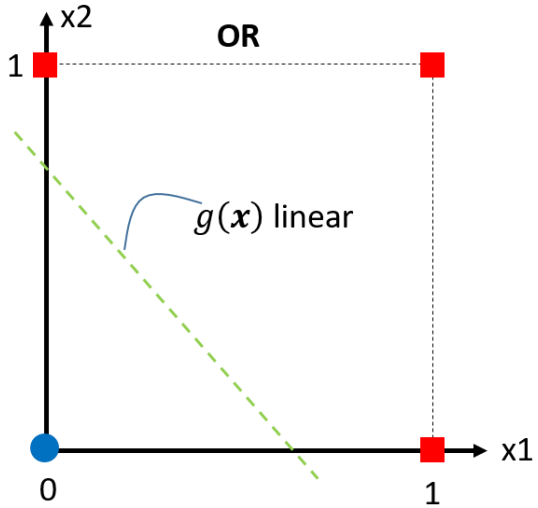

x1	x2	y
0	0	0
0	1	1
1	0	1
1	1	1

Perceptron

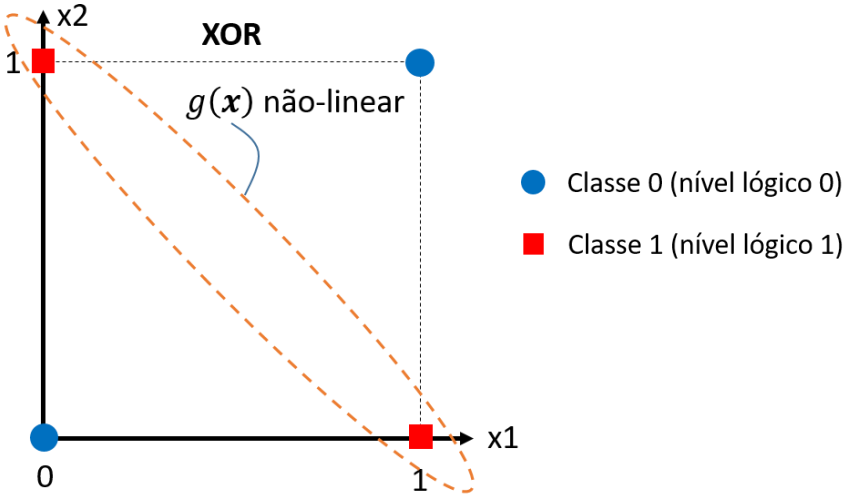

- Porém, a lógica XOR ***não é linearmente separável*** e necessita de uma ***superfície de separação não-linear***.
- Vejam na figura abaixo que são necessárias ***no mínimo duas retas paralelas***.
- Como veremos, a ***separação da lógica XOR pode ser obtida combinando-se o resultado de dois perceptrons*** (i.e., dois classificadores lineares), que resultará em uma superfície de separação não linear.

Exemplo: perceptron_xor_problem.ipynb

Tarefas

- **Quiz**: *"T320 - Quiz – Redes Neurais Artificiais (Parte II)"* que se encontra no MS Teams.
- **Exercício Prático**: **Laboratório #6**.
  - Pode ser baixado do MS Teams ou do GitHub.
  - Pode ser respondido através do link acima (na nuvem) ou localmente.
  - Instruções para resolução e entrega dos laboratórios.

Obrigado!

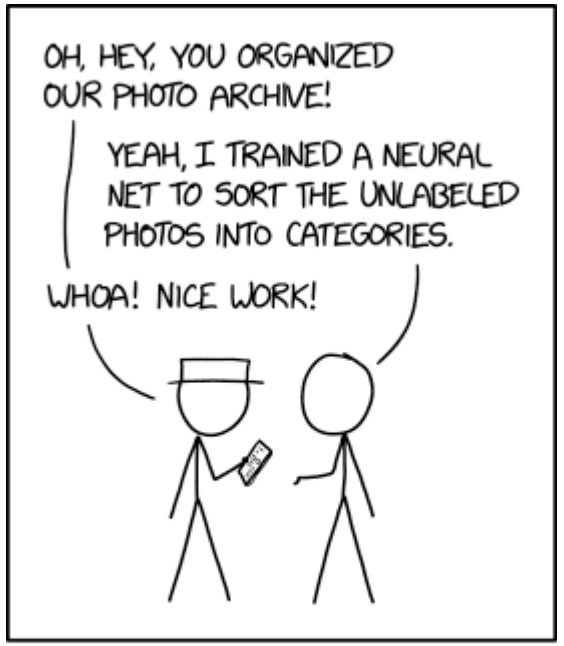

ENGINEERING TIP:
WHEN YOU DO A TASK BY HAND, YOU CAN TECHNICALLY SAY YOU TRAINED A NEURAL NET TO DO IT.

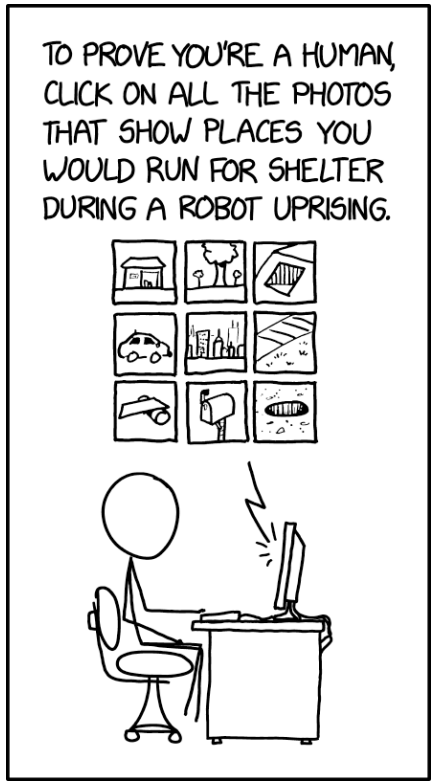

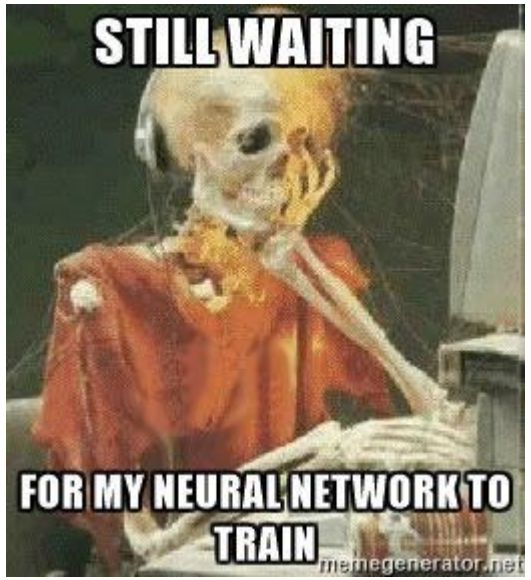

Figuras

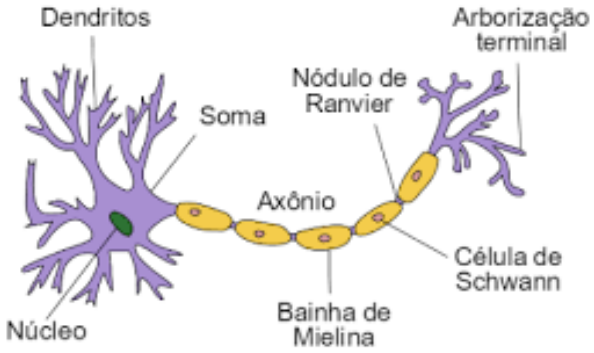
Dendritos
Arborização terminal
Nódulo de Ranvier
Soma
Axônio
Célula de Schwann
Núcleo
Bainha de Mielina

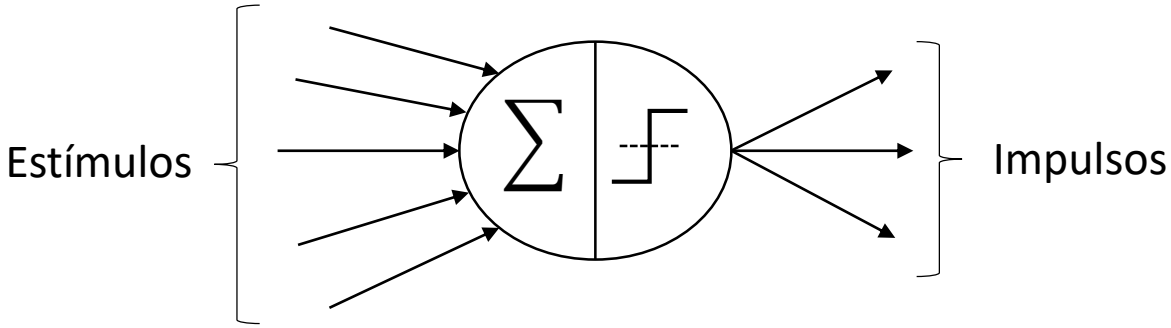
Estímulos
Impulsos

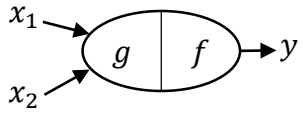

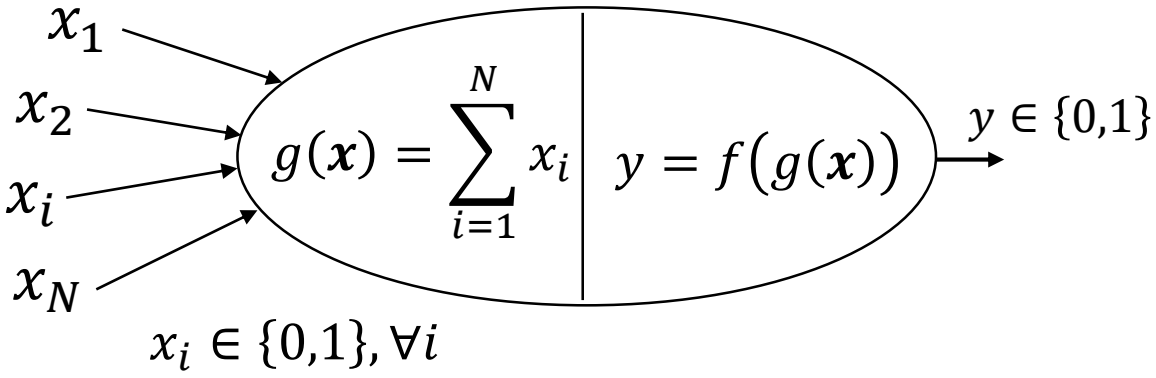

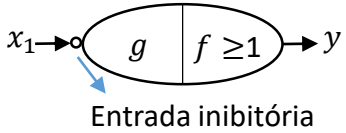

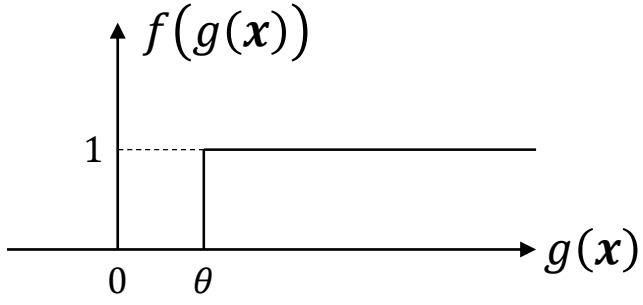

$$y = f\big(g(\boldsymbol{x})\big) = \begin{cases} 1 \text{ se } g(\boldsymbol{x}) \geq \theta \\ 0 \text{ se } g(\boldsymbol{x}) < \theta \end{cases}$$

onde θ é o limiar de decisão.

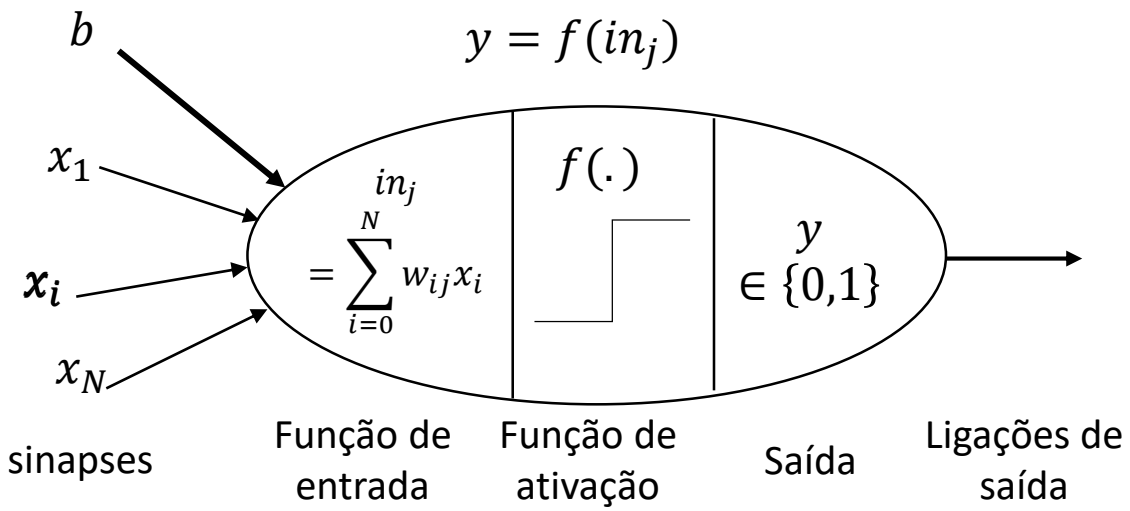
b
$y = f(in_j)$
x_1
$\boldsymbol{x_i}$
x_N
$in_j = \sum_{i=0}^{N} w_{ij} x_i$
$f(.)$
$y \in \{0,1\}$
sinapses
Função de entrada
Função de ativação
Saída
Ligações de saída

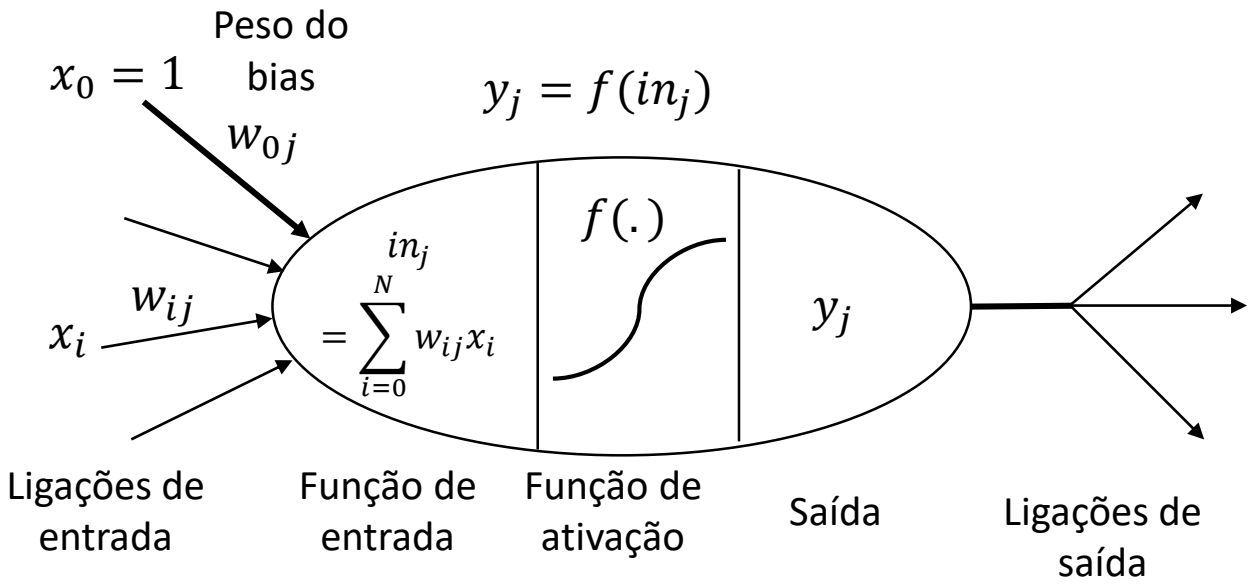
Peso do bias
$x_0 = 1$
w_{0j}
$y_j = f(in_j)$
$f(.)$
$in_j = \sum_{i=0}^{N} w_{ij} x_i$
w_{ij}
x_i
y_j
Ligações de entrada
Função de entrada
Função de ativação
Saída
Ligações de saída

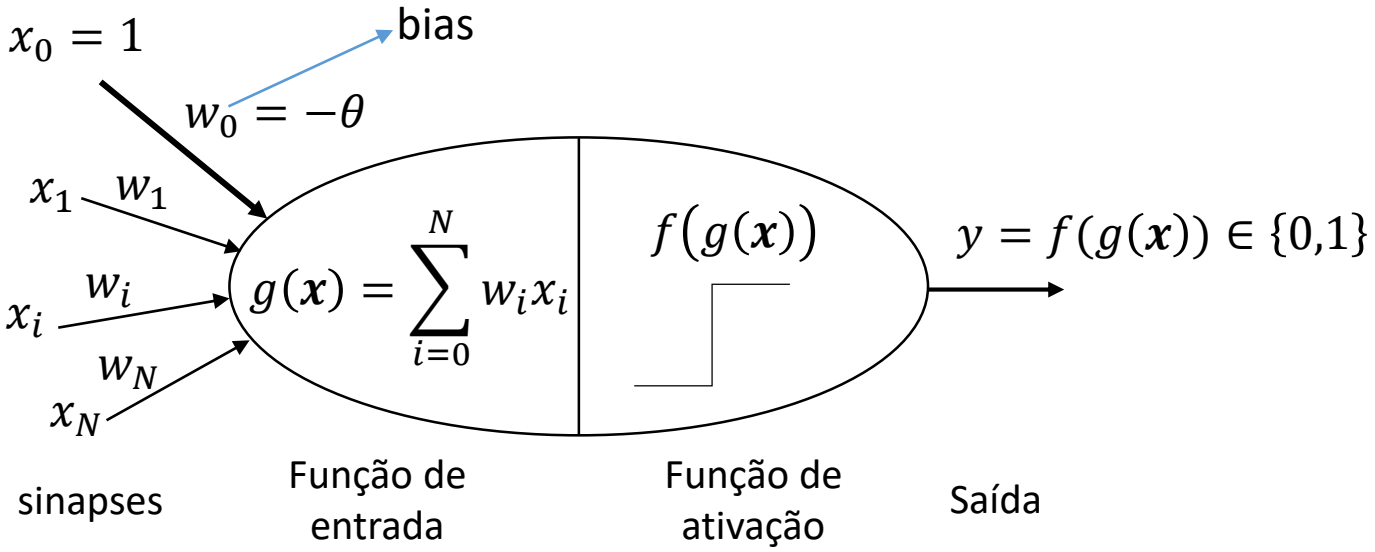
$x_0 = 1$
bias
$w_0 = -\theta$
x_1
w_1
x_i
w_i
w_N
x_N
$g(\boldsymbol{x}) = \sum_{i=0}^{N} w_i x_i$
$f(g(\boldsymbol{x}))$
$y = f(g(\boldsymbol{x})) \in \{0,1\}$
sinapses
Função de entrada
Função de ativação
Saída

$f(g(\boldsymbol{x}))$
1
0
$g(\boldsymbol{x})$

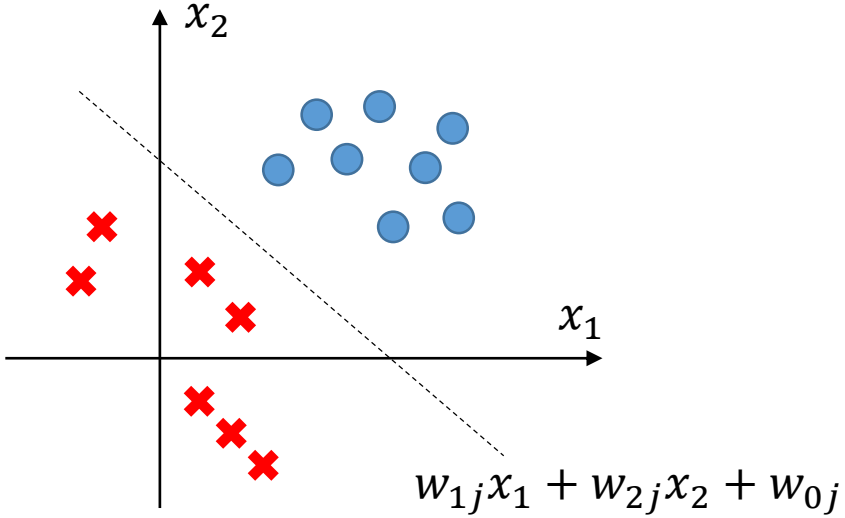
x_2
x_1
$w_{1j}x_1 + w_{2j}x_2 + w_{0j}$

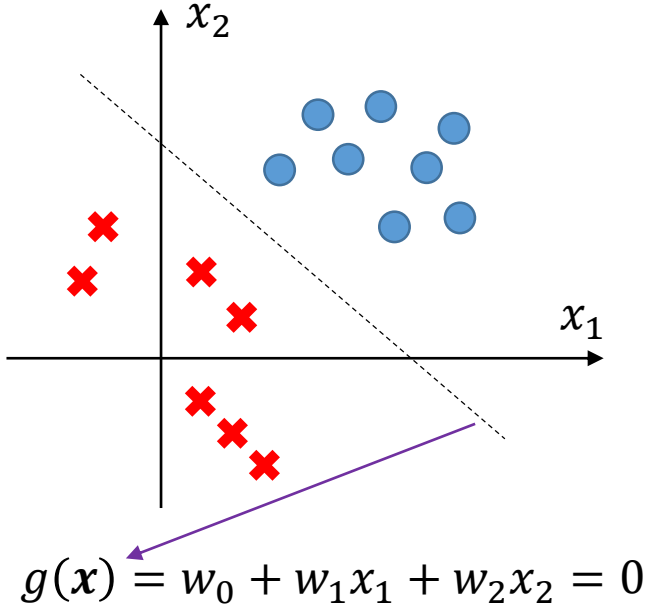
x_2
x_1
$g(\boldsymbol{x}) = w_0 + w_1x_1 + w_2x_2 = 0$

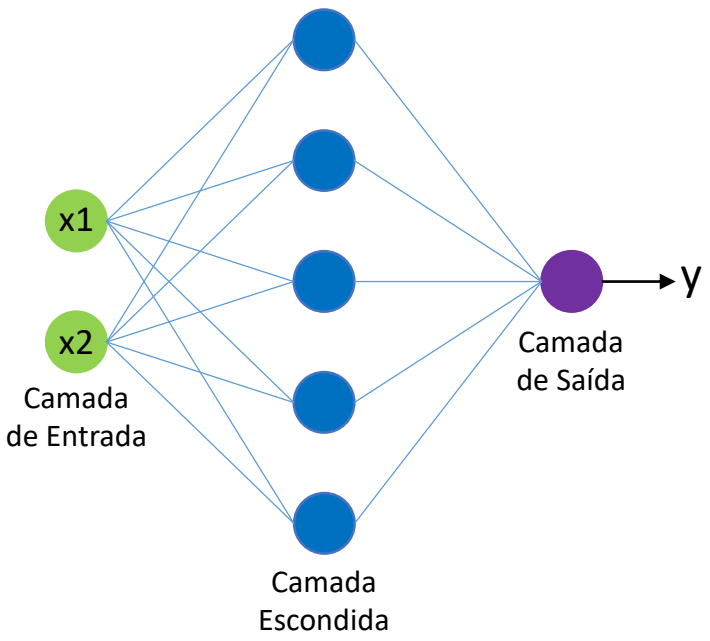
x1
x2
Camada
de Entrada
Camada
Escondida
Camada
de Saída
y

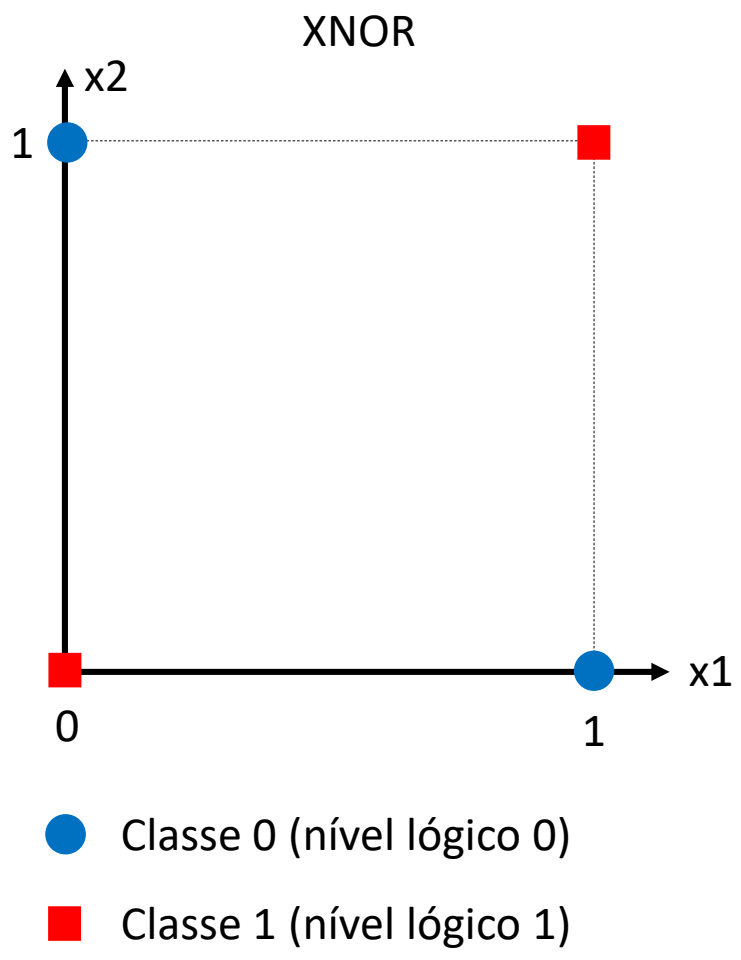
XNOR
x2
1
x1
0
1
Classe 0 (nível lógico 0)
Classe 1 (nível lógico 1)

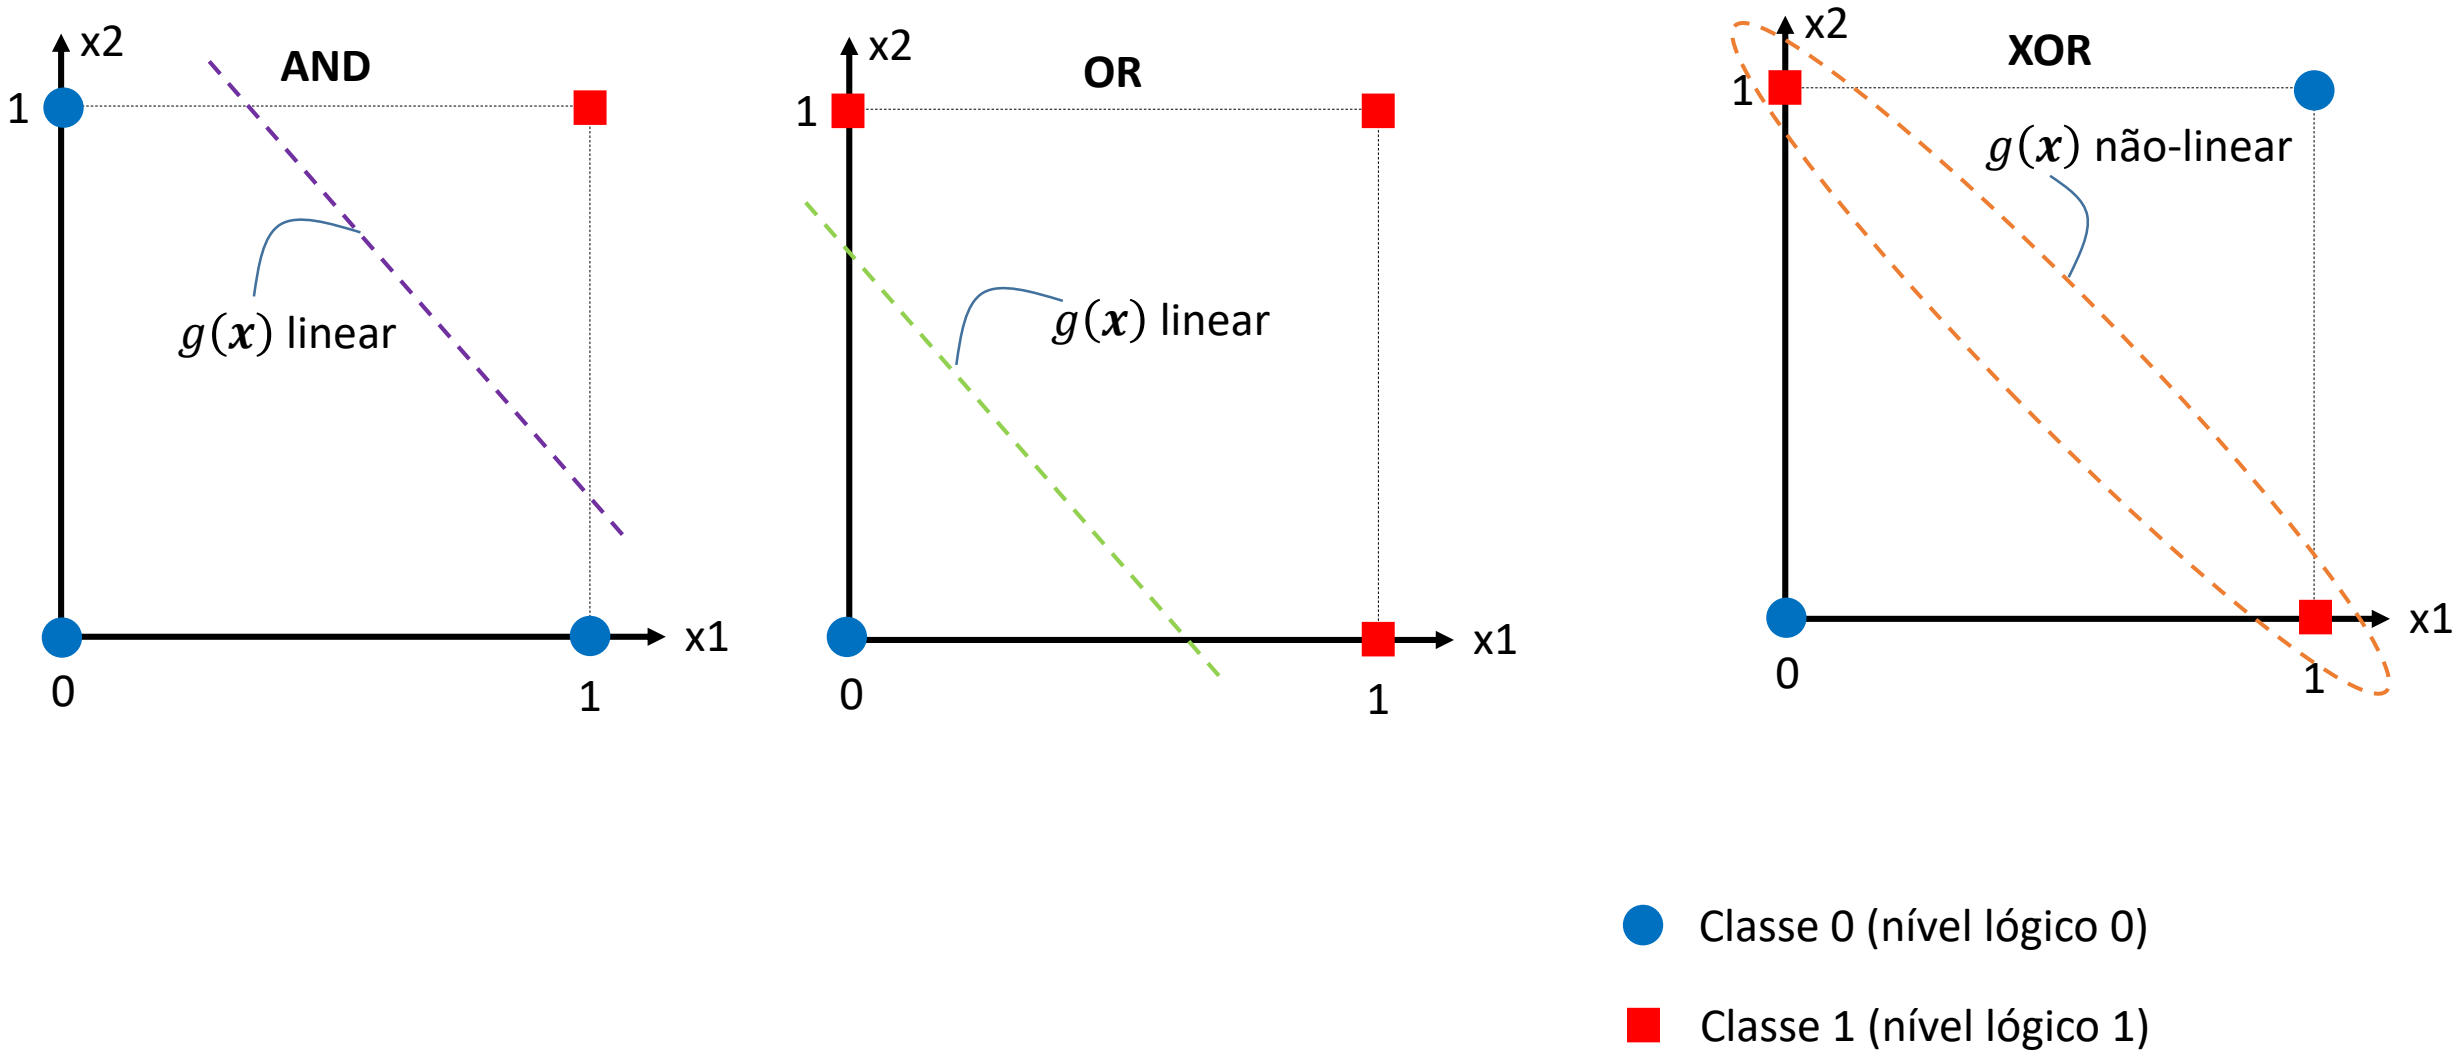
AND
x2
x1
1
0
1
$g(\boldsymbol{x})$ linear
OR
x2
x1
1
0
1
$g(\boldsymbol{x})$ linear
XOR
x2
x1
1
0
1
$g(\boldsymbol{x})$ não-linear
Classe 0 (nível lógico 0)
Classe 1 (nível lógico 1)

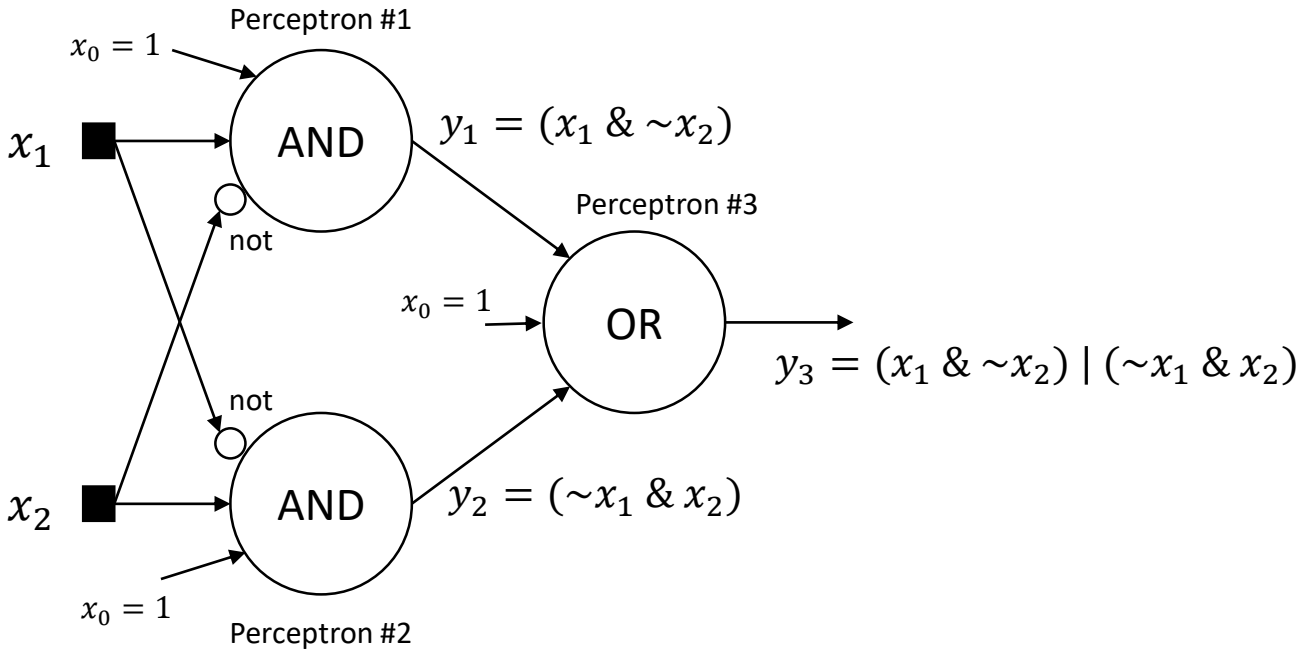
Perceptron #1
$x_0 = 1$
x_1
AND
$y_1 = (x_1 \,\&\, {\sim}x_2)$
not
Perceptron #3
$x_0 = 1$
OR
$y_3 = (x_1 \,\&\, {\sim}x_2) \mid ({\sim}x_1 \,\&\, x_2)$
not
x_2
AND
$y_2 = ({\sim}x_1 \,\&\, x_2)$
$x_0 = 1$
Perceptron #2

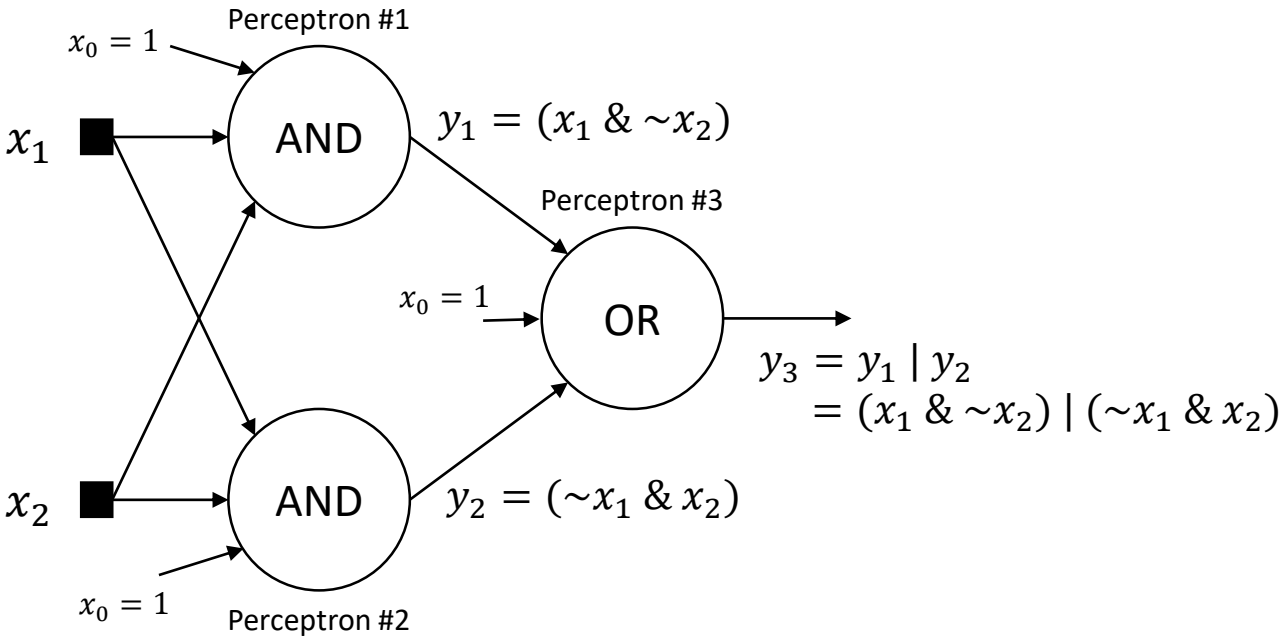
Perceptron #1
$x_0 = 1$
x_1
AND
$y_1 = (x_1 \,\&\, {\sim}x_2)$
Perceptron #3
$x_0 = 1$
OR
$y_3 = y_1 \mid y_2$
$= (x_1 \,\&\, {\sim}x_2) \mid ({\sim}x_1 \,\&\, x_2)$
x_2
AND
$y_2 = ({\sim}x_1 \,\&\, x_2)$
$x_0 = 1$
Perceptron #2

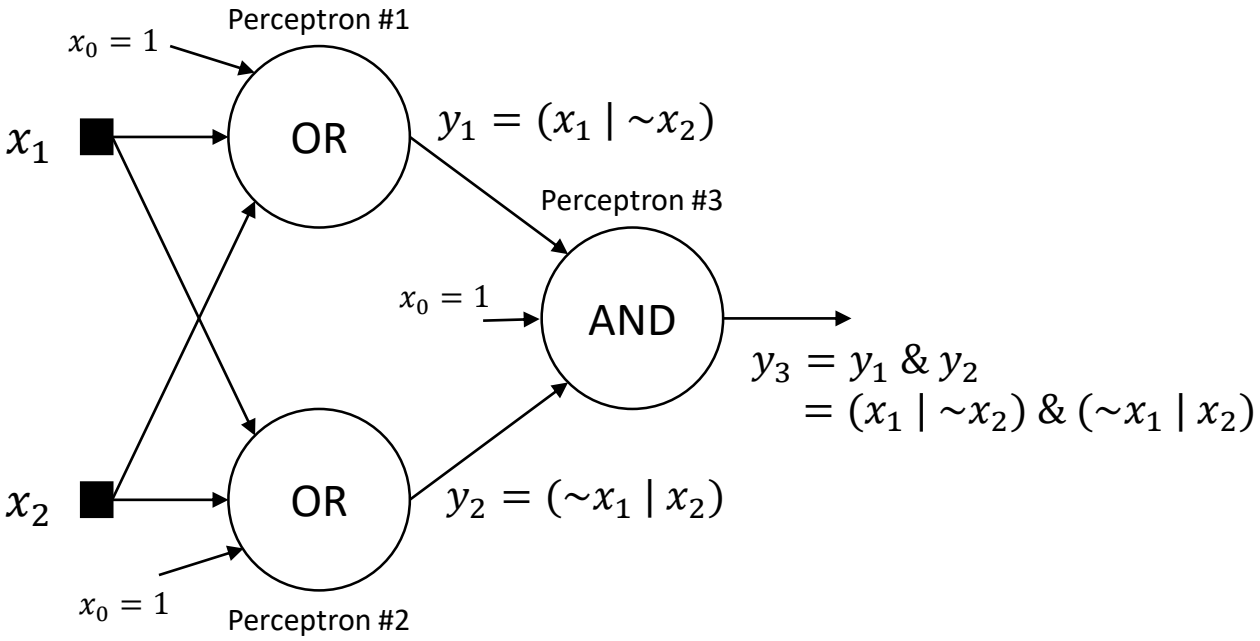
$x_0 = 1$
Perceptron #1
x_1
OR
$y_1 = (x_1 \mid \sim x_2)$
Perceptron #3
$x_0 = 1$
AND
$y_3 = y_1 \,\&\, y_2$
$= (x_1 \mid \sim x_2) \,\&\, (\sim x_1 \mid x_2)$
x_2
OR
$y_2 = (\sim x_1 \mid x_2)$
$x_0 = 1$
Perceptron #2

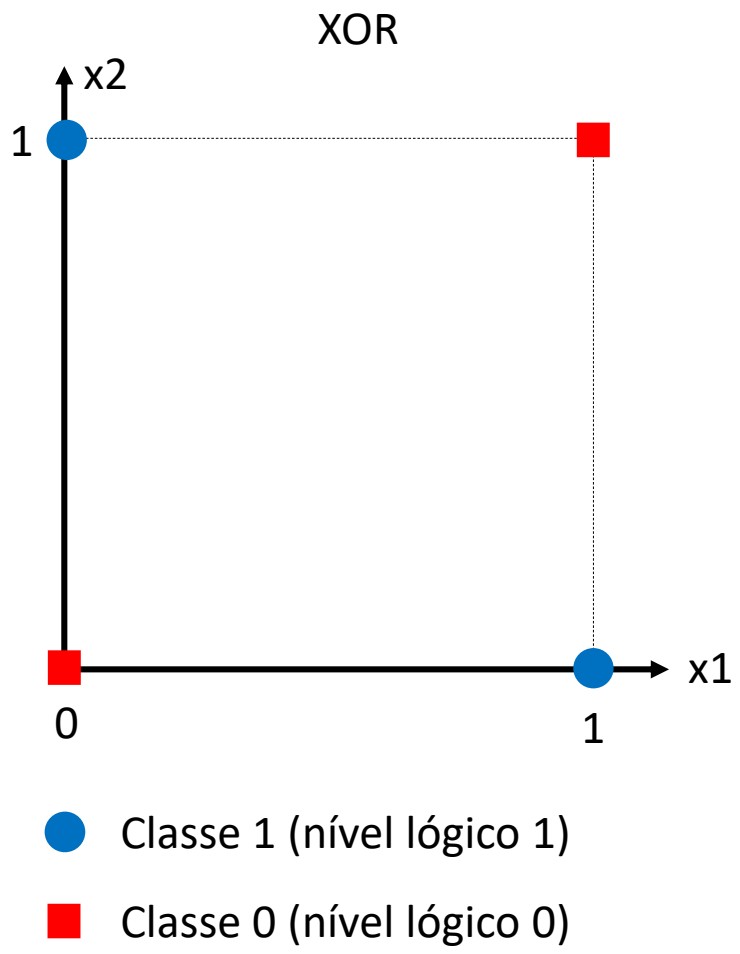
XOR
x2
1
x1
0
1
Classe 1 (nível lógico 1)
Classe 0 (nível lógico 0)

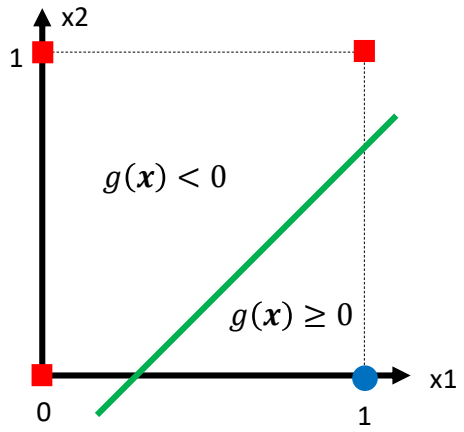
x2
1
$g(\boldsymbol{x}) < 0$
$g(\boldsymbol{x}) \geq 0$
x1
0
1

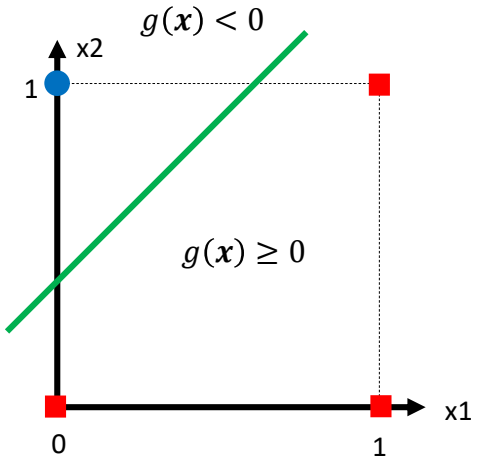
$g(\boldsymbol{x}) < 0$
x2
1
$g(\boldsymbol{x}) \geq 0$
x1
0
1